

KC桌面——外资精译

AI 系列第48期：Agent间协作；模型拓展应用场景

AI 系列第48期：Agent间协作；模型拓展应用场景

要点 (1) 腾讯：在Agent间（A2A）领域与不同行业建立合作；(2)
阿里巴巴：通义千问应用向第三方Agent和技能开放，为用户提供一站式个性化服务；(3)
美图与WPS达成合作，前者AI设计功能向WPS用户开放；(4)
继Anthropic于5月之后，OpenAI正在Codex中加强金融和法律Agent功能；(5)
OpenRouter：Token消耗量较前一周增长13.5%

在本报告中，我们为投资者提供超过50个数据点，涵盖OpenRouter的Token消耗量、不同模型的定价、Artificial Analysis中的模型智能水平、按子行业划分的用户趋势及其他行业数据以供分析。

腾讯：构建Agent间生态系统。其中包括 (1) 与美团AI助手“小美”及AI助手“元宝”的合作。当用户在元宝中提交本地服务请求时，将实现Agent间（A2A）通信；(2) 与OPPO、小米、华为、Vivo、荣耀等多家智能手机品牌在A2A（Agent间）能力上合作。用户可与手机内置AI语音助手对话，后者将帮助发送微信消息或启动微信音视频通话（而非打开微信应用）。据腾讯云AI行业应用峰会（链接），产品是除模型和前沿技术探索之外AI领域的重点之一。多元化的产品及数据洞察可进一步解锁不同应用场景下的模型智能。

阿里巴巴：通义千问应用向第三方Agent和技能开放，零售品牌及航空公司参与；6月1日发布Qwen3.7-Plus。在Agent和技能方面，首批合作伙伴包括肯德基、瑞幸、蜜雪冰城及中国东方航空。我们认为通义千问应用正在构建Agent生态系统，并为用户提供全面的个性化服务。另一方面，阿里巴巴在5月阿里云峰会（链接）发布Qwen 3.7-Max后，于6月1日发布Qwen3.7-Plus。它是一个多模态交互式混合Agent，具备统一的GUI（图形用户界面）/ CLI（命令行界面），可处理视觉和文本任务，并提供全面的编码Agent及全模态输入的生产力工具。此外，它在多种Agent框架下具有跨框架泛化能力。


美图与WPS在办公+设计领域开展合作。WPS用户可通过文生图/图生图功能使用美图AI海报特性，尤其适用于电商商户的营销素材。另一方面，WPS用户也可在短视频生成中使用美图功能，用于直播电商。

可灵（Kling）于2026年6月26日全球用户数突破1亿。这较2025年底的6000万用户增长67%。企业客户数量从2025年的3万家增至2026年6月的5万家。覆盖全球224个国家和地区。

Kimi推出AI桌面端Kimi Work。要点 (1) 本地Agent可全天候自主运行；(2)
WebBridge使其能够访问浏览器并完成多步骤任务；(3) 群体智能（Swarm Intelligence）可通过使用多个专业Agent并将任务同时分解为多层子任务来解决复杂问题；(4)
专为金融行业构建，并预集成跨不同市场的深度数据源。

继Anthropic于5月之后，OpenAI推出面向金融和法律行业的AI工具。OpenAI为Codex推出了6个新插件，具备金融领域的专业技能。面向法律行业的插件正在开发中。此前，Anthropic于5月推出了10个金融服务Agent模板，涵盖研究、客户覆盖以及金融与运营等领域。

图表1 - 截至6月8日过去12个月的周度Token消耗量（万亿）



图表 1

来源：OpenRouter, JEF

图表2 - 最新一周按模型划分的Token消耗量前十排名

来源：OpenRouter, JEF

OpenRouter：Token消耗量较前一周增长13.5%。基于对6月1日当周（对比5月25日当周）的分析（图表1），周度Token消耗量增长13.5%至36.1万亿。排名方面，DeepSeek V4 Flash位列第一，其次是腾讯的Hy3预览版和MiniMax M3。

百度、阿里、腾讯、金山云、AI实验室及可灵为受益方。我们预计，AI模型和Agent需求上升带来的Token消耗量激增将使百度、阿里巴巴、腾讯（BAT）、金山云（KC）、AI实验室及可灵等云服务提供商受益。根据Artificial Analysis的分析，(1) 中美模型之间的智能差距正在缩小；(2)

得益于MoE、线性注意力及MFU，API成本仅为美国的几分之一；(3)


编码、工作空间场景及中长篇幅内容未来将迎来重大机遇（图表69-73）。

中美对比

AI模型

根据OpenRouter，2026年2月Token消耗量大幅增长，原因是 (a) 编码/Agent采用率激增，使人们使用AI从“聊天”转向“工作”。它连接可本地部署或服务器部署的大模型，允许通过自然语言聊天实现工作流自动化；(b) 发布了多款高性能且成本高效的模型，包括Kimi K2.5（2026年1月）、M2.5（2026年2月）和GLM-5（2026年2月）。

图表3 - 截至6月8日过去12个月的周度Token消耗量（万亿）




图表 2

来源：OpenRouter, JEF 根据OpenRouter（6月1日至7日），中国模型Token消耗量较前一周增长27.5%，达14.2万亿。相比之下，美国模型Token消耗量为3.2万亿。DeepSeek V4 Flash周度Token消耗量快速增长

根据OpenRouter，编码/Agent采用率上升以及高性能、成本高效的中国模型发布正在推动Token消耗量增长在OpenRouter中，中国模型在6月1日当周的Token消耗量超过美国模型


图表4 - 截至6月8日按公司划分的周度Token消耗量市场份额



图表 3

来源：OpenRouter, JEF

图表5 - 自2026年1月以来的每周Token消耗量（十亿）



图表 4

来源：OpenRouter, JEF

DeepSeek V4 Flash在6月1日当周Token消耗量排名第一

图表6 - 最新一周按模型划分的Token消耗量前十排名

来源：OpenRouter, JEF


根据Artificial Analysis, 中国模型DeepSeek、Qwen、Kimi、MiniMax和智谱在智能水平上正缩小与美国模型的差距。中国模型在混合专家（MoE）架构、线性注意力和MLU（模型算力利用率）方面具有高成本效益。根据2026年斯坦福AI指数报告（2026年4月），美国顶尖模型领先中国模型2.7%。此外，截至2026年3月，Anthropic（1503）、xAI（1495）、Google（1494）、OpenAI（1481）、阿里巴巴（1449）和DeepSeek（1424）占据Arena Elo评分的第一梯队。

图表7 - 最新一周按模型划分的Token消耗量第11至20名排名

来源：OpenRouter, JEF

中国模型在智能水平上正缩小与美国模型的差距。在输入/输出API方面，中国大模型相比美国模型具有高效率。

图表8 - 截至6月8日领先模型的缓存命中/输入/输出API价格




图表 5

来源：Artificial Analysis, JEF

在输入/输出 API 价格方面，中国模型仅为美国模型的一个零头。

图表 9 - 截至 6 月 8 日的前 20 大模型智能指数




图表 6

来源：Artificial Analysis, JEF

在前 20 大模型中，截至 6 月 1 日有 9 个是中国模型且权重开放。


图表 10 - 截至 6 月 8 日的前沿语言模型智能随时间变化



图表 7

来源：Artificial Analysis, JEF


图表 11 - 截至 6 月 8 日的前 20 大模型智能体指数



图表 8

来源：Artificial Analysis, JEF


图表 13 - 截至 6 月 8 日的人工智能指数运行成本



图表 9

来源：Artificial Analysis, JEF


图表 12 - 截至 6 月 8 日的前 20 大模型编程指数



图表 10

来源：Artificial Analysis, JEF

图表 14 - 截至 6 月 8 日的人工智能指数运行输出速度



图表 11

来源：Artificial Analysis, JEF

不同模型的输入/输出价格 / 编程计划与智能体产品定价

红色表示当月价格上涨/新价格

图表 15 - 阿里巴巴、腾讯、百度和字节跳动的定价计划

来源：公司, JEF

图表 16 - AI 实验室 MiniMax、智谱、Kimi 的定价计划

来源：公司, JEF

图表 17 - AI 实验室 StepFun、小米和 DeepSeek 的定价计划

来源：公司, JEF

图表 18 - 海外参与者 Anthropic、OpenAI 和 Google 的定价计划

来源：公司，JEF

视频生成模型产品

红色表示当月价格上涨/新价格

图表 19 - 视频生成模型定价（人民币）

来源：公司，JEF

不同视频生成模型的定价计划

图表 20 - 视频生成模型定价（美元）

来源：公司，JEF

图表 21 - 视频生成会员比较（原价）

来源：公司，JEF

图表 22 - 视频生成会员比较（促销后）

来源：公司，JEF

编程计划与智能体产品

红色表示当月价格上涨

图表 23 - 火山引擎方舟智能体计划

来源：公司，JEF

领先参与者的不同编程和智能体产品定价计划

图表 24 - 腾讯 AI 产品定价

来源：公司，JEF

图表 25 - Hy Token 计划

来源：公司，JEF

图表 26 - 腾讯 Token 计划

来源：公司，JEF

图表 27 - BABA 编程计划

来源：公司，JEF

图表 28 - BABA Token 计划

来源：公司，JEF

图表 29 - 百度编程计划

来源：公司，JEF

图表 30 - MaxClaw 订阅价格

来源：公司，JEF

图表 31 - MaxClaw 附加价格

来源：公司，JEF

图表 32 - MiniMax Token 计划

来源：公司， JEF

图表 33 - 小米 MiMo Token 计划

来源：公司， JEF

图表 34 - GLM 编程计划

来源：公司， JEF

图表 35 - Kimi 会员计划

来源：公司， JEF

图表 36 - Kimi 会员计划（续）


来源：公司， JEF

OpenClaw

根据 OpenRouter， OpenClaw 基于 Token 消耗的前三大模型来自中国，即 DeepSeek V4 Flash、 MiniMax M3 和 MiniMax M2.7。其他模型包括 DeepSeek V4 Pro、 MiniMax M2.5 和 GLM 5.1。

根据 OpenRouter， DeepSeek V4 Flash、 MiniMax M3 和 MiniMax M2.7 在 OpenClaw 上的 Token 消耗量排名前三。

图表 37 - OpenClaw 的 Token 消耗量（十亿）




图表 12

来源：OpenRouter， JEF

图表 39 - 过去 30 天 OpenClaw 使用的前 15 大模型（截至 6 月 8 日）

来源：OpenRouter， JEF

图表 38 - Hermes Agent 的 Token 消耗量（十亿）




图表 13

来源：OpenRouter, JEF

图表 40 - 过去 30 天 Hermes Agent 使用的前 15 大模型（截至 6 月 8 日）

来源：OpenRouter, JEF


图表 41 - 全球：截至 6 月 8 日成功率前 10 大模型



图表 14

来源：PinchBench, JEF

图表 42 - 中国：截至 6 月 8 日成功率前 10 大模型



图表 15


来源：PinchBench, JEF

AI 助手

\- 环比趋势：4月通义千问 DAU 达到 2920 万（3月：2910 万），元宝达到 900 万（3月：800 万）。豆包环比增长 13% 至 1.51 亿（3月：1.33 亿）。DeepSeek DAU 环比增长约 1% 至约 2900 万。

4月多家领先玩家的 DAU 环比增长


图表 43 - 中国领先 AI 助手的周 DAU（百万）



图表 16

来源：QuestMobile, JEF


图表 45 - 中国领先 AI 助手的每周 DAU 人均使用时长（分钟）



图表 17

来源：QuestMobile, JEF


图表 44 - 中国领先 AI 助手的月 DAU（百万）



图表 18

来源：QuestMobile, JEF

图表 46 - 中国领先 AI 助手的月 DAU 人均日使用时长（分钟）



图表 19

来源：QuestMobile, JEF

视频生成模型

根据 Artificial Analysis（截至 6 月 8 日），HappyHorse-1.0 在文生视频和图生视频方面排名前五。其他包括 Seedance 2.0、SkyReels V4、Kling 3.0 Omni 1080p、Kling 3.0 1080p、Veo 3.1 和 grok-imagine-video。

图表 47 - 图生视频排行榜前 15 名（含音频）

来源：Artificial Analysis, JEF

图表 48 - 文生视频排行榜前 15 名（含音频）

来源：Artificial Analysis, JEF

全球及中国 AI 移动应用 MAU 排名

图表 49 - 全球 AI 移动应用 MAU 排名（5 月 26 日）

来源：AICPB, JEF

图表 50 - 中国 AI 移动应用 MAU 排名（5 月 26 日）

来源：AICPB, JEF

根据 aicpb.com，由于 2 月春节，中国 AI 应用（包括豆包、通义千问、夸克和元宝）的 MAU 相比 ChatGPT 经历了强劲的环比增长。

在国内市场，Kling 的 MAU 在 5 月实现了快速的环比增长。


4 月 26 日：来自 QuestMobile 分析的月度应用追踪器

在线购物

\- 环比趋势：4 月淘宝/拼多多 DAU 分别下降 1%/2%，唯品会增长 3%。京东 DAU 环比增长 2%。 \- 同比趋势：京东 DAU 同比增长 9%，淘宝/拼多多分别同比增长 6%/10%。


4 月拼多多 DAU 保持快速同比增长

图表 51 - 4 月 26 日淘宝/拼多多/京东的 MAU



来源：QuestMobile, JEF

图表 52 - 4 月 26 日淘宝/拼多多/京东的 DAU



来源：QuestMobile, JEF

4 月美团 MAU 环比基本稳定

外卖

- 环比趋势：美团 MAU 当月环比增长 1%。
- 同比趋势：4 月美团 MAU 同比增长 4%（3 月同比增长 3%）。

图表 53 - 过去 12 个月美团应用的 MAU



来源：QuestMobile, JEF


在线音乐

\- 环比趋势：4月汽水音乐 MAU 环比增长 2% 至 1.599 亿。腾讯音乐方面，QQ 音乐/酷狗/酷我 MAU 分别环比下降 6%/3%/3%。网易云音乐 MAU 当月环比增长 1%。

汽水音乐保持快速的 MAU 同比增长，4 月环比基本稳定

\- 同比趋势：4月汽水音乐 MAU 同比增长 75%，网易云音乐 MAU 同比增长 2%。腾讯音乐方面，QQ 音乐 MAU 同比增长 1%，而酷狗/酷我 MAU 分别同比下降 8%/16%。


图表 54 - 4 月 26 日腾讯音乐、汽水音乐和网易云音乐的 MAU



图表 23

来源：QuestMobile, JEF

图表 55 - 过去 12 个月汽水音乐的 MAU




图表 24

来源：QuestMobile, JEF

在线视频

- 环比趋势：腾讯视频/爱奇艺的MAU环比下降3%/7%，优酷环比增长8%。芒果TV的MAU保持环比稳定增长。
- 同比趋势：当月主要长视频平台的MAU同比下滑。

图表56- 爱奇艺、腾讯视频和优酷在4月26日的MAU



图表 25

来源：QuestMobile, JEF


直播与短视频

- 环比趋势：抖音主应用DAU在4月环比增长2%。游戏直播方面，虎牙MAU环比增长3%，斗鱼环比下降8%。哔哩哔哩MAU当月环比保持稳定。
- 同比趋势：抖音主应用DAU保持20%的稳健同比增长。游戏直播方面，虎牙和斗鱼的MAU同比分别下降4%和15%。哔哩哔哩MAU当月同比增长约4%。

主要长视频平台MAU在4月同比下滑

抖音DAU在4月保持稳健同比增长

图表57 - 抖音过去12个月的DAU



图表 26

来源：QuestMobile, JEF

图表58 - 哔哩哔哩过去12个月的MAU



图表 27

来源：QuestMobile, JEF

在线旅游

- 环比趋势：携程/去哪儿的MAU在4月环比分别增长7%/8%。
- 同比趋势：携程/去哪儿的MAU在4月同比分别下降5%/10%。

图表59 - 携程过去12个月的MAU



图表 28

来源：QuestMobile, JEF

在2月春节过后，携程国内市场的MAU在4月环比增长

新闻应用

- 环比：微博MAU在4月下降1%，今日头条MAU下降3%。
- 同比：微博MAU同比下降2%，今日头条同比下降3%。

微博MAU在4月出现同比负增长

图表60 - 微博过去12个月的MAU

来源：QuestMobile, JEF

百度应用

- 环比：MAU保持稳定，DAU在4月增长2%。
- 同比：MAU同比下降7%，DAU同比下降20%。

图表61 - 百度过去12个月的MAU

来源：QuestMobile, JEF

百度应用MAU在4月环比稳定，同比下滑

IDC关于公有云Token消耗的估算与展望

图表62 - 2025年中国MaaS市场月均日均Token消耗量

来源：IDC, JEF

图表64 - 2025年中国MaaS市场主要厂商份额（按收入计）

来源：IDC, JEF

图表66 - 推动人们决定广泛部署模型的最重要因素

来源：IDC, JEF

图表63 - 2025年中国MaaS市场Token消耗份额

来源：IDC, JEF

图表65 - 2025年中国私有大型模型平台市场主要厂商份额（按收入计）

来源：IDC, JEF

来源：IDC, JEF

附录

Omdia关于亚洲及大洋洲智能体AI开发平台的热力图

根据Omdia，智能体AI软件市场预计将以105%的复合年增长率从2025年的2.71亿美元增长到2030年的97亿美元。阿里云在5个领域获得最高排名：(1) 上下文工程，(2) 模型支持，(3) 多智能体框架，(4) 运维与生命周期管理，以及 (5) 开源与社区。

图表68 - Omdia关于亚洲及大洋洲智能体AI开发平台的热力图

来源：Omdia, JEF

根据Omdia，阿里云被列为构建和部署AI智能体的领导者与首选之一。它在7项指标中的5项获得最高排名。

市场规模：编码、工作空间与内容创作

根据Grand View Research，全球AI代码工具市场预计将从2025年到2030年增长3倍，达到260亿美元。另一方面，F&S预测中国AI代码生成市场将在2028年达到约47亿美元。KA定制化解决方案预计将成为关键收入贡献者。

全球AI代码工具市场预计2030年规模是2025年的3倍

图表69 - 全球AI代码工具市场规模（十亿美元）

来源：Grand View Research, JEF

图表70 - 中国AI代码生成市场规模（按服务类型，十亿元人民币）

来源：Frost & Sullivan, JEF

图表71 - 中国不同行业的AI代码渗透率

来源：Frost & Sullivan, JEF

根据高临产业研究（2024），AI+工作空间软件市场规模预计在2028年达到1910亿元人民币，是2024年规模的6倍。

在AI代码渗透率方面，互联网、游戏、人工智能、金融和能源是前五大关键行业

图表72 - 中国AI+工作空间市场规模

图表73 - 内容创作中的生成式AI市场规模 2025年至2035年（十亿美元）

来源：Precedence Research, JEF 来源：高临, JEF

根据Precedence Research，全球生成式AI内容创作市场预计增长7倍，在2035年超过1400亿美元，对比2025年。

图表74 - 2025年下半年与上半年中国企业日均Token消耗量（万亿）

来源：Frost & Sullivan, JEF

根据F&S，企业日均Token消耗量环比增长263%，达到37万亿，其中阿里云市场份额增长最多，在2025年下半年占据第一位置，达到32%（2025年上半年：17.7%），其次是豆包的21.3%（2025年上半年：14.1%）和DeepSeek的18.4%（2025年上半年：10.3%）。

阿里通义千问在2025年下半年企业Token消耗量中排名第一

图表75 - 2025年上半年企业Token消耗市场份额

来源：Frost & Sullivan, JEF

图表76 - 2025年下半年企业Token消耗市场份额

来源：Frost & Sullivan, JEF

中国大语言模型

根据F&S/中国信通院，中国大语言模型市场预计在2024年至2030年间以约64%的复合年增长率增长，并在2030年超过1000亿元人民币。按细分市场看，由于付费意愿仍然较低，消费者收入的增长速度预计将慢于企业。

中国大语言模型预计在2024年至2030年间以64%的复合年增长率增长。按细分市场看，本地部署是主要收入贡献者

图表77 - 中国大语言模型市场规模（十亿元人民币）

来源：Frost & Sullivan, 中国信通院, JEF

图表78 - 中国企业大语言模型市场规模（十亿元人民币）

来源：Frost & Sullivan, 中国信通院, JEF

Anthropic与OpenAI

- 2026年5月，Anthropic于5月28日宣布投后估值9650亿美元。其在H轮融资中筹集了650亿美元。ARR在5月初超过470亿美元。
- 据The Information报道，OpenAI收入预计在2030年达到2000亿美元，是2026年规模的6倍以上。预计未来几年智能体收入贡献将上升。

图表79 - Anthropic的ARR

来源：The Information，公司报告，JEF

图表81 - OpenAI 2023年至2030年预测收入（截至2025年第三季度）

来源：The Information，JEF

图表80 - OpenAI的ARR

来源：The Information，公司报告，JEF

图表82 - OpenAI 2024年至2030年预测收入构成（截至2025年第三季度）

来源：The Information，JEF

图表83 - MiniMax：未来几年占OpenAI收入的百分比

来源：CIC，JEF估计

中国主要参与者的模型

图表84 - 阿里模型列表

来源：公司，JEF

图表85 - 腾讯模型列表

来源：公司，JEF

图表86 - 百度模型列表

来源：公司，JEF

图表87 - MiniMax模型列表

来源：公司，JEF

图表88 - Moonshot AI模型列表

来源：公司，JEF

图表89 - Z.ai模型列表

来源：公司，JEF

图表90 - 基准测试术语表

来源：JEF

我们看到不同的第三方分析显示，中国对全球Token消耗有显著贡献。根据Hugging Face的数据，在截至2月26日的过去12个月中，中国模型占全球下载量的41%。

Exhibit 91 - 中国每日Token使用量

来源：国家数据局（NDA），JEF

Exhibit 92 - 豆包每日Token消耗量

来源：火山引擎, JEF

Exhibit 93 - 各区域Token份额

来源：OpenRouter, JEF

公司估值/风险

公众号：KC桌面