

KC桌面——外资精译

美洲科技：硬件

传统服务器与加速服务器：行业入门指南

本报告作为服务器行业的全面入门指南，专为经验丰富的科技投资者和硬件领域新手设计。它提供了对过去70年市场技术演进、当前竞争动态以及行业治理财务框架的基础分析。通过将我们的分析植根于历史趋势和当前单位经济模型，本报告旨在为投资者提供必要的工具，以应对全球服务器生态系统内的短期波动和长期转变。

本入门指南的重点领域包括：

2026-30年服务器市场预测：650 Group预测，全球服务器市场将以+38%的五年复合年增长率增长，到2030年达到1.4万亿美元，驱动力来自传统服务器（2030年1640亿美元）+13%的增长和加速服务器（2030年1.2万亿美元）+45%的增长。传统服务器和加速服务器市场在所有客户垂直领域都应实现两位数增长，超大规模云商和新型云服务商因持续的AI基础设施部署而表现强劲，而企业需求则应受益于为支持代理型AI采用及更广泛技术更新而进行的数据中心现代化改造。还包括AI基础设施部署中CPU和GPU作用的总结。

■ 市场结构与供应商动态：对服务器供应商格局的审视，其中市场份额因客户垂直领域不同而存在显著差异。企业市场高度集中，由品牌OEM厂商主导，包括戴尔、HPE、联想和IBM，而超大规模机会主要由白牌供应商满足；新型云服务商目前混合使用OEM和ODM。

单位经济模型及大宗商品成本变化的影响：传统服务器和AI服务器物料清单的详细分解。我们估计，服务器OEM在销售一台CPU服务器时通常能获得15%的毛利率和5-7%的营业利润率。DRAM和NAND历史上约占传统服务器物料清单的30%，但根据当前行业对2026/27年价格上涨的预期，假设没有抵消措施，到2026年底，内存可能占传统服务器物料清单的60%以上。

目录


传统服务器 5 加速服务器 15 大宗商品成本上升如何影响服务器市场？ 23 披露附录 27

定义服务器市场

服务器是为客户端运行特定应用服务的专用计算机。虽然PC和服务器架构相似，但服务器通常设计有更多的CPU/GPU插槽、内存以及电源/网络接口的冗余，以确保关键任务工作负载的可用性。在企业中，服务器用于处理网络的边缘或前端，服务于协作商业软件、网页服务、文件服务和电子邮件等应用。云提供商在数据中心大规模部署服务器（数量级达数十万台），用于运行云计算、搜索、视频交付、社交网络以及最近的生成式AI工作负载等应用。

2025年，整个服务器市场的年收入约为2840亿美元，同比增长45%，驱动力来自AI服务器需求的强劲增长和更高的平均售价。除非另有说明，本入门指南中的所有服务器市场估计（包括市场份额和预测）均基于650 Group的数据。650 Group预计，未来五年整体服务器市场将以38%的复合年增长率增长，到2030年达到约1.4万亿美元，驱动力来自AI服务器需求。虽然服务器市场历史上由新技术采用和基础设施更新周期驱动，但2023年和2024年实现的强劲AI驱动增长标志着与历史增长趋势的重大转折。因此，在本报告中，我们分别审视传统服务器（即通用、非加速服务器）市场和加速服务器（即带有额外GPU或其他定制加速器的高性能服务器）市场。


图表1：2025年整个服务器市场的年收入约为2840亿美元，同比增长45%，驱动力来自AI服务器需求的强劲增长和更高的平均售价 行业服务器收入（百万美元）和增长率（%）



图表 1

来源：650 Group


图表2：2025年行业服务器出货量同比下降13%，原因是AI服务器需求被传统服务器的下降所抵消；预计2026年传统服务器和AI服务器出货量都将增长 行业服务器出货量（千台）和增长率（%）



图表 2

来源：650 Group

图表3：供应商市场份额因垂直领域和产品（AI与传统）不同而存在显著差异 服务器细分市场摘要



图表 3




图表 4

来源：650 Group

传统服务器


根据650 Group的数据，2025年传统服务器市场的年收入约为890亿美元（同比增长10%），出货量约840万台（下降18%），平均售价约为10,500美元（同比增长35%）。传统服务器，也称为通用服务器，部署在各种环境中，从本地服务器机房到数据中心，通常用于更通用的工作负载，如网页托管、数据库管理、文件共享或应用服务器（相对于AI/ML等专业化工作负载）。对于AI推理和训练，非加速服务器用于编排和控制平面层。传统服务器包括CPU、内存、存储等。与AI服务器不同，传统服务器没有嵌入加速卡（即GPU）。

图表4：2025年传统服务器市场的年收入约为890亿美元（同比增长10%） ...
行业传统服务器收入（百万美元）和年增长率（%）



图表 5


来源：650 Group 图表5：...出货量约840万台，平均售价约为10,500美元
传统服务器出货量（百万台）和平均售价（美元）



图表 6


来源：650 Group 2024年传统（非加速）服务器按CPU架构划分的出货量

图表6：行业标准服务器基于x86 CPU架构



图表 7

图表7：大多数传统服务器为机架式或模块化 2024年传统（非加速）服务器按外形规格划分的出货量




图表 8

来源：IDC

最早于20世纪50年代推出的服务器是大型机，这是一种高性能、高可靠性的计算系统。大型机采用集中式架构，配备大型处理器和大容量内存，最重要的是具有多层冗余设计，有助于保证高可用性。虽然大型机在服务器出货量中仅占较小份额，但对于需要持续运营的行业（如金融机构、医疗保健公司和政府机构）的关键任务工作负载而言，大型机占据重要份额（IBM报告称，全球前50大银行中有90%运行在IBM Z（其大型机解决方案）上）。机架式服务器于20世纪90年代推出，以满足互联网基础设施日益增长的需求。机架式服务器采用标准化单元（称为机架单元（“U”），每个高1.75英寸、宽19英寸）制造，并安装在机箱或机架中（标准服务器机架高42U）。这种标准化提高了效率、可扩展性并简化了管理；机架式服务器通常是更具成本效益的计算解决方案。

案。服务器有多种外形规格，但标准CPU服务器通常为1U或2U，这意味着在留出空间给电源、冷却、网络 and 存储等其他设备的情况下，每个机架可容纳约20-40台服务器。与设计为模块化风格以提高密度和处理能力的刀片服务器相比，每台机架式服务器通常包含作为独立系统运行所需的所有组件（例如计算、内存、电源、存储等）。每个刀片包含服务器的关键组件，如CPU和内存，并安装在专用机箱内，该机箱提供共享基础设施，如网络、电源和冷却。刀片服务器机箱设计为适合行业标准服务器机架。类似地，多节点服务器在模块化设计和资源共享方面与刀片服务器相似，只是它们不共享网络结构。塔式服务器是独立的立式服务器机柜——外形与传统台式计算机相似——但组件（例如计算、内存）有所升级，通常由中小企业使用。

图表8：服务器有多种外形规格，包括大型机、机架式、刀片式和塔式




图表 9

行业标准服务器基于x86 CPU架构，这是网络基础设施、数据中心和云提供商中最常部署的CPU架构，根据Gartner的数据，到2025年将占部署量的约85%。x86架构（例如Intel Xeon、AMD Epyc）支持广泛的指令集，并与广泛的软件和操作系统兼容。ARM（占比15%且不断增长）架构旨在计算更简单的指令，从而产生更节能、更具成本效益的解决方案。由超大规模云提供商（例如AWS Graviton、Google Axion）和Nvidia的Grace CPU设计的定制芯片使用基于ARM的架构。由于不同的CPU架构具有独特的指令集，为一个架构编译的软件通常无法在另一个架构上运行而无需重新编译，这对企业组织来说可能是一个巨大的负担。其他CPU架构包括RISC、CISC和EPIC。GS半导体分析师James Schneider预计，x86指令集将保持服务器CPU市场的主要份额，尤其是在企业中，而ARM服务器CPU的份额将有所增长，尤其是在那些专注于构建定制硬件以降低功耗的超大规模云提供商中。


我们估计全球传统服务器装机量约为7000万台，平均使用寿命为5.7年。我们通过假设每年每台服务器的平均使用寿命（基于劳伦斯伯克利国家实验室的估计），然后汇总相应前几年的服务器出货量来估计服务器装机量。我们的服务器出货量估计基于IDC、650 Group和Gartner传统服务器（即非加速型）预测的混合平均值。

图表9：我们估计全球传统服务器装机量约为7000万台，平均使用寿命为5.7年。
全球传统服务器装机量（单位：百万台）和平均可用寿命假设（年）




图表 10

图表10：我们估计，截至2025年，全球服务器装机量中有32%已使用5年或以上，较十年前8%的比例显著上升...按使用年限划分的全球服务器装机量（单位：百万台）以及使用年限为5年及以上的服务器占比



图表 11

图表11：……这在很大程度上是由于主要超大规模云提供商服务器使用寿命的延长
主要美国超大规模云提供商的服务器使用寿命（用于会计/折旧目的）




图表 12

我们预计传统服务器出货量将正常化至每年约1000万台（而2018-22年平均为1300万台），原因是（1）向新系统更新换代以提高效率（即密度提升），以及（2）代理型AI推动了对扩展服务器集群的需求。

服务器整合将如何长期影响装机量？HPE报告称，一台Gen12服务器可以替代7台Gen11服务器或14台Gen10服务器，同时功耗降低65%。DELL报告称，其17G服务器以3:1（15G）或7:1（14G）的比例整合旧服务器，而其超过70%的装机量仍在运行14G或更旧的服务器（截至2025年11月）。在一个简化的情景分析中，假设所有旧服务器都被新一代服务器替换，并以3:1或6:1的比例替换14G及更旧的服务器，戴尔的服务器装机量可能缩减高达60%。我们注意到，这并未考虑工作负载的任何增长，这将需要增加在线计算能力（部分抵消这一整合阻力）。也就是说，当前传统服务器的整合可能导致中期内服务器装机量结构性减少，这可能会限制未来更新换代周期的潜在上行空间。如果每年出货的服务器数量显著减少，那么为了维持稳定的利润池，平均售价和利润率需要显著提高。

图表12：DELL报告称，其17G服务器以6:1的比例转换旧的14G服务器 戴尔14G和17G服务器规格的说明性比较

图表13：在我们的说明性情景分析中，假设以3:1或7:1的比例替换14G及更旧的服务器，戴尔的服务器装机量可能缩减高达60% 戴尔传统服务器装机量情景分析



图表 13


图表14：如果每年出货的服务器数量显著减少，那么为了维持稳定的利润池，平均售价和利润率需要显著提高
行业传统服务器装机量情景分析

3/8

传统服务器在AI部署中扮演什么角色？尽管GPU服务器占据了迄今为止大部分新增AI基础设施支出，但传统CPU在AI部署中也发挥着关键作用。首先，在专为AI训练设计的大规模GPU集群中，CPU服务器充当头节点/编排层。当GPU负责模型训练所需的并行处理重活（即工作节点）时，CPU服务器则管理集群、调度任务、路由数据并监控资源分配。没有传统服务器编排工作流程，高性能GPU将无法高效运行，这使得CPU基础设施成为任何训练集群的关键组成部分。其次，智能体AI需要一种混合方法，将GPU的概率推理（统计模式识别和生成token）与CPU的确定性执行（基于规则的逻辑、API工具调用和严格的工作流编排）相结合。由于智能体工作流高度依赖工具，并且需要持续、可预测的编排，CPU更适合处理这些确定性任务，以防止延迟瓶颈。这种架构转变将对硬件配置产生影响；虽然传统AI训练通常的CPU与GPU配比为1:4至1:8，但英特尔指出，智能体推理的需求正将这一配比推近至1:2甚至1:1。智能体AI的采用，尤其是在企业中，仍处于早期阶段，对CPU基础设施投资时机和规模的预期仍存在不确定性。

随着超大规模客户需求增长，传统服务器供应商市场份额已从品牌OEM转向白牌。根据650 Group的数据，过去十年，前五大传统服务器供应商（戴尔、HPE、IBM、SMCI和联想）按出货量计算的市场份额已从2014年的累计53%下降至2025年的42%。我们还注意到类似趋势，收入份额从2014年的63%下降至2025年的57%。这一趋势是由从传统OEM转向非品牌“白牌”设备所驱动，白牌设备在2025年约占传统服务器出货量的23%和传统服务器收入的28%，而2014年这一比例分别为15%和8%。


图表15：过去十年，前五大传统服务器供应商（戴尔、HPE、IBM、SMCI和联想）按出货量计算的市场份额已从2014年的累计53%下降至2025年的42% 按供应商划分的传统服务器行业出货量份额（%）



图表 14

来源：650 Group

图表16：同样，前五大供应商的收入份额已从2014年的63%下降至2025年的57%
按供应商划分的传统服务器行业收入份额（%）



图表 15

来源：650 Group

这一转变的主要驱动力是不同客户垂直领域潜在需求的变化，超大规模客户（高度偏向白牌）的传统服务器收入十年复合年增长率（2014-24年）为18%，而企业传统服务器收入十年复合年增长率为-2%，主要受工作负载向公有云迁移的推动。截至2025年，650 Group估计超大规模传统服务器市场中72%由ODM/白牌供应商提供。相比之下，企业服务器市场中98%由品牌OEM提供，前五大供应商占总收入的71%。

白牌服务器是无品牌解决方案，通常由ODM使用现成的通用组件组装而成。它们通常以更低的价格出售，并为客户提供更多定制机会（客户可以指定硬件需求，即内存、CPU等，以及操作系统）。超大规模客户和其他云提供商的运营规模比传统企业更大，服务器架构数量可达数百万。与传统企业相比，超大规模客户专注于最大化（1）价值，不愿为服务器上非必要的额外功能付费；并最小化（2）成本，因为他们几乎不支付维护和支持费用，任何出现故障的服务器都会被丢弃，同时工作负载会重新分配到其他横向扩展数据中心的其他服务器上。有关服务器制造的更多信息，请参阅我们的IT硬件分销与制造行业入门中的“IT硬件制造行业入门：OEM、ODM、CM”部分。


传统服务器OEM在定价、品牌认知度、分销模式和增值服务方面展开竞争；独立产品通常在技术上缺乏足够的差异化，无法带来市场份额增长。对于传统企业部署而言，可靠性至关重要，系统构建旨在不惜一切代价避免硬件故障。因此，企业更愿意为内置冗余和昂贵的维护合同付费：

首先，企业硬件设计为易于维护，设备中嵌入传感器以收集温度、驱动器性能和功耗等关键指标，从而提供服务器健康状况和潜在故障的可见性。戴尔、HPE、SMCI等服务器OEM还在其服务器设备中提供“带外”管理技术，允许管理员独立于CPU远程监控和控制服务器。虽然SMCI的智能管理平台基于英特尔的开源IPMI（智能平台管理接口），但戴尔（集成戴尔远程访问控制器，即iDRAC）和HPE（集成Lights-Out，即iLO）都投资构建了具有更高级功能和特性的专有嵌入式服务器管理工具。Principled Technologies在2024年4月的一项研究发现，戴尔的服务器管理工具比SMCI的同类平台拥有显著更多的管理和安全功能。

其次，OEM——尤其是戴尔和HPE——为其企业硬件提供延长保修以及增强的支持和维护服务。例如，戴尔的ProSupport和HPE的Tech Care计划在标准硬件保修基础上，增加了软件配置、主动监控和问题检测（由上述iDRAC和iLO等硬件增强和管理工具实现），以及全天候在线和电话技术支持，许多计划还包括现场支持。为了推动维护服务与硬件销售的捆绑，戴尔的销售团队通常会在向企业客户报价时包含一份为期三年的关键任务ProSupport合同。在一个简单例子中，将一份价值1,300美元的ProSupport关键任务合同附加到一台7,000美元的戴尔PowerEdge R470服务器销售中，可以使服务器总销售的毛利率增加约4个百分点（假设硬件毛利率约为15%，服务毛利率约为40%，与戴尔2025财年披露数据一致）。

第三，戴尔（DELL）与慧与（HPE）也向企业客户提供专业服务、托管服务、教育及金融服务。例如，针对额外的咨询类费用，戴尔可为整个数据中心项目的硬件安装提供解决方案级设计与实施服务（一种专业服务），涵盖其他原始设备制造商的硬件。这超出了戴尔常规 ProDeploy 合同的范畴，后者通常仅涵盖所附特定硬件设备的安装，而不考虑数据中心安装的最佳实践或顺序（例如，先服务器后网络等）。我们的渠道调研显示，戴尔的程序级服务（源自 EMC 支持模式）被视为行业最佳，并成为与其他硬件 OEM 厂商的差异化优势。同样，慧与在其计算、存储和网络设备系列中提供全面的咨询与专业服务组合。


图表 17：截至 2025 年，超大规模云服务商占传统服务器出货量的 31%...
按客户垂直领域划分的传统服务器出货量占比



图表 16

来源：650 Group


图表 18：……以及服务器工作负载的 61% 按客户垂直领域划分的服务器工作负载占比



图表 17

来源：650 Group


图表 19：2025 年超大规模云服务商传统服务器平均售价约比企业低 30%
按客户垂直领域划分的传统服务器平均售价（美元）



图表 18

来源：650 Group


图表 20：650 Group 估计，超大规模云服务商传统服务器市场中 72% 由 ODM/白牌供应商提供传统服务器收入市场份额——超大规模云服务商客户垂直领域（%）



图表 19

来源：650 Group

图表 21：相比之下，企业服务器市场 98% 由品牌 OEM 厂商提供传统服务器收入市场份额——企业客户垂直领域（%）



图表 20

来源：650 Group

传统服务器单位经济性

品牌供应商通常在服务器硬件销售上获得约 15-20% 的毛利率和约 6-8% 的营业利润率。下面我们展示一份 x86 服务器的示例物料清单，组件定价截至 2025 年 7 月，以反映未受 2025 年秋季开始的 DRAM/NAND 价格飙升影响的物料清单。在此示例中，组件约占总产品成本的 90%，而服务器品牌加价及 ODM 制造费用约占 10%。根据当前对 2026/27

年的定价预期（详见下文“更高的大宗商品成本如何影响服务器市场？”），某些传统服务器配置中的 DRAM/NAND 内容可占服务器 BOM 的 60%

以上。如上所述，我们估计，将支持服务和维护合同附加到服务器销售上，可为品牌供应商增加 4 个百分点的毛利率。

图表 22：传统服务器物料清单 CPU 通用服务器示例物料清单

组件定价截至 2025 年 7 月，以反映未受 DRAM/NAND 价格飙升影响的物料清单

加速服务器


GPU 非常适合 3D

图形渲染，因为它们可以同时处理复杂视觉效果所需的重复计算，例如变换形状、应用光照、着色像素。

根据 650 Group 的估计，2025 年加速服务器市场的年收入约为 1950 亿美元（同比增长 69%），出货量约 190 万台（同比增长 27%），平均售价约为 10 万美元（同比增长 33%）。加速服务器（包括用于 AI 工作负载的 AI 服务器）配备专用硬件加速器，例如 GPU 或定制 ASIC¹，这些加速器与 CPU 协同工作，以加速数据密集型、复杂的工作负载（统称为“XPU”）。虽然 CPU 设计用于在其核心上按顺序、串行处理指令（英特尔 Granite Rapids 服务器 CPU 拥有 128 个核心），但 GPU 设计用于在其数千个核心上同时（即并行）处理多个计算（英伟达 B200 GPU 拥有 20,480 个 CUDA 核心和 640 个张量核心）。因此，并行处理在处理可分解为更小、独立部分的任务（如大数据集分析、科学模拟或图形渲染）时效率更高。加速器对服务器架构而言并非新鲜事物；英伟达在 25 年前就推出了用于 PC 上 3D 视频游戏图形渲染的 GeForce 256 GPU。在过去二十年中，GPU 和其他定制 ASIC 越来越多地部署于日益广泛的工作负载，这些工作负载同样受益于并行处理，被称为 GPGPU 或通用


GPU。就本报告而言，我们将加速服务器市场定义为包含所有配备加速卡的服务单元。这包括用于 AI 的服务器，以及其他机器学习和高性能计算用例。

图表 23：2025 年加速服务器市场的年收入约为 1950 亿美元（同比增长 69%） ...
行业传统服务器收入（百万美元）及年增长率（%）



图表 21

图表 24：……出货量约 190 万台（同比增长 27%），平均售价约为 10 万美元（同比增长 33%）
传统服务器出货量（百万台）及平均售价（美元）




图表 22

来源：650 Group Transformer 模型，包括像 Chat-GPT 这样的大语言模型，是一种神经网络。来源：650 Group


AI训练需要在加速计算领域进行大规模投资。训练AI模型涉及处理海量数据，并执行数十亿次数学运算，以学习模式并做出预测。举个简单的例子，神经网络是一种基础计算模型，旨在通过寻找不同互联节点（即神经元）之间的连接来识别模式并从数据中学习。在神经网络内部，输入数据（例如由矩阵表示的图像、文本或数值）会与权重矩阵相乘。这些权重决定了神经网络试图检测的特定模式或特征。这种矩阵乘法的结果（通常随后会经过一个激活函数）决定了下一层神经元的激活状态。随着数据逐层传递，网络能够提取出越来越抽象和复杂的特征。AI模型通过更新网络权重来“学习”，以最小化预测结果与实际结果之间的差异。对本报告至关重要的一点是，矩阵乘法是一种高度可并行的运算（许多更小、独立的计算同时发生），这非常适合GPU。研究人员发现，在大语言模型中，超过90%的计算任务都使用了矩阵乘法。因此，自2022年11月ChatGPT公开发布以来，加速服务器的需求在2023年出现了显著增长，并且随着OpenAI（ChatGPT）、谷歌（Gemini）、Anthropic（Claude）和Meta（Llama）等模型构建者投资的增加，这一需求持续增长。AI模型的庞大规模（据报道，Llama 4 Behemoth拥有2.0万亿个参数）使得加速服务器不仅是一种优势，更是在可行时间内训练模型的必要条件。使用CPU计算需要数年才能训练完成的模型，使用GPU则可以在数周到数月内完成。

知名人工智能系统中的参数 图表25：神经网络是一种基础计算模型，旨在通过寻找不同互联节点（即神经元）之间的连接来识别模式并从数据中学习 说明性神经网络架构



图表 23

图表26：AI模型的庞大规模（据报道，Llama 4拥有2.0万亿个参数）使得加速服务器不仅是一种优势，更是在可行时间内训练模型的必要条件



图表 24

参数是AI系统中的变量，其值在训练过程中进行调整，以确定输入数据如何转换为期望的输出；例如，神经网络中的连接权重

训练AI模型涉及模型参数的迭代调整（例如，反向传播），而AI推理主要涉及通过神经网络的“前向传播”


除了模型训练，加速计算在推理和RAG中也扮演着角色。首先，AI推理是使用训练好的AI模型对新数据进行预测的过程。虽然所需的原始计算能力低于训练AI模型，但AI推理仍然受益于加速服务器的并行架构来执行矩阵乘法。在推理过程中，预训练模型接收新的输入数据，然后数据通过其神经网络的每一层。在每一层，模型的预确定权重会与新数据相乘（即矩阵乘法），并逐层通过网络（“前向传播”），结合偏置相加和激活函数，最终产生输出或预测。其次，RAG（检索增强生成）是一种使用外部知识库（如数据库或网络资源）来更新或改进静态AI模型的技术。RAG技术通过在生成步骤之前增加一个检索步骤（将查询转换为数值表示或“嵌入”，然后在向量数据库中搜索相似的嵌入）来提高大语言模型的准确性。生成这些向量嵌入、索引和搜索向量数据库以及重新排序检索结果，使用并行GPU计算比使用CPU更高效。与AI训练类似，AI推理和RAG在加速计算硬件上表现更好，但并非必须使用XPU。Nscale发现，Mistral 7B

Instruct模型在GPU上每秒可生成63个token，而在CPU上运行时每秒仅能生成约18个token。

目前，大多数XPU由英伟达销售，预计未来定制加速器的采用将增加。GS半导体分析师Jim Schneider预计，在可预见的未来，商用AI加速器（例如英伟达GPU）将保持AI基础设施市场的主要份额，原因在于：（1）AI模型开发优先考虑灵活性和模型训练的优化；（2）AI开发者专注于高性能解决方案；（3）商用芯片拥有更成熟的开发者/软件生态系统。尽管如此，Jim认为，短期内定制ASIC的采用将增加，以处理内部工作负载（例如，谷歌用于搜索，亚马逊用于电子商务），长期来看，将处理更多外部工作负载，尤其是推理。

图表27：GS半导体分析师Jim Schneider预计，英伟达将保持AI加速器市场的主要收入份额

AI芯片设计商加速计算收入（占总收入百分比）



图表 25

CPU、内存和网卡在加速服务器中也至关重要。虽然CPU不负责大规模的并行处理（由GPU处理），但CPU仍用于AI任务，例如管理数据处理、初始模型设置以及编排GPU库。内存（包括RAM和存储）在处理海量数据时也至关重要。为避免数据处理中的瓶颈，加速服务器必须配备充足的内存带宽、密度和效率。网络接口卡（NIC）是专用的附加卡，经过编程可运行网络软件进程，从而释放服务器处理能力用于其主要应用任务。虽然GPU占加速服务器物料清单的大部分，但其他组件的成本在绝对金额上仍高于传统服务器，这支撑了更高的平均售价。

加速服务器单位经济效益

品牌供应商（例如戴尔、慧与）在AI服务器硬件销售上通常能获得约8-10%的毛利率和约中个位数的营业利润率。下面我们展示一个AI服务器（H100 DGX服务器）的说明性物料清单，组件定价截至2025年7月，以反映未受2025年秋季开始的DRAM/NAND价格飙升影响的物料清单。在此说明性示例中，组件约占产品总成本的95%，而服务器品牌加价及ODM制造费用约占5%。


图表28：AI服务器物料清单 CPU通用服务器的说明性物料清单

组件定价截至2025年7月，以反映未受DRAM/NAND价格飙升影响的物料清单；GPU成本包含HBM定价。

6/8

当前AI服务器基础设施的主要买家包括：(1) 超大规模云厂商，他们投资AI用于自身内部工作负载（如搜索、电子商务）并为其公有云运营建设容量；(2) 二级新型云厂商，他们建设AI算力容量用于GPU租赁（如Coreweave）或主权AI项目；以及较小程度上 (3) 企业客户，他们正在自身商业模式中试验AI以提升成本效率并增加收入机会。AI采用率在所有行业中均有所上升，GS显示，截至2026年4月，19.8%的公司已采用AI，其中信息技术、专业服务、教育和金融行业公司尤为突出。截至2026年4月，中型企业（100-249名员工）和大型企业（250名以上员工）的采用率最高。


图表29：截至2026年4月，所有行业中19.8%的公司已采用AI 按行业划分的美国公司AI采用率（%）



图表 26


图表30：当前采用率在中型和大型企业中最最高 按员工人数划分的美国公司AI采用率

按员工人数划分的美国公司AI采用率



图表 27

*6次调查移动平均线。*自问题措辞变更后显示即期数据。



图表 28

购买模式（以及相应的供应商市场份额）因客户类型而异。与传统服务器类似，超大规模云厂商通常从ODM采购AI服务器，而二级云和企业客户则从品牌OEM采购：

■ 超大规模云厂商大量采购加速服务器，2025年占AI服务器总出货量的82%，涉及5家公司（亚马逊、Alphabet、Meta、微软、苹果）。超大规模云厂商通常采购定制AI硬件，直接从商业芯片供应商处购买芯片，然后与ODM合作设计针对其特定需求（如密度、散热或功耗）优化的定制机箱。因此，白牌供应商占超大规模云厂商AI服务器收入的约92%以上，其次是英伟达（约3%）和超微电脑（约3%）。

二级云和新型云厂商主要从一流的服务器OEM采购AI服务器，领先的是超微电脑（截至2025年市场份额约39%）和戴尔（约38%），其次是白牌（约10%）和英伟达（约6%）。像DELL和SMCI这样的服务器OEM提供基于英伟达参考设计（称为"HGX"服务器）的AI服务器，以及一套强大的咨询和实施服务。HGX服务器是围绕基础HGX基板（GPU加部分网络）按照英伟达参考架构构建的，但OEM可以通过定制散热（风冷与液冷）、CPU和RAM密度及配置、网络等来创造独特产品。我们预计二级云客户将继续依赖OEM的工程专业知识，但到2027年，一些更成熟的新型云厂商将开始使用ODM进行定制或半定制服务器设计。650

Group预计，二级云将从2025年占AI总出货量的约13%增长到本十年末的36%。

\- 企业AI服务器需求仍处于初期阶段，2025年企业仅占AI服务器出货量的约5%。需求由传统IT硬件供应商戴尔和慧与（2025年各占约28%份额）满足，其次是英伟达（约15%），后者通过其DGX服务器平台及完整的网络和软件组合进入企业垂直市场。OEM还通过其全面的服务组合（包括咨询、实施、管理和融资）为企业客户增加价值。因此，我们通常认为企业客户对OEM的利润率贡献最大。

图表31：截至2025年，超大规模云厂商占行业AI服务器收入的大部分... AI服务器收入（十亿美元） 来源：650 Group

图表32：...AI服务器出货量份额最高... AI服务器出货量（百万台） 来源：650 Group

图表33：...但AI服务器平均售价最低 AI服务器平均售价（美元） 来源：650 Group

图表34：超大规模云厂商AI服务器市场由白牌主导...

超大规模云厂商AI服务器市场份额（占垂直市场总收入百分比） 来源：650 Group

二级云及服务提供商AI服务器市场份额（占垂直市场总收入百分比）

图表35：...而二级市场由一流服务器供应商DELL和SMCI领先

来源：650 Group

图表36：企业AI服务器市场在慧与、戴尔和英伟达之间更为均衡 企业AI服务器市场份额（占总量的百分比）

来源：650 Group

图表37：各服务器制造商关键属性总结 戴尔、慧与、超微电脑和白牌的关键属性对比

附加服务和软件支持可以提高AI服务器销售的盈利能力。为了最大化IT硬件的性能和功能，IT硬件供应商通常向客户提供额外服务，例如专业服务（安装、配置、迁移）、生命周期服务（托管服务、持续支持、故障修复），以及一些云或即服务产品（DELL APEX、HPE Greenlake、NetApp Keystone）。企业客户通常比二级云或超大规模云客户需要更多支持来实施IT项目。这些客户通常结合使用OEM提供的点解决方案服务和跨供应商的专业IT系统集成商（如埃森哲、IBM、塔塔）。构建定制AI集群的更成熟客户也可能与像Penguin（PENG）这样的公司合作，该公司在数据中心系统集成方面拥有30多年的经验。这种专业知识使PENG成为Meta研究集群等重大AI项目的首选合作伙伴，这些项目专注于最大化首次生成令牌的时间和底层GPU的性能。Penguin的解决方案部署更快，部分原因是该公司在发货给客户之前，会在其工厂内预先构建、预先布线、预先配置和测试集群（而同行则是直接发货设备并在现场组装）。

更高的商品成本如何影响服务器市场？

内存市场现状如何？（截至2026年6月）

DRAM（一种用于硬件设备易失性存储的半导体存储器，即"内存"）和NAND（非易失性、持久性半导体"存储"）的价格自2025年秋季以来大幅上涨（超出典型内存周期波峰/波谷），主要驱动力来自AI基础设施需求。为了充分供应AI基础设施建设所需的高利润高带宽内存（HBM），芯片制造商（如三星、美光、SK海力士）已将产能从标准DRAM和NAND生产转移，导致供应短缺和价格持续上涨。与常规DRAM相比，每GB HBM晶圆消耗的硅面积约为前者的3倍，这意味着优先生产HBM对常规DRAM产量产生巨大影响。GS半导体分析师预测，2026年常规DRAM价格将增长约316%（截至2026年5月31日）。我们注意到，推动DRAM成本上升的许多因素同样影响NAND闪存定价，GS半导体分析师估计2026年NAND价格将上涨256%。截至2026年5月，GS半导体分析师预计供需错配将持续到2028年。

为何重要？

DRAM和NAND通常占传统服务器物料清单的约30%（图表40）。根据当前行业对DRAM定价的预期，假设无抵消措施，到2026年底内存可能占传统服务器物料清单的60%以上。举例说明，若传统服务器供应商希望在承受约315%的DRAM价格上涨的同时维持约15%的毛利率，则需提价超过90%。这假设CPU等其他物料清单组件无价格压力，而英特尔和AMD的CPU价格也在上涨。

对于AI服务器，由于GPU价格高昂，内存占物料清单的比例较小（DRAM和NAND约2%，HBM约6%）。因此，为抵消投入成本上涨所需的相对提价幅度较小。

图表38：DDR5 16Gb现货价格较最新合约价溢价10% DDR5 16Gb现货价格相对合约价的溢价/折价

来源：Trendforce

硬件OEM厂商拥有成熟的管理常规商品成本波动的策略，包括降规、认证新供应商、建立战略库存以及转嫁高价。然而，这些策略是基于更"典型"的内存周期（即约3年的产能不足/供应短缺导致产能过剩/供应过剩）建立的，因此可能不足以应对当前的结构性内存逆风。

签订长期协议（LTA）。戴尔和慧与等服务器供应商正积极寻求签订长期协议（也称为新商业模式或战略客户协议）以锁定中长期供应量。许多OEM厂商已完成长期协议签署，与过去不同，这些协议包含更高约束力的承诺。根据我们全球半导体团队的调研，正在讨论的长期协议包括大额预付款和重大违约罚则，可确保更强的约束力。定价在预设范围内讨论，设有保证可持续高利润率水平的价格下限。

认证新供应商：为认证新供应商，厂商需进行多阶段验证流程，正式确认特定供应商的内存模块在其全系列计算机型号中足够可靠、兼容且性能达标。这通常是涉及工程、质量保证和供应链团队的跨职能深度协作，耗时3-6个月。

值得注意的是，在内存领域，常规DRAM市场由三大厂商（三星、美光、SK海力士）主导，合计占据超过90%的市场份额。由于企业服务器OEM厂商已与主要DRAM供应商合作，潜在的新供应商仅为台湾的南亚科技和华邦电子或中国大陆的长鑫存储等较小厂商，它们合计占全球市场不到10%（因此认证它们为供应商可能无法完全解决供应短缺问题）。与DRAM市场类似，NAND市场也高度集中于三星、SK海力士、铠侠、西部数据和美光（超过90%）。中国的长江存储等较小厂商仅占全球供应的一小部分。

■ 建立战略库存：服务器供应商可利用资产负债表建立关键组件的战略储备（某些情况下可达6个月供应量），有助于抵消商品成本波动的短期影响。建立战略库存（相对于“准时制”制造模式，即组件在需要时恰好到货以最小化持有成本）可帮助厂商对冲价格并确保供应。然而，将资产负债表绑定于库存会限制厂商赚取利息收入或进行其他投资的能力，并承担库存过时的风险。慧与和联想历史上曾利用资产负债表战略性地建立库存，而戴尔则更倾向于准时制制造模式。服务器供应商通常与组件供应商签订包含批量采购安排的长期协议，但定价并非总能得到保证。

■ 提价：厂商可通过直接提价（提高标价）、间接提价（减少折扣）或产品组合调整（需求塑造）来转嫁更高成本。首先，在商业和企业市场（相比消费者市场对小幅提价较不敏感）中，直接提高标价更为常见。其次，厂商可通过调整销售、促销和返点来改变折扣策略，从而提高实际价格。第三，拥有更直接销售团队的OEM厂商可通过主动引导客户选择利润更高、供应更充足的产品来塑造需求。

当前内存供应短缺如何影响服务器市场？

我们考察了持续的DRAM内存供应短缺可能影响服务器市场供应、需求和盈利能力的两种方式。

- 供应商短缺：常规内存需求远超供应，可能对出货量构成逆风。截至2026年5月，GS半导体分析师预计2026/2027/2028年DRAM供需将出现5.0%/5.9%/3.9%的大幅供应不足，成为过去15多年来供应短缺最严重的年份。因此，我们预计服务器供应商在短期内无法完全满足其需求/积压订单。此外，GS半导体分析师预计长期协议的广泛采用将提高内存供应商的需求可见性，使其制定更高效的资本支出计划，并降低此前周期中出现的供应过剩风险。
- 需求弹性：为保护本已微薄的利润空间，供应商很可能将上涨的成本转嫁给客户，这亦可能影响需求。例如，有报道称戴尔等服务器供应商在2026年（截至5月）年内已提价超过50%。尽管目前（截至2026年5月）判断需求所受最终影响为时尚早，但我们预计，鉴于IT预算通常具有固定性，企业级服务器客户在需求开始恶化前所能承受的价格涨幅存在上限。相反，我们观察到超大规模云服务商与AI新云厂商在整个2026年持续上调资本支出预算，以应对AI基础设施中通胀性的商品成本。换言之，我们预计服务器价格上涨不会影响此类客户群体对服务器的需求弹性。