

KC桌面——外资精译

AI 系列第51期：成本性能与Token消耗及智能水平的趋势

AI 系列第51期：成本性能与Token消耗及智能水平的趋势

要点 (1) 硅数LLM

Token支出指数：6月14日至19日期间，该指数持续疲软，维持在1.64至1.68之间，而5月31日为2.04；(2)

OpenRouter：Token消耗较前一周增长4.7%；(3)

重申在全球行业趋势下，高成本效益模型是关键，且落后美国模型约7个月；(4)

火山引擎将于周二/周三举办FORCE大会，涵盖多个重点领域；(5) 微信AI正在测试中

在本报告中，我们为投资者提供超过50个数据点，涵盖OpenRouter的Token消耗、不同模型的定价、Artificial Analysis的模型智能水平、按子领域划分的用户趋势以及其他行业数据以供分析。

火山引擎：预计在6月23日（周二）和24日（周三）即将举行的FORCE大会上将有多项更新。火山引擎本周将举办此次大会，并设有多个不同领域的专场。我们关注：(1)

豆包大模型的日Token消耗量。2026年3月，其披露日Token消耗量已达120万亿；(2)

豆包的商业化计划更新及各类订阅套餐定价；(3) 视频生成模型Seedance 2.0的更新，特别是ARR趋势；(4)

其编码和智能体策略的更新（例如TRAE、Arkclaw、coze）；(5) MaaS收入目标。

腾讯：启动微信AI测试。腾讯正在社交与通讯、信息与搜索、生产力、娱乐/购物以及工具生成等多个场景下，对微信AI进行小规模测试。微信AI名为“小微”：1) 位于主页面左上角；2) 是消息功能中的一项特性。其核心模型是由微信团队开发的WeLM。我们认为这是腾讯在A2A领域迈出的重要一步，并预计其将于2026年第四季度正式发布。详情请参阅报告。

阿里巴巴：全栈能力与投资拥抱巨大的AI可及市场。蔡崇信主席在巴黎VivaTech 2026大会上的关键点。(1)

AI的TAM为50万亿美元，考虑到AI生产人类智能和生产力单位，这相当于全球GDP的一半；(2)

中国在AI供应方面投资不足。阿里巴巴凭借其自由现金流，是定位较好的公司之一；(3)

阿里巴巴的战略核心在于其在芯片和基础设施、通义千问模型及应用方面的集成式全栈能力；(4)


继德国和英国之后，在法国设立其第三个欧洲中心。智能体服务计划于2026年下半年在欧洲推出。

硅数LLM Token支出指数：6月数据相较5月底继续显示疲软。该指数（图表2）根据使用集中度进行加权（例如，当需求转向高端模型时，支出会增加）。另一方面，媒体报道（例如The Information、经济观察报）指出，科技和互联网公司为员工的Token消耗设置了上限。根据我们的核查，该指数在6月14日至19日期间介于1.64至1.68之间，而5月31日为2.04。根据Artificial Analysis，中国模型（DeepSeek、通义千问、Kimi、MiniMax和智谱）相比美国模型具有极高的成本效益，且API成本仅为美国模型的一小部分（图表3），这得益于前者精炼的架构，如MoE（混合专家模型）、注意力机制（分组查询注意力GQA、稀疏注意力）和MLU（模型算力利用率）。

OpenRouter：Token消耗较前一周增长4.7%。根据对6月15日当周（对比6月8日当周）的分析（图表1），每周消耗的Token数量增长了4.7%，达到46.7万亿。在排名方面，DeepSeek V4

Flash位列第一，其次是小米MiMo-V2.5和MiniMax M3。

图表1 - 截至6月22日的过去12个月每周Token消耗量（万亿）



图表 1

来源：OpenRouter, JEF


图表2 - 硅数LLM Token支出指数



图表 2

来源：FactSet, JEF

图表3 - 中国模型与美国模型的混合价格对比（2026年第一季度）



图表 3

来源：Artificial Analysis, JEF

图表4 - 最近一周按模型划分的Token消耗量前十排名

来源：OpenRouter, JEF

接下页……


百度、阿里巴巴、腾讯、金山云、AI实验室及可灵是受益方。我们预计，随着对AI模型和智能体需求的增长，Token消耗将激增，这将使百度、阿里巴巴、腾讯、金山云、AI实验室和可灵等云服务提供商受益。根据Artificial Analysis的分析：(1) 中美模型之间的智能差距正在缩小；(2) 得益于MoE、线性注意力和MFU，API成本仅为美国的一小部分；(3) 编码、工作空间场景以及中长篇幅内容未来将迎来重大机遇（图表73-77）。

中美对比

AI模型

根据OpenRouter的数据，Token消耗在2026年2月显著增长，原因是：(a) 编码/智能体的采用激增，这使得人们使用AI从“聊天”转向“工作”。它连接了可以本地部署或服务器部署的大模型，允许你通过自然语言聊天实现工作流自动化；(b) 一系列高性能、高成本效益的模型发布，包括Kimi K2.5（2026年1月）、M2.5（2026年2月）和GLM-5（2026年2月）。

图表5 - 截至6月22日的过去12个月每周Token消耗量（万亿）




图表 4

来源：OpenRouter, JEF

根据OpenRouter（6月15日至21日），中国模型的Token消耗量较前一周增长2.12%，达到18.8万亿。相比之下，美国模型的Token消耗量为5.8万亿。DeepSeek V4 Flash每周Token消耗量快速增长

根据OpenRouter，编码/智能体采用率的上升以及高性能、高成本效益的中国模型的发布，正在推动Token消耗在OpenRouter中，中国模型在6月15日当周的Token消耗量超过了美国模型


图表6 - 市场份额：截至6月22日按公司划分的每周Token消耗量



图表 5

来源：OpenRouter, JEF

图表7 - 自2026年1月以来的每周Token消耗量（十亿）



图表 6

来源：OpenRouter, JEF

图表8 - 最近一周按模型划分的Token消耗量前十排名

来源：OpenRouter, JEF DeepSeek V4 Flash在6月15日当周的Token消耗量排名第一


根据Artificial Analysis, 中国模型（DeepSeek、通义千问、Kimi、MiniMax和智谱）在智能水平上正在缩小与美国模型的差距。中国模型在混合专家模型架构、线性注意力和MLU方面具有极高的成本效益。根据2026年斯坦福AI指数报告（2026年4月），美国顶尖模型领先中国模型2.7%。另外，截至2026年3月，Anthropic（1503）、xAI（1495）、Google（1494）、OpenAI（1481）、阿里巴巴（1449）和DeepSeek（1424）占据了Arena Elo评级的第一梯队。

图表9 - 最近一周按模型划分的Token消耗量第11至20名排名

来源：OpenRouter, JEF


中国模型在智能水平上正在缩小与美国模型的差距。在输入/输出API方面，中国大模型相比美国模型效率极高。

图表10 - 截至6月22日领先模型的缓存命中/输入/输出API价格



图表 7


图表11 - 中国模型季度输入/输出价格



图表 8

来源：Artificial Analysis, JEF 在输入/输出API价格方面，中国模型仅为美国模型的一小部分。

图表12 - 美国模型季度输入/输出价格




图表 9

来源：Artificial Analysis, JEF


■ 专有 ■ 开放权重 ■ 开放权重（商业使用受限）

图表13 - 截至6月22日的前20大模型智能指数



图表 10

图表14 - 截至6月22日的前沿语言模型智能随时间变化




图表 11

■ 专有 □ 开放权重 ■ 开放权重（商业使用受限） 来源：Artificial Analysis, JEF 来源：Artificial Analysis, JEF

在前20大模型中，截至6月22日有9个是中国模型且为开放权重。


图表15 - 截至6月22日的前20大模型代理指数



图表 12

■ 专有 □ 开放权重 ■ 开放权重（商业使用受限）


图表16 - 截至6月22日的前20大模型编程指数



图表 13

来源：Artificial Analysis, JEF 来源：Artificial Analysis, JEF


图表17 - 截至6月22日运行人工智能指数的成本 最具吸引力象限



图表 14

来源：Artificial Analysis, JEF

图表18 - 截至6月22日运行人工智能指数的输出速度 最具吸引力象限



图表 15

来源：Artificial Analysis, JEF

不同模型的输入/输出价格 / 编程计划和代理产品定价

红色表示当月价格上涨/新价格

图表19 - 阿里巴巴、腾讯、百度和字节跳动的定价计划

来源：公司, JEF

图表20 - AI实验室MiniMax、智谱、Kimi的定价计划

来源：公司, JEF

图表21 - AI实验室StepFun、小米和DeepSeek的定价计划

来源：公司, JEF

图表22 - 海外玩家Anthropic、OpenAI和谷歌的定价计划

来源：公司, JEF

视频生成模型产品

不同视频生成模型的定价计划

红色表示当月价格上涨/新价格

图表23 - 视频生成模型定价（人民币）

来源：公司, JEF

图表24 - 视频生成模型定价（美元）

来源：公司, JEF

图表25 - 视频生成会员比较（原价）

来源：公司, JEF

图表26 - 视频生成会员比较（促销后）

来源：公司, JEF

编程计划和代理产品

红色表示当月价格上涨

领先玩家不同编程和代理产品的定价计划

图表27 - 火山引擎方舟代理计划

来源：公司, JEF

图表28 - 腾讯AI产品定价

来源：公司, JEF

图表29 - Hy token计划

来源：公司, JEF

图表30 - 腾讯token计划

来源：公司, JEF

图表31 - 阿里巴巴编程计划

来源：公司, JEF

图表32 - 阿里巴巴token计划

来源：公司, JEF

图表33 - 百度编程计划

来源：公司, JEF

图表34 - MaxClaw订阅价格

来源：公司, JEF

图表35 - MaxClaw附加价格

来源：公司, JEF

图表36 - MiniMax token计划

来源：公司, JEF

图表37 - 小米MiMo token计划

来源：公司, JEF

图表38 - GLM编程计划

来源：公司, JEF

图表39 - Kimi会员计划

来源：公司, JEF

图表40 - Kimi会员计划（续）


来源：公司, JEF

OpenClaw

根据OpenRouter， OpenClaw基于token消耗的前三大模型来自中国，即MiniMax M3、DeepSeek V4 Flash和MiniMax M2.7。其他模型包括DeepSeek V4 Pro和MiniMax M2.5。

根据OpenRouter， MiniMax M3、DeepSeek V4 Flash和Owl Alpha在OpenClaw上的token消耗排名前三。


图表41 - OpenClaw的token消耗（十亿）



图表 16

来源：OpenRouter, JEF

图表42 - Hermes Agent的token消耗（十亿）



图表 17

来源：OpenRouter, JEF


图表43 - 过去30天OpenClaw使用的前15大模型（截至6月22日）

来源：OpenRouter, JEF

图表44 - 过去30天Hermes Agent使用的前15大模型（截至6月22日）

来源：OpenRouter, JEF


图表45 - 全球：截至6月22日成功率前10大模型



图表 18

来源：PinchBench, JEF

图表46 - 中国：截至6月22日成功率前10大模型



图表 19


来源：PinchBench, JEF

AI助手

\- 环比趋势：5月通义千问日活跃用户数达2790万（4月：2920万），元宝达880万（4月：900万）。豆包环比增长5%至1.58亿（4月：1.51亿）。DeepSeek日活跃用户数环比增长约6%至约3050万。

5月多家领先玩家的日活跃用户数环比增长


图表47 - 中国领先AI助手周度日活跃用户数（百万）



图表 20

来源：QuestMobile, JEF


图表48 - 中国领先AI助手月度日活跃用户数（百万）



图表 21


来源：QuestMobile, JEF

图表49 - 中国领先AI助手每周每DAU用户使用时长（分钟）



图表 22

图表50 - 中国领先AI助手每月每DAU用户日均使用时长（分钟）



图表 23

视频生成模型

根据Artificial Analysis（截至6月22日），HappyHorse-1.0在文生视频和图生视频方面排名前五。其他包括Seedance 2.0、Wan 2.7、SkyReels V4、Kling 3.0 Omni 1080p、Kling 3.0 1080p (Pro)、Veo 3.1和grok-imagine-video。

图表51 - 前15名图生视频排行榜（含音频）

来源：Artificial Analysis, JEF

图表52 - 前15名文生视频排行榜（含音频）

来源：Artificial Analysis, JEF

全球及中国AI移动应用月活跃用户数排名

图表53 - 全球AI移动应用月活跃用户数排名（5月26日）

来源：AICPB, JEF

根据aicpb.com，由于2月春节，中国AI应用（包括豆包、通义千问、夸克和元宝）的月活跃用户数相比ChatGPT经历了强劲的环比增长。

图表54 - 中国AI移动应用月活跃用户数排名（5月26日）

来源：AICPB, JEF

在国内市场，Kling的月活跃用户数在5月经历了快速的环比增长。


5月26日：来自QuestMobile分析的月度应用追踪

在线购物

\- 环比趋势：5月淘宝/唯品会日活跃用户数分别增长5%/1%，拼多多下降0.5%。京东日活跃用户数5月环比增长13%。

\- 同比趋势：京东日活跃用户数同比下降3%，淘宝/拼多多同比分别增长1%/8%。

Exhibit 55 - MAU for Taobao / PDD / JD in May-26




图表 24

来源：QuestMobile, JEF
拼多多5月日活跃用户数同比保持快速增长。

外卖

Exhibit 56 - DAU for Taobao / PDD / JD in May-26



Source: QuestMobile, Jefferies

图表 25

美团5月月活跃用户数环比基本稳定。

- 环比趋势：美团月活跃用户数当月环比增长1%。
- 同比趋势：美团月活跃用户数5月同比增长3%（4月同比增长4%）。

图表57 - 过去12个月美团应用月活跃用户数



来源：QuestMobile, JEF


在线音乐

\- 环比趋势：5月汽水音乐月活跃用户数环比增长4%至1.668亿。对于腾讯音乐，QQ音乐/酷狗月活跃用户数环比分别增长2%/1%，酷我环比下降2%。网易云音乐月活跃用户数当月环比增长1%。

汽水音乐5月月活跃用户数同比保持快速增长，环比基本稳定。

\- 同比趋势：5月，Soda Music月活跃用户数同比增长75%，而网易云音乐月活跃用户数同比增长1%。就腾讯音乐而言，QQ音乐月活跃用户数同比增长1%，而酷狗/酷我则分别同比下降9%/17%。

图表58 - 腾讯音乐、Soda Music和网易云音乐5月月活跃用户数 250



图表 27

数据来源：QuestMobile, JEF

图表59 - Soda Music过去12个月月活跃用户数



图表 28

数据来源：QuestMobile, JEF 在线视频 5月头部长视频平台月活跃用户数同比下降

\- 环比趋势：腾讯视频/爱奇艺/芒果TV月活跃用户数环比增长1%/3%/3%，优酷环比下降3%。

• 同比趋势：当月头部长视频平台月活跃用户数同比下降。

图表60 - 爱奇艺、腾讯视频和优酷5月月活跃用户数 数据来源：QuestMobile, JEF

直播与短视频

5月抖音日活跃用户数保持稳健同比增长

\- 环比趋势：5月抖音主应用日活跃用户数环比增长2%。游戏直播方面，虎牙月活跃用户数环比下降1%，斗鱼环比增长3%。哔哩哔哩月活跃用户数当月环比增长2%。

\- 同比趋势：抖音主应用日活跃用户数保持21%的稳健同比增长。游戏直播方面，虎牙和斗鱼月活跃用户数分别同比下降7%和11%。哔哩哔哩月活跃用户数当月同比增长约4%。

图表61 - 抖音过去12个月日活跃用户数 数据来源：QuestMobile, JEF 在线旅游

图表62 - 哔哩哔哩过去12个月月活跃用户数 数据来源：QuestMobile, JEF

2月春节过后，携程国内月活跃用户数5月环比下降

- 环比趋势：5月携程/去哪儿月活跃用户数分别环比下降7%/8%。
- 同比趋势：5月携程/去哪儿月活跃用户数同比下降9%/13%。

图表63 - 携程过去12个月月活跃用户数 数据来源：QuestMobile, JEF

新闻应用

- 环比：5月微博月活跃用户数增长4%，今日头条月活跃用户数增长1%。

5月微博月活跃用户数实现同比正增长

- 同比：5月微博月活跃用户数同比增长1%，而今日头条同比下降2%。

图表64 - 微博过去12个月月活跃用户数 数据来源：QuestMobile, JEF

百度应用

- 环比：5月月活跃用户数保持稳定，日活跃用户数下降2%。
- 同比：5月月活跃用户数同比下降8%，日活跃用户数同比下降21%。

5月百度应用月活跃用户数环比稳定，同比下降

图表65 - 百度过去12个月月活跃用户数 数据来源：QuestMobile, JEF

IDC关于公有云Token消耗的估算与展望

图表66 - 2025年中国MaaS市场月均日Token消耗量

数据来源：IDC, JEF

图表67 - 2025年中国MaaS市场按Token消耗量计算的市场份额 数据来源：IDC, JEF

图表68 - 2025年中国MaaS市场主要厂商市场份额（按收入计）

数据来源：IDC, JEF 图表69 - 2025年中国私有大模型平台市场主要厂商市场份额（按收入计）

图表70 - 推动人们决定广泛部署模型的最重要因素

数据来源：IDC, JEF 数据来源：IDC, JEF

数据来源：IDC, JEF

附录

Omdia关于亚洲及大洋洲智能体AI开发平台的热力图

据Omdia，智能体AI软件市场预计将以105%的复合年增长率增长，从2025年的2.71亿美元增至2030年的97亿美元。阿里云在5个领域获得最高排名：（1）上下文工程，（2）模型支持，（3）多智能体框架，（4）运维与生命周期管理，以及（5）开源与社区。

据Omdia，阿里云被列为构建和部署AI智能体的领导者与首选之一。其在7项指标中的5项获得最高排名。

图表72 - Omdia关于亚洲及大洋洲智能体AI开发平台的热力图

市场规模：编码、工作空间与内容创作

据Grand View Research，全球AI代码工具市场预计将从2025年到2030年增长3倍，达到260亿美元。另一方面，F&S预测中国AI代码生成市场将在2028年达到约47亿美元。KA定制解决方案预计将成为关键收入贡献者。

全球AI代码工具市场预计2030年规模将是2025年的3倍

图表73 - 全球AI代码工具市场规模（十亿美元） 数据来源：Grand View Research, JEF

图表74 - 中国AI代码生成市场规模按服务类型划分（十亿元人民币） 数据来源：Frost & Sullivan, JEF

图表75 - 中国不同行业AI代码渗透率

就AI代码渗透率而言，互联网、游戏、人工智能、金融和能源是前五大关键行业 数据来源：Frost & Sullivan, JEF 据Gonyn Industry Research（2024），AI+工作空间软件市场规模预计在2028年达到1910亿元人民币，是2024年规模的6倍。

图表76 - 中国AI+工作空间市场规模 数据来源：Gonyn, JEF

图表77 - 内容创作中生成式AI市场规模2025年至2035年（十亿美元） 数据来源：Precedence Research, JEF 据Precedence

Research，全球生成式AI内容创作市场预计将增长7倍，在2035年超过1400亿美元，而2025年为基准。

图表78 - 2025年下半年与上半年中国企业日Token消耗量（万亿） 数据来源：Frost & Sullivan, JEF

据F&S，企业日Token消耗量环比增长263%至37万亿，其中阿里云市场份额增幅最大，在2025年下半年占据32%的榜首位置（2025年上半年为17.7%），其次是豆包的21.3%（2025年上半年为14.1%）和DeepSeek的18.4%（2025年上半年为10.3%）。

2025年下半年，阿里通义千问在企业Token消耗量中排名第一

图表79 - 2025年上半年企业Token消耗量市场份额 数据来源：Frost & Sullivan, JEF

图表80 - 2025年下半年企业Token消耗量市场份额 数据来源：Frost & Sullivan, JEF

中国大语言模型

据F&S/中国信通院，中国大语言模型市场预计在2024年至2030年间将以约64%的复合年增长率增长，并在2030年超过1000亿元人民币。按细分市场看，由于付费意愿仍然较低，消费者收入预计增速慢于企业。

图表81 - 中国大语言模型市场规模（十亿元人民币） 数据来源：Frost & Sullivan, 中国信通院, JEF

中国大语言模型预计在2024年至2030年间将以64%的复合年增长率增长。按细分市场看，本地部署是主要收入贡献者

图表82 - 中国企业大语言模型市场规模（十亿元人民币） 数据来源：Frost & Sullivan, 中国信通院, JEF

Anthropic与OpenAI

\- 2026年5月，Anthropic于5月28日宣布投后估值9650亿美元。其在H轮融资中筹集了650亿美元。年度经常性收入在5月初超过470亿美元。

\- 据The Information，OpenAI收入预计在2030年达到2000亿美元，是2026年规模的6倍以上。预计未来几年智能体收入贡献将上升。

图表83 - Anthropic年度经常性收入

图表84 - OpenAI年度经常性收入 数据来源：The Information, 公司报告, JEF 数据来源：The Information, 公司报告, JEF

图表85 - OpenAI 2023年至2030年预测收入（截至2025年第三季度） 数据来源：The Information, JEF

图表86 - OpenAI 2024年至2030年预测收入构成（截至2025年第三季度） 数据来源：The Information, JEF

图表87 - MiniMax：未来几年占OpenAI收入的百分比 数据来源：CIC, JEF估算

中国主要厂商的模型

图表88 - 阿里模型列表

数据来源：公司, JEF

图表89 - 腾讯模型列表

数据来源：公司, JEF

图表90 - 百度模型列表

来源：公司, JEF

图表91 - MiniMax模型列表

来源：公司, JEF

图表92 - Moonshot AI模型列表

来源：公司, JEF

图表93 - Z.ai模型列表

来源：公司, JEF

图表94 - 基准测试术语表

来源：JEF

我们认为，不同的第三方分析显示，中国对全球Token消耗有显著贡献。根据Hugging Face的数据，截至2月26日的过去12个月中，中国模型占全球下载量的41%。

来源：国家数据局, JEF 图表96 - 豆包每日Token消耗

■ 每日Token消耗（万亿）

来源：火山引擎, JEF 图表97 - 按地区划分的Token份额 来源：OpenRouter, JEF

公司估值/风险