

KC桌面——外资精译

AI GPU/ASIC 追踪、中国大语言模型、先进封装与MLCC
——下一个AI瓶颈

与科技分析师Shawn Kim、Charlie Chan、Nigel Van Putten、Daisy Dai、Lydia

Lin一同探讨AI半导体与硬件供应链、先进封装、功率半导体及MLCC的最新动态及投资影响。在此注册。

Nigel van Putten

概述


全球科技网络直播

AI GPU/ASIC追踪、中国大语言模型、先进封装与MLCC——下一个AI瓶颈


全球 科技 网络直播



图表 1



图表 2




图表 3

来源：Shutterstock，三星电机

AI服务器随着供电架构演进需要更多MLCC

新的服务器设计需要更高容值、更低ESL以及更靠近CPU和GPU的嵌入式MLCC解决方案。




图表 4


来源：太阳诱电。

MLCC行业高度集中

前五大供应商约占全球MLCC市场（2025年）的87%，由村田（OW）和三星电机（OW）领衔。



图表 5




图表 6

来源：公司数据。


AI正成为MLCC行业的关键增长驱动力

我们预计，受单机用量增长和规格升级推动，到2027年AI服务器MLCC需求将接近10亿美元。



图表 7


AI服务器MLCC需求（百万美元）




图表 8

MLCC基本面正在转折

近期中国台湾主要MLCC供应商的月度销售额增长已转为正值。自去年末以来，盈利修正广度显著改善。



图表 9



图表 10

AI半导体：现在与未来——“提示”

- 生成式AI需求驱动因素：

- 杀手级应用
- 竞争
- 主权需求

- 增长限制：

- 预算
- 能源 -> 在美国
- 芯片产能 -> 在中国
- 监管

- 半导体解决方案：

- 摩尔定律
- CoWoS/SolC

- HBM

- CPO

- 定制芯片
- GaN HVDC 800V

- 增长视角：


- 推理 vs. 训练 AI半导体
- 边缘 vs. 云端 AI半导体
- 定制ASIC vs. AI GPU

即使英伟达（OW）提供强大的AI GPU，云服务商仍需要定制芯片

全球云服务商云端AI定制芯片

谷歌TPU进入第六代

AWS AI训练解决方案Trainium




图表 11



图表 12

Meta MTIA v1 采用RISC-V内核



图表 13

Habana开发了Gaudi芯片



图表 14

AWS AI推理解决方案Inferentia



图表 15

特斯拉正在推出Dojo



图表 16

AI ASIC的最新证据：AWS Trainium3




图表 17

亚洲研究团队对Trainium的预测

来源：AWS、谷歌、Meta、英特尔、特斯拉、（e）估算。

根据各云服务商计划，更多ASIC项目即将到来


谷歌TPU性能快速增长



图表 18

来源：公司数据，（e）估算

主要公司ASIC出货量预测



图表 19


中国AI GPU需求的近期市场追踪

英伟达5090在中国价格持续上涨



图表 20

中国主流AI大语言模型平均Token价格



图表 21


字节跳动（火山引擎/豆包）Token激增表明AI需求旺盛



图表 22

来源：公司数据、淘宝。

中国 vs. 全球——云资本开支趋势



图表 23

AI芯片价值链——中国 vs. 美国——AI计算脱钩




图表 24

来源：。


中国基础设施优势缩小了感知上的技术差距

中美AI九大因素对比——芯片、系统、基础设施



图表 25

昇腾950芯片显微图



图表 26

华为CloudMatrix 384 A3 SuperPod


- 第一步：如果一个计算芯片不够强大，将更多芯片封装到单个芯片中。
- 第二步：如果一个芯片不够强大，构建更大的机架和集群。 第三步：如果一个晶圆厂不够用，扩大制造产能。



图表 27

推理经济学：TCO与每Token成本

国产芯片相比英伟达面向中国的处理器，具有更低的TCO和可比的每Token成本（AI大语言模型推理）



图表 28

■ 10MW容量的TCO（百万美元） ◆ 每Token成本（美分）（右轴）（越低越好） 来源：公司数据，估算。

国内AI加速器开发商的订单下达与潜在订单

TPS（每秒Token输出量）——性能分析

中国AI加速器TPS（每秒Token数）分析

来源：公司数据，估算（*我们的假设包括：AI大语言模型：DeepSeek R1；输入Token：1,024；输出Token：1,024；激活专家数：257个中的9个；模型大小：671GB；模型层数：61；批量大小：1；算力：FP8，若FP8不可用则使用FP16）。

国产芯片凭借显著更低的价格，实现了更强的每美元性能 性能/成本对比

- = 基于估算。来源：公司数据。

中国AI GPGPU厂商“十龙”。我们重点关注寒武纪（OW）、沐曦（EW）和壁仞科技（OW）

来源：公司数据。

寒武纪、沐曦和壁仞科技对比 来源：公司数据。

寒武纪：推理性能与客户锁定领先；OW

寒武纪的产品与规格

寒武纪的供应链与客户 我们预计寒武纪2025-2028年收入将以90%的复合年增长率扩张

来源：公司数据。e = 估算。

壁仞科技：凭借强劲订单可见性发挥供应链韧性；OW

壁仞科技激进的产品路线图 我们预计壁仞科技2025-2028年收入将以122%的复合年增长率扩张

我们预计壁仞科技毛利率将保持温和 来源：公司数据。e = 估算。

Nigel van Putten

功率半导体——供给驱动的上升周期

分立器件总收入同比增速自2025年第四季度以来转正

汽车和工业占分立半导体终端需求的约70%（2025年）

来源：WSTS、Gartner。

需求——喜忧参半

工业自动化公司收入在2026年第一季度同比增长21%，增长强劲

中国电动汽车批发销量年初至今疲软，但正逐步转正

供给增量有限

全球领先功率半导体公司资本开支连续两年下降

2026-2028年产能增加可能放缓

来源：公司数据，估算

股价（最近收盘价）