

KC桌面——外资精译

硬件与网络

硬件与网络

数据中心观察：LLM使用量与GPU定价攀升支撑AI需求；内存现货价格出现分化

在本期《数据中心观察》报告中，我们概述了与AI基础设施需求相关的关键数据点，包括LLM token用量与价格、GPU租赁价格以及内存成本。综合来看，最新数据表明AI基础设施需求环境呈现积极趋势，包括LLM使用量的扩张，这足以抵消LLM token价格的同比下跌，同时GPU租赁价格环比持续走高。重要的是，基于我们的样本和简化假设，即使采用保守的token价格，我们估计token经济性对模型提供商而言方向性向好。与此同时，DRAM价格继续上涨，但增速放缓，而NAND现货价格已连续三个月小幅下跌。《数据中心观察》报告的主要亮点如下：

- 6月份OpenRouter上的LLM趋势重新加速。6月份OpenRouter上的LLM趋势普遍重新加速，token用量（环比+70%，同比20倍）、定价（环比小幅上涨，但同比仍-5%，美国模型逆势同比上涨）和支出（环比+70%，同比16倍）均有所增长。有趣的是，虽然美国模型在用量上失去份额（35%），但它们主导了支出（85%以上），其中Anthropic的Claude Opus 4.7是唯一在用量和支出上均排名前五的模型。
- 6月份所有层级的GPU租赁价格均上涨。
6月份，非超大规模云服务商的GPU租赁价格全线环比持续增长，Nvidia GPU三个层级（A100、H100、B200）的价格均环比走高。A100领涨环比涨幅，在三个层级中环比增幅最大，而H100和B200的扩张速度较为温和。B200的定价约为H100的2倍，H100的定价约为A100的1.7倍，这两个比率均连续第二个月小幅下降。
- 6月份内存价格仍处高位但出现分化，DRAM和NAND走势相反。DRAM现货价格6月份再次环比上涨，连续第三个月上涨，同比涨幅超过8倍；而NAND现货价格小幅下跌，在2026年第一季度强劲上涨后连续第三个月小幅下跌，但仍同比上涨超过5倍。

LLM Token追踪器

我们的LLM Token追踪器每月捕捉一周的使用量和定价数据，提供OpenRouter上约300个LLM趋势的月度快照或抽样。请注意，OpenRouter偏向开发者、初创公司和代理编码流量，不包括第三方API流量（直接的OpenAI/Anthropic、超大规模云服务商托管的端点）。


主要结论：

- 6月份token用量增长加速，此前在2026年初增长有所放缓。6月份token用量增长加速，环比扩大+70%（5月为+33%，4月为+5%），同比扩大20倍（5月为12倍，4月为15倍）。相比之下，美国模型（OpenAI、Anthropic、Google、xAI等）的用量占总量的35%（5月为46%，4月为56%），其增长也在6月份加速，环比扩大+30%（5月为+9%，4月为+23%），同比扩大8倍（5月为6倍，4月为10倍）。
- 进入6月，token定价同比继续走低，但幅度较近几个月更为温和。虽然6月份平均token定价环比上涨+7%（5月为+5%，4月为+19%），但同比下跌仍在继续，不过速度有所放缓，同比下降-5%（5月为-21%，4月为-24%）。我们认为，这一跌幅放缓是由美国模型的强劲定价趋势引领的，这体现在成交量加权平均定价上：美国模型环比上涨+27%（5月为+19%，4月为+10%），同比上涨+77%（5月为+36%，4月为+4%）；而所有模型环比持平（5月为-8%，4月为+15%），同比下降-20%（5月为-25%，4月为-23%）。
- 6月份token支出也加速增长，此前两个月增长有所放缓。6月份token支出增长加速，环比扩大+70%（5月为+23%，4月为+21%），同比扩大16倍（5月为9倍，4月为12倍）。相比之下，美国模型的支出占总量的85%以上（5月为90%，4月为85%），其增长也在6月份加速，环比扩大+65%（5月为+30%，4月为+35%），同比扩大1

4倍（5月为8倍，4月为10倍）。

- Opus 4.7在用量和支出上均排名前五。6月份基于token用量的前五名模型是：1) DeepSeek V4 Flash；2) MiMo-V2.5；3) MiniMax M3；4) Hy3 preview；5) Claude Opus 4.7， 占总token用量的45%。然而，基于支出，6月份的前五名模型是：1) Claude Opus 4.7；2) Claude Opus 4.8；3) GPT-5.5；4) Claude Sonnet 4.6；5) GLM 5.2， 占总token支出的75%。


图1：Token用量



图表 1

来源：OpenRouter, JPM估算 注：“美国周度Token”包括美国模型


图2：平均Token定价



图表 2

来源：OpenRouter, JPM估算


图3：成交量加权平均Token定价



图表 3

来源：OpenRouter, JPM估算 注：“美国VWAP”包括美国模型


图4：周度Token支出快照（百万美元）



图表 4

来源：OpenRouter, JPM估算 注：“美国支出”包括美国模型


图5：基于用量的前20名模型（周度Token，万亿）



图表 5

来源：OpenRouter, JPM估算

图6：Token定价 vs. 用量



图表 6

来源：OpenRouter, JPM估算

GPU租赁价格追踪器

基于彭博指数的主要结论：

- 6月份A100租赁价格环比大幅上涨；H100与A100的比率小幅走低。6月份A100平均租赁价格为1.63美元/GPU小时，环比上涨+6.3%（5月为+6.6%，4月为+1.8%），连续第五个月环比增长。
- 6月份H100租赁价格继续环比上涨。6月份H100平均租赁价格为2.72美元/GPU小时，环比上涨+3.7%（5月为+3.2%，4月为+2.1%），连续第七个月环比增长。6月份H100与A100的价格比率平均为1.67倍（5月为1.71倍，4

月为1.77倍）。

- 6月份B200租赁价格环比上涨；B200与H100的比率继续走低。6月份B200平均租赁价格为5.33美元/GPU小时，环比上涨+2.7%（5月为+0.4%，4月为+1.3%），环比涨幅落后于H100和A100。6月份B200与H100的价格比率平均为1.96倍（5月为1.98倍，4月为2.04倍，2025年9月指数推出时约为2.58倍）。

图7：平均月度租赁价格（非超大规模云服务商）



图表 7

来源：彭博金融终端 图8：平均月租金价格（环比百分比变化）



图表 8

来源：彭博金融终端


内存价格追踪

基于彭博数据的关键要点：

\- DRAM现货价格6月继续上涨，DDR5 16Gb同比涨幅超过8倍。DDR5 16Gb现货价格6月达到43.14美元，环比上涨+10%（5月为39.24美元，4月为33.12美元），同比上涨+740%（2025年6月为5.13美元），继2月和3月小幅环比下跌后，连续第三个月环比上涨。

\- NAND现货价格6月环比小幅下跌；NAND 1Tb同比仍上涨超过5倍。NAND 1Tb现货价格6月追踪至27.03美元，环比小幅下跌-0.3%（5月为27.12美元，4月为27.43美元），同比上涨+412%（2025年6月为5.28美元），继2026年第一季度大幅上涨后，连续第三个月环比小幅下跌。


图9：内存价格（环比百分比变化）



图表 9

来源：彭博金融终端

图10：内存价格（同比百分比变化）



图表 10

来源：彭博金融终端