

KC桌面——外资精译

MS：金山云三年营收复合增长35%，AI云驱动利润率改善

我们看好金山云从二线通用云厂商向AI云早期且坚定的转型，其AI收入快速增长，盈利能力持续改善，并得到小米和金山集团强大生态系统的支持。我们首次覆盖，给予超配评级。

关键点：公司情况更新

金山云及时的转型和早期全面押注AI的战略，使其在中国十大公有云厂商中在AI时代占据了有利位置。在全球芯片短缺背景下，公司展现出强大的定价能力；更重要的是，有利的现金流将缓解资产负债表不确定性。

小米+金山生态系统提供了差异化的AI应用场景，同时其他主要客户的收入贡献也在快速增长。

在我们的基准情景下，我们预计金山云将在未来3-5年内跟随行业领先者的利润率上升轨迹，保持稳定差距，达到低双位数的EBIT利润率。

\- 我们的乐观情景假设，基于开源大模型快速增长的MaaS业务将支撑更高的资产回报表现和利润率。

我们首次覆盖金山云。金山云是一个纯粹且弹性的AI云标的，是我们大中华区IT服务与软件覆盖中的首选。我们预测2025-28年，受AI云业务驱动（AI在2025年第四季度贡献了34%的收入，我们预计到2026年将升至>40%，到2028年>60%），收入复合年增长率为35%，调整后EBITDA复合年增长率为79%。调整后OP利润率的上行空间（2028年6.9%对比2025年-1.6%）得益于GPU云和潜在的MaaS业务的有利单位宏观环境性。

，较美国新云厂商同行中位数10倍有所折让，以反映供应链可用性的更大不确定性。考虑到折旧政策的差异和EBIT有限，我们更倾向于使用EBITDA进行公司间比较。

主要节奏变化不确定性包括供给侧限制导致采购不足、利率高于预期导致融资成本上升，以及中国AI模型开发慢于预期。

主要催化剂包括服务器使用寿命长于预期、MaaS贡献提升以及小米AI生态系统的突破。



图表 1

金山云控股 (KC.O,KC US)

除非另有说明，所有指标均基于MS ModelWare框架 ** = 基于共识方法论 § = 共识数据由Refinitiv Estimates提供 e = MS估计

MS与所覆盖的公司有业务往来并寻求开展业务。因此，读者应注意，该公司可能存在影响MS客观性的利益冲突。读者应将MS视为研究决策的单一因素。

有关分析师认证和其他重要披露，请参阅本报告末尾的披露部分。

财务摘要：公司情况更新

图表1：金山云：财务摘要 利润表

来源：公司数据，MS估计。


关键绩效指标与财务比率

不确定性回报 – 金山云控股 (KC.O)

受益于算力短缺

公司情况更新

基准情景，基于5.5倍2027年预期EV/EBITDA倍数。该倍数较美国新云厂商同行平均值13倍和中位数10倍有所折让，以反映较低的资产回报表现和供应链可用性的更大不确定性。考虑到折旧政策的差异和EBIT有限，我们更倾向于使用EBITDA进行公司间比较。



不确定性回报图




来源：Refinitiv, MS

超配逻辑：公司情况更新

- 我们预测2026年AI收入将增长109%，受强劲的算力需求和总计150亿元人民币的服务器研究驱动。
- \- 我们预计毛利率将因其更高利润率的AI业务而扩大。
- ，较美国新云厂商同行有所折让，以反映供应链可用性的更大不确定性。

Consensus Rating Distribution



Source: Refinitiv, Morgan Stanley Research

图表 4

来源：Refinitiv，MS

新数据时代：正面 长期增长：正面 在此查看不确定性回报主题描述

乐观情景：公司情况更新

7.0倍 2027年预期EV/EBITDA

我们假设对高端GPU的需求更强劲，推动EBITDA更快增长，以及Mimo模型的积极发展。

27.00美元 基准情景

5.5倍 2027年预期EV/EBITDA

我们预计金山云将继续受益于超大规模企业对高端GPU的需求。

15.00美元 悲观情景

4.00美元

4倍 2027年预期EV/EBITDA

我们假设中国AI发展仍在调整。



图表 5

平均MS估计 来源：Refinitiv，MS

不确定性回报 – 金山云控股 (KC.O)

关键盈利输入

研究驱动因素

- \- AI收入增长
- \- 毛利率

全球收入分布



图表 6

- AI GPU需求强于预期
 - 利率低于预期，带来更好的回报率
- 来源：MS估计 [在此查看区域层级说明](#)

公司情况更新

上行不确定性


- \- 小米AI模型开发好于预期

节奏变化不确定性

- 供给侧限制导致采购不足
- 利率高于预期导致融资成本上升
- 中国AI模型开发慢于预期



图表 7



图表 8

持仓情况：公司情况更新



图表 9

来源：MS Prime Brokerage。包含与MSPB持有的某些对冲产品敞口。信息可能与更广泛的市场趋势不一致或无法反映。多空比 = 多头敞口 / 空头敞口。行业占净总敞口百分比 = （特定行业：多头敞口 - 空头敞口） / （所有行业：多头敞口 - 空头敞口）。

执行摘要：公司情况更新

金山云向新云厂商的早期且坚定转型，正帮助其在AI时代抓住上行空间。作为此前二线通用云服务商，金山云于2022年开始转型，大规模缩减低利润率的CDN业务，将其融入小米生态系统，并在2024年尽管研发和财务资源有限的情况下，全面押注AI相关业务和技术栈。金山云成功抓住了来自超大规模企业和AI实验室快速增长的训练需求。这些举措已初见成效，收入增长连续三年加速，EBITDA利润率趋势向上，营业利润于2025年实现扭亏。AI云在2025年第四季度贡献了公有云收入的49%，根据我们的估计，到2026年将进一步增至61%，到2028年增至78%。我们相信，对于金山云而言，AI推理带来的可观上行空间将很快到来，尤其是基于开源大模型构建的MaaS业务，这得益于金山云强大的模型优化能力。

研究亮点：公司情况更新

- 强劲需求保障了对客户的议价能力，并确保项目层面可观的内部回报表现
- 预付款和融资租赁改善了资本结构
- 中国低利率和宽松的信贷环境为整体现金流提供支撑

研究顾虑：公司情况更新

- 供应链限制可能为新增收入带来不确定性
- 资本密集型属性仍较高，可能引发对融资的担忧
- 内容分发网络等传统云业务可能稀释整体增长

主要节奏变化不确定性

- 若金山云遭遇服务器供应链中断，增长可能因产能不足面临节奏变化不确定性。另一方面，若下一代服务器的供应/可用性大幅增加或远早于预期上市，金山云现有服务器的租赁定价可能面临显著不确定性。
- 若中国AI发展因代币消耗减弱或国内超大规模云厂商资本支出减少而仍在调整，云厂商可能面临需求疲软。
- 若国内领先大语言模型在AI模型更新中选择闭源（目前为开源），将限制金山云未来由MaaS业务带来的利润率提升空间。
- 若AI大语言模型领域的关键参与者因下游整合而决定退出市场，可能对整体AI训练需求产生谨慎影响，至少短期内如此。

主要上行不确定性

- 若金山云服务器在四至五年折旧年限后仍能继续运行，折旧周期结束后利润率可能显著提升。我们估算，假设定价不变，服务器额外使用一年可使设备内部回报表现提高5个百分点。
- 若小米AI生态系统发展超出市场预期，特别是MiMo的能力，可能为金山云业务量带来额外上行空间。

- 鉴于超大规模云厂商直接利用来自新云提供商的AI算力，其AI研究（运营支出）的任何上调都应支撑对金山云服务的需求。

查看我们关于中国AI路径系列报告的更多内容

数据中心：偏远地区的拐点与颠覆（2026年1月21日）
中国AI路径：通过自研芯片拥有完整AI堆栈（2026年3月11日）
中国AI路径：通过AI云将激增的代币使用量变现（2026年3月16日） 中国AI路径：物超所值（2026年4月27日）

受益于蓬勃发展的云市场

AI云：公司情况更新

我们将AI云定义为IaaS + MaaS。鉴于应用层的碎片化特性及难以精确估算规模，我们将AI SaaS排除在市场测算之外。此外，当我们提及云厂商时，通常指基础设施提供商，它们为应用开发者提供底层能力。尽管如此，我们认识到，随着智能体及AI原生应用的发展，AI应用层长期潜在市场规模可能远超基础设施层。


根据IDC数据，生成式AI的IaaS + MaaS层预计将从2024年的150亿元人民币增长至2029年底的2180亿元人民币，复合年增长率为72%。作为IaaS + PaaS的一部分，生成式AI占比预计将从2024年的6%上升至2029年底的39%。

我们对行业CIO的调查显示类似趋势，与AI相关的公有云支出占比预计将从2026年上半年的6%在未来三年内升至10%。

图表2：AI时代与传统云的区别


来源：公司数据，MS。

图表3：AI在中国IaaS + PaaS中的占比将持续提升



来源：IDC估算，MS。


图表4：与AI相关的公有云支出（CIO视角的混合占比）



图表 11

来源：AlphaWise, MS。当前与未来三年内与AI/LLM相关的公有云支出平均占比

图表5：与AI相关的公有云支出（加权平均）



图表 12

来源：AlphaWise, MS。


AlaaS——生成式AI正成为增长的重要贡献者：根据IDC数据，2025年上半年中国生成式AI IaaS收入达到167亿元人民币（同比增长220%），占国内IaaS市场总额的17%（该市场同比增长17%）。从总增长贡献来看，生成式AI贡献了13个百分点，而其他IaaS收入贡献为3.7个百分点，表明生成式AI正成为中国IaaS市场最重要的增长驱动力。基础设施层展现出最显著的增长，这与采用周期的早期阶段相符——但我们认为，随着未来应用创新，AI SaaS层将迎头赶上，并推动代币使用量激增。

3/11

AI PaaS/MaaS：MaaS 已成为AI时代基础设施层与平台层之间的一个特殊层级。MaaS通过API向用户提供一系列模型，超大规模云厂商可按Token用量收费。主要云厂商均已推出各自的MaaS产品，包括百度的千帆、字节跳动的火山引擎以及阿里巴巴的百炼平台。此外，还有一些新兴厂商（如SiliconFlow）在该细分市场中正获得更多份额。

AI SaaS仍处于早期阶段，市场正在等待杀手级应用的出现。目前大多数应用以聊天机器人、智能体和视频生成工具的形式呈现。我们对近期OpenClaw的出现及其在开发者和消费者中日益增长的受欢迎程度感到鼓舞。尽管我们认为AI


SaaS/智能体最终可能代表比基础设施层大得多的潜在市场（TAM），但市场仍处于早期阶段，目前难以衡量。

Exhibit 6: IaaS market breakdown

图表 13

来源：IDC, MS。

图7：增长贡献：生成式AI是中国IaaS市场的主要增长驱动力



图表 14

来源：IDC, MS。

关键需求驱动因素——Token用量上升

推理是中国的主要需求驱动因素：我们预计模型推理需求将成为未来生成式AI IaaS应用的主要驱动力。根据IDC数据，2024年训练工作负载占生成式AI IaaS市场的76%，但随着推理工作负载以显著更快的速度增长，这一份额预计到2029年底将下降至23%。IDC预测，2024-2029年训练需求将以26%的复合年增长率（CAGR）扩张，而推理需求则为103%。我们认为强劲的推理需求由以下因素驱动

- 更先进且更易获取的大语言模型（LLM）
- 未来AI应用的出现以及生成式AI融入日常工作负载
- 多模态模型的改进，与标准文本到文本的LLM相比，可能需要更多Token。

我们认为推动Token增长和AI应用的关键垂直行业将主要包括互联网公司、AI原生开发者以及电动汽车/汽车行业。

Token用量持续上升……：Token是驱动AI需求的基本单位。我们注意到，中国的Token用量一直在上升，其中以字节跳动的豆包（一款AI聊天机器人）为首。根据字节跳动数据，其日均Token用量从2024年12月的4万亿上升至2025年底的50万亿。此外，在2025年2月DeepSeek发布后市场波动之后，中国主要AI应用的使用时长出现了快速增长。OpenClaw日益普及是另一个例子，说明新的用例如何导致Token用量的非线性增长。MiniMax指出，受OpenClaw驱动，其ARR（年化经常性收入）从2025年12月的1亿美元增长了50%，达到2026年2月的1.5亿美元，而Token用量则增长了6倍。尽管如此，我们注意到其超过70%的收入来自海外市场。

总体而言，我们认为有几个因素支撑了中国Token用量的激增

- 面向消费者的应用使用（通义千问、夸克、元宝、豆包等）
- 更广泛的面向企业的应用（如编程智能体）
- 新兴用例，例如最近的OpenClaw。


……与上一轮周期相比，这可能会推动公有云采用率上升：我们此前指出，中国公有云市场规模小于美国的一个主要原因是企业偏好私有云或本地部署。我们最新的CIO调查显示了变化的早期迹象：采用公有云的意愿从上次调查的44%上升至54%，而三年内采用的意愿也从19%上升至35%。

为何使用AI云？在下游用户方面，模型提供商占生成式AI IaaS使用量的最大份额（23%），其次是行业用户，如汽车和资金。企业使用IaaS而非购买自有基础设施或采用私有云的一些原因包括

- 更高的弹性：客户在工作负载使用方面拥有更大的灵活性，无需在产生收入之前过度承诺购买硬件，这可以改善其研究回收期。对于（超大规模云厂商以外的）公司而言，大量购买GPU服务器可能负担更重，因为需要大量资本支出。
- 芯片组限制：鉴于芯片组供应紧张，尤其是在中国，超大规模云厂商采购AI芯片（通过批量购买获得更优价格，并且更容易接触供应链）以及小型公司通过云服务获取算力是合理的。
- 底层技术快速迭代：芯片组的性能逐年大幅提升，芯片的使用寿命通常仅为4-5年。因此，对于小型企业而言，购买AI服务器在宏观环境上并不划算。
- 更好的模型捆绑：顶级超大规模云厂商拥有自己的前沿模型，如果企业有兴趣采用这些模型，而不是雇佣人才来采用和微调它们，这也能提供更好的服务和部署。

不使用AI云的原因——数据安全是最大的阻力：我们认为商界最终会认识到，采用AI云可能需要与云厂商共享专有数据，这可能会让这些厂商在一定程度上了解内部数据处理活动。因此，当保护专有数据的价值超过公有云部署的成本效益时，组织可能会选择将某些工作负载迁移到私有云或本地环境。这一趋势可能会阻碍AI云的长期潜在市场（TAM）。我们的CIO调查也表明，混合部署模式可能是最佳的长期方法。


图8：按工作负载类型划分的生成式AI IaaS



图表 15

来源：IDC，MS估计。


图9：按下游用户划分的生成式AI IaaS



图表 16

来源：IDC，MS。


图10：按供应商类型划分的协助AI部署的供应商



图表 17

来源：AlphaWise，MS。

图11：按供应商名称划分的协助AI部署的供应商




图表 18

来源：AlphaWise，MS。

图12：公司情况更新


公有部署将在未来12个月内增加 预计未来12个月与未来3年将驻留的AI/ML工作负载



图表 19

来源：AlphaWise, MS。


图13：主要AI应用：使用时长仍在快速增长



图表 20

来源：QuestMobile, MS。

图14：中美Token用量的主要数据点



图表 21

来源：公司数据，MS。


供给端——芯片仍是最大制约因素

芯片组可用性是关键制约因素：我们注意到，中国的人工智能需求仍受到AI芯片可用性的显著限制。我们预计这一制约将从2026年下半年起逐步缓解，得益于国内AI晶圆产能扩张以及英伟达H200及同等芯片可能重新进入市场以满足训练需求。我们的泛半导体团队预计，2026-27年国内AI产能将几乎翻倍，这有望支撑国内AI技术的发展。我们与数据中心供应商的交流显示，超大规模云服务商预计将从2026年下半年收到芯片发货后开始提升其国内AI产能。

我们认为增长由资本支出驱动：在周期早期阶段，我们认为增长主要由供给驱动，因此资本支出可能是云收入增长的领先指标。基于公司披露数据，中国超大规模云服务商的资本支出增长在2023年一季度触底，并在2024年因强劲的AI研究而开始快速加速。因此，公有云收入增长在2023年底触底，并于2024年四季度开始回升，主要受阿里巴巴云收入增长带动，其增速从2024年的个位数加速至2025年第三季度的34%。我们认为持续的AI研究将进一步支撑云增长，且随着基础设施利用效率提升以及未来更强大芯片组的采用，云增长可能继续加速。我们预测超大规模云服务商资本支出同比增长41%，达到6020亿元人民币（约860亿美元），相当于美国超大规模云服务商水平的11-12%。我们预测阿里巴巴和腾讯的资本支出强度将提升至约15%，但仍落后于谷歌和Meta的40-50%以及亚马逊和微软的约20%。

基础设施层面的优化提升效率：尽管中国在芯片组层面面临更大制约，但包括模型开发商和云服务商在内的基础设施提供商持续提升AI芯片组利用效率。这些优化努力有助于提供商在芯片供应有限的情况下支撑更高的工作负载/使用量。以MiniMax为例，其招股说明书指出可实现超过75%的模型算力利用率，而行业平均水平为40-50%，从而降低推理成本并提升性能。


图表15：云资本支出与增长



图表 22

资料来源：公司数据，MS估计。


图表16：我们预测2026年超大规模云服务商资本支出将达到6020亿元人民币



图表 23

资料来源：公司数据，MS估计。


图表17：中国——服务器支出与出货量增长



图表 24

资料来源：IDC，MS。

图表18：我们的半导体团队预测中芯国际AI产能将在2026年翻倍



图表 25

资料来源：公司数据，MS（E）估计。

金山云向新云转型

新云的基础：公司情况更新

新云是一种专门化的云服务商，专注于提供专为AI工作负载设计的基础设施和服务。更具体地说，新云是一种运营专为AI工作负载构建的数据中心的云公司，为寻求这种专业化基础设施的企业提供更快或更便捷的访问高性能GPU的途径，用于训练和运行AI。与提供广泛通用服务的传统超大规模云服务商（如AWS、Azure、谷歌云、阿里云）不同，新云是为AI的严苛需求——尤其是涉及GPU的需求——而专门构建的。全球领先的新云玩家包括CoreWeave和Nebius。

新云的出现满足了日益增长的AI专用硬件需求，以及企业在获取和负担必要资源方面面临的挑战。超大规模云服务商和科技公司通常是新云的核心客户。

关键特征：公司情况更新

- AI优先的基础设施：新云将其整个基础设施——计算、存储和网络——设计为针对AI特定任务进行优化。
- GPU即服务：核心产品是GPUaaS，提供按需访问强大、通常是最新一代GPU的能力。客户从新云租用GPU来训练AI模型或运行AI推理。
- 资本支出转运营支出：公司可以租用GPU计算能力，而不是自行购买昂贵的AI硬件，从而将资本支出转为运营支出。
- 针对AI工作负载优化：它们擅长为训练和微调大语言模型、复杂分析和实时模拟等任务提供计算能力。
- 高性能网络：新云优先考虑GPU集群之间的高速互连和低延迟网络，以确保高效通信和分布式训练。
- 专业化服务：除GPU外，新云通常还提供AI优化存储、数据管道支持、AI模型训练和微调服务以及监控工具。
- 灵活定价：新云通常采用按需付费定价模式，通常提供从小时价格到GPU生命周期价格的透明定价，无需大额前期研究。

- 敏捷性：新云通常比大型云服务商更精简、更敏捷，能够快速采用最新技术。

新云公司提供的核心价值主张包括

- 获取计算能力及其他相关基础设施/设备/组件，包括数据中心、内存、交换机、网络。在中国，芯片组采购远比其他方面重要，而在美国，数据中心及相关电力采购是重大障碍。
- 软件栈能力，包括集群编排、模型训练和微调、推理优化、开发者工具。这些对于服务初创企业和企业更为重要，在服务超大规模云服务商时相对不那么重要。
- 资金支持。

金山云从传统云向新云的转型

随着中国云行业从传统云计算时代演进到AI驱动时代，金山云经历了重大的战略和竞争定位调整。

1. 云时代的市场地位（2024年之前）

在传统云时代，金山云是中国公有云市场的中等规模参与者。它在2019年至2021年间展现出强劲的早期增长，收入年复合增长率为51.3%。与阿里云、华为云、腾讯云和国有电信运营商等云同行相比，它是一个相对独立的参与者。我们估计2025年金山云在中国公有云IaaS/PaaS市场的份额为3-4%。金山云并未在所有细分领域与超大规模云服务商直接竞争，而是专注于特定行业垂直领域，尤其是游戏和视频，在这两个领域的云服务中占据前三名。该公司还严重依赖内容分发网络服务，该服务曾贡献高达其收入的一半。然而，内容分发网络是一种商品化的低利润业务，对盈利能力造成了影响。

我们注意到，在此期间，IaaS 价值链上的大多数资源/设备/组件并未面临严重短缺。因此，云服务商主要依靠单位成本优势和更有利的客户组合（这能实现更高的资源利用率和复用）来驱动盈利能力。

总体而言，金山云面临多重挑战，包括价格竞争、有限的生态支持、因规模相对同行较小导致的成本劣势，以及资产负债表约束。在整个云周期中，该公司持续处于亏损和现金消耗状态，导致读者对其商业模式的可持续性产生质疑。


图表 19：中国公有云厂商（标识）



图表 26

资料来源：MS。


图表 20：金山云营收与净亏损，2017-2025 年



图表 27

资料来源：公司数据，MS估计。

图表 21：金山云毛利率、调整后 EBITDA 利润率、调整后营业利润率，2017-2025 年



图表 28

资料来源：公司数据，MS估计。

2. AI 时代的市场地位（2024 年后）

战略转型：公司情况更新

金山云经历了两步战略转型，以在 AI 时代重新定位自身：1) 从通用云服务商转向 AI 驱动的高性能计算服务器（新云）；2) 从服务第三方的独立云服务商转向优先服务小米生态。

- 第一步始于 2022 年下半年 CEO 变更。公司采取了“高质量与可持续发展”战略，拥抱 AI 技术以提升盈利能力并保持竞争优势。新任 CEO 邹涛先生放弃了以往对营收规模的关注（服务于大型互联网公司的业务，尤其是 CDN 贡献从一半降至百分之十几），转而聚焦盈利能力。结果，金山云经历了两年负营收增长，但毛利率从 2022 年上半年的低个位数大幅提升至 2024 年下半年的十几倍，调整后 EBITDA/营业利润均转正。这解决了金山云的生存问题。
- 第二步始于小米探索 AI 机遇的决心，这发生在小米汽车于 2024 年上半年成功首发之后。一个关键里程碑是 2024 年 11 月小米与金山云签署了为期三年的关联交易战略框架协议。金山云成为小米生态的战略云合作伙伴，支持小米的 AI、AIoT 和电动汽车业务。小米将为金山云提供财务支持。这为金山云带来了显著的新增长机遇。

关键 AI 产品

自 2024 年起，金山云将其全部研发和财务资源转向 AI 云。2025 年，金山云推出了星帆平台——一个为基础 AI 模型和具身智能打造的一站式 AI 训练与推理平台，提供从模型开发、训练到推理的全生命周期管理。星帆平台的模型 API 服务提供高可用、易集成的模型调用，支持高并发推理和多模型管理。它是一个中立平台，能够托管几乎所有开源模型。公司还提供面向私有化部署的银河堆栈，具备异构 GPU 管理、网络 and 智能容器调度能力，并实现全栈本地化。金山云与几乎所有大语言模型创业公司合作，为模型训练提供大规模计算集群。

因此，金山云营收自 2024 年下半年起重新加速，2025 年增长 23%，AI 云贡献了全部增量营收。结合同行在 AI 领域的各种策略，我们看到阿里云、火山引擎、百度智能云和金山云在 AI 时代势头正劲，而腾讯云、华为云、国有电信运营商云和 UCloud 则势头减弱。

我们注意到，AI 时代的一个关键变化是高端芯片组已成为稀缺资源，具备供应链能力的云服务商都展现出良好的定价能力和盈利能力提升。

AI 时代对云服务商来说有何新变化？

- 两类快速崛起的大客户。第一类是大语言模型厂商，如 DeepSeek、MiniMax、智谱和 Kimi。它们密集使用高端 GPU 进行大语言模型训练，且多数采用租赁算力而非购买。它们良好的发展和成功的融资为 AI 训练的长期发展奠定了基础。它们在软件栈方面也很专业，因此主要使用来自新云服务商的裸金属租赁服务（量大但利润率相对较低）。第二类崛起的客户是从事机器人和自动驾驶的初创公司。与大语言模型厂商相比，它们需求规模相对较小，需要更多软件栈服务，这意味着新云服务商能获得更好的利润率。
- 更加差异化的服务使得超大规模云服务商开始整合新云服务商。这与美国的情况非常相似，微软和 Meta 是 CoreWeave 和 Nenius 的大客户。阿里巴巴管理层也在其财报电话会上提到，正在通过向新云服务商租赁算力，将部分 AI 资本支出转为运营支出，尽管这些新云服务商也与阿里云存在竞争。

这两个新趋势为新云服务商在 AI 时代作为超大规模云服务商和企业的重要补充留下了广阔的发展空间。

图表 22：金山云星帆平台 资料来源：MS。

图表 23：领先云服务商营收增长：阿里云、百度智能云、腾讯云和金山云在 2025 年显著加速，字节跳动在低基数上保持高位，而华为和电信运营商增速节奏变化

资料来源：IDC，公司数据，MS。注：字节跳动、华为和三大电信运营商使用 IDC 数据。

图表 24：金山云 AI 营收占总营收比例 资料来源：公司数据，MS 估计。

图表 25：金山云营收构成 资料来源：公司数据，MS 估计。

图表 26：传统云与 AI 云时代对比

资料来源：公司数据，MS。

推理与提价推动利润率改善

AI 云利润率有望较传统工作负载提升

我们识别出收入端三个因素和成本端三个因素，它们共同决定了 AI 云的利润率。

收入端：公司情况更新

- 单位算力价格：这是网站标价或批量采购价格，即使用云服务商提供的 GPU/ASIC 的单位成本。我们认为每 token 价格是服务底层成本以及总体供需环境的函数。额外的增值服务，如捆绑的 MaaS 服务或推理，可以增加收入，从而改善利润率。
- 最大算力：由底层 AI 基础设施的数量决定，通常以 AI 算力的 GPU 小时数或推理工作负载的 token 生成量来衡量。
- 利用率：这也包括用于自有应用或免费用例（例如，豆包）的算力占比。鉴于运营杠杆，利润率应比利用率增长更快。

成本端：公司情况更新

- 资本支出或单位资本支出：指购买底层计算基础设施（主要是 AI 芯片和服务器）的支出。我们认为，采用 ASIC 进行推理可带来成本优势，因为第三方 ASIC 提供商通常芯片组毛利率为 90%，服务器毛利率为 60-70%，这意味着自研 ASIC 可使单位服务器资本支出降低 50% 以上。
- 折旧年限：美国超大规模云厂商已将服务器折旧年限延长至六年；而中国云厂商仍按 3-5 年计提折旧。折旧政策会对利润率产生影响。
- 其他运营成本：包括电力和数据中心成本。超大规模云厂商正通过将数据中心迁往偏远地区来压缩这部分成本，这些地区以较低的租金和更便宜的电价著称（参见我们的报告）。

从训练到推理：我们认为训练工作负载更为商品化（按 GPU 小时提供和定价）——这意味着定价主要反映供需动态。因此，价格可能根据芯片组的可用性而波动更大。

另一方面，我们认为 KC 在推理工作负载方面有更多提升利润率的机会。推理工作负载按 Token/API 计费，单台服务器的算力可分配给多个工作负载。这为利润率带来了更多灵活性，具体体现在

- 更优的定价机制与灵活性：训练工作负载的定价相对固定且商品化，但推理工作负载的定价更为灵活。超大规模云厂商可通过增加更多增值服务（如 MaaS 及其他平台服务）来调整定价，从而提高每 GPU 利用率的收入。KC 未来还可成为小米 MiMo 闭源 API 的专有服务提供商。我们认为 MaaS 的增量利润率可达 30-50%，远高于公司综合毛利率。
- 架构/软件创新：推理工作负载有更多空间通过架构创新（如 KV 缓存）来压缩成本和提高利用率，这可以改善生成 Token 所需的 FLOPS，从而在给定计算资源下提高每秒生成的 Token 数。架构创新可在相同硬件研究下将 Token 生成量提升两倍以上。MiniMax 指出，其单服务器收入平均可达同行的两倍，主要得益于每 FLOPS 生成的 Token 更多。

- 更弹性的资源分配：训练工作负载可能需要占用整台服务器，而推理工作负载允许更弹性地分配计算资源。这意味着单台服务器可处理多个工作负载，实现并发调度/批处理，从而最大化资源利用率，进而带来更高利润率。在夜间和周末填充工作负载利用率，可有效提高云服务收入的利润率。

MaaS是一个快速增长的收入来源。据IDC数据，中国MaaS收入在2025年同比增长332%至31亿元人民币，并预计在2026年再同比增长500%至186亿元人民币。这主要得益于Token使用量的激增，2025年增长17倍至1900万亿，2026年再增长20倍至40000万亿。另一方面，Token价格应会减半以上，以提高采用率和可负担性。IDC还指出，MaaS的未来发展应由成本效率（提高吞吐量的架构）、性能以及配套工具和应用生态系统驱动。

我们认为MaaS也是云厂商提升利润率的重要工具。如上所述，MaaS可产生非常高的利润率，因为IaaS基础设施是提供MaaS服务的最大成本组成部分。一旦云厂商建立了底层基础设施，增量MaaS收入即可显著贡献利润。

以MiniMax和智谱为例，我们估计其截至2026年的云API利润率分别为60%和21%。我们注意到，MiniMax享有更高利润率，主要得益于海外收入及其多模态产品（通常高于基础大语言模型）。

假设超大规模云厂商以类似定价水平对其API进行商业化，我们估计这可使它们的收入增加25-150%。我们认为大部分增量收入将贡献给利润率，因为云基础设施是销售成本的最大组成部分。实践中，我们预计国内超大规模云厂商将趋向该区间的低端，原因是它们聚焦中国市场且具备提供多模态能力。

图表28：训练与推理工作负载的差异

图表29：中国MaaS收入份额 来源：IDC，MS。

图表30：中国MaaS Token份额 来源：IDC，MS。

图表31：MiniMax – MaaS利润率 来源：公司数据，MS。

图表32：关键AI硬件销售成本占收入百分比 来源：公司数据，MS。

涨价将利好纯云厂商

我们已见证国内外一系列涨价（参见《中国新兴前沿：中国AI之路：通过AI云实现激增Token使用量的货币化》，2026年3月16日）。

云涨价始于全球超大规模云厂商

- 2026年1月4日，AWS将其用于机器学习的EC2容量块价格上调约15%。此次涨价影响p5e.48xlarge（NVIDIA H200 GPU）等高性能实例，原因是AI资源需求旺盛，许多地区价格从每小时34.61美元升至39.80美元。
- 2026年1月27日，谷歌云宣布自2026年起对网络、存储和AI基础设施实施大幅涨价，原因是需求增长和基础设施成本上升。部分地区的CDN和对等互联数据传输费率上涨100%，特定存储和AI服务成本也在增加。新定价将于2026年5月生效。
- 5月21日，Nebius宣布自6月1日起，按需容量价格平均上涨29%，抢占式容量价格上涨51%，旨在应对持续的GPU容量强劲需求，同时保持市场竞争力。

主要受上游大幅涨价驱动

- 内存：涨价始于去年，势头延续至2026年，SanDisk等公司因组件限制于2026年1月再次上调SSD价格。
- CPU：年初，组件涨价已蔓延至CPU。
- 其他成本稳定：与此同时，第三方IDC成本相对稳定。

图表33：Silicon Data H100租赁指数 来源：Bloomberg，MS。

图表34：Silicon Data B200租赁指数 来源：Bloomberg，MS。

受此影响，中国云及相关产品也开始涨价

- 网宿科技宣布其CDN产品涨价35-40%，自2026年2月1日起生效（链接）。
- \- Ucloud（未覆盖）亦宣布，自2026年3月1日起，将对其云产品线所有续约及新客户提价（链接）。
- \- 腾讯AI平台亦于3月将其自研模型价格最高上调400%，我们认为这归因于底层基础设施成本上升（链接）。
- \- 阿里云于3月26日宣布，其AI计算产品价格上调5-34%，自4月18日起生效（链接）。
- \- 百度云紧随阿里云之后，宣布AI计算相关服务价格上调5-30%（链接）。
- \- 金山云宣布，AI计算及文件存储服务价格将上调15-50%，自2026年7月12日起生效。管理层将涨价归因于全球AI基础设施需求强劲及硬件成本上升（链接）。

我们注意到，涨价已逐步从底层半导体/硬件传导至服务提供商。定价机制顺畅，表明AI计算领域供需结构失衡。

图表35：近期全球涨价情况

来源：公司数据，MS。

图表36：淘宝平台英伟达4090及5090显卡零售价 来源：淘宝，MS。

金山云的终端利润率可能为多少？

我们预计金山云长期可实现至少20%的综合毛利率，而2025年为16%。AI相关云服务已产生20-25%的毛利率，该收入流的持续增长应有助于利润率向20%水平扩张。阿里巴巴亦已给出云业务长期利润率目标为20%，而2026年第一季度为9%，意味着超过10个百分点的上行空间。类似地，我们认为金山云未来五年内营业利润率有望扩张超过10个百分点。

我们认为金山云利润率扩张的主要驱动因素包括

- \- 架构优化：金山云专注于更高效的token生成及提升算力整体利用率。这可通过在夜间及周末向人形机器人/自动驾驶等特定客户出售冗余资源，以及采用FP4等方式提升吞吐量来实现。
- \- KV缓存：一旦计算命中KV缓存，利润率状况将显著改善，因其不再消耗内存带宽。金山云KV缓存命中率较高，有效降低了计算成本，从而提升利润率。
- \- 提价：尽管金山云未宣布任何整体性提价，但我们的调研显示，其可能收窄对某些合同给予客户的折扣。这亦应构成有效提价，从而提升业务整体利润率。
- \- 高利润率产品供给：除纯算力外，金山云还可通过token直接提供模型能力，向客户提供MaaS服务。如我们前述讨论，增加这一额外层级纯粹是利润增厚的。除此之外，云及模型厂商以外的客户缺乏构建网络的能力，这使得金山云能赚取额外利润。这些客户通常来自自动驾驶及机器人领域。

从成本结构来看，我们预计由于与服务器采购相关的资本开支及融资租赁义务增加，未来服务器折旧将成为更大的成本组成部分。然而，我们预计服务器租赁服务价格的上涨将在很大程度上抵消这一影响，因为定价通常跟随底层采购成本。除服务器折旧外，我们预计包括IDC及履约费用在内的其余成本组成部分将受益于经营杠杆，其增速应保持在整体营收增速之下。

图表37：金山云毛利率走势 来源：公司数据，MS估计。

来源：公司数据，MS。

从阿里云近期关于云利润率的表态中得到的启示

在三月季度业绩中，阿里云指出AI相关收入占外部云收入的30%，MaaS相关年化经常性收入达80亿元人民币，并将在下一季度超过100亿元，年底前达到300亿元，表明AI相关云服务需求强劲。

就业务利润率而言，阿里云此前给出的云业务长期EBITA利润率目标为20%，主要由MaaS收入贡献驱动。这表明MaaS的利润率可能高于纯GPU云业务。这与我们上述论点一致，即采用ASIC及MaaS可推动业务获得更高利润率。我们注意到，若参考MiniMax及智谱的利润率，纯MaaS利润率可高达60-70%。

我们认为金山云来自MaaS收入的贡献及MaaS利润率可能较小，因其不开发自有的基础模型，因此相对于原始模型开发者，其优化模型性能的空间较小。因此，MaaS的机会将取决于MiMo的商业化进展，金山云可作为小米大模型的专属MaaS提供商。除MaaS外，我们预计随着AI相关收入占总收入比重提升，金山云的整体利润率状况将逐步向AI云服务收敛。

图表39：金山云星火平台上的AI模型 来源：MS。

图表40：阿里云与金山云EBITA利润率，2022-2029年预测 来源：公司数据，MS估计。

更长生命周期、融资租赁及客户预付款下的单位宏观环境分析

市场因新云业务模式资本需求沉重而对其存有担忧，并将其视为“资产负债表即服务”。然而，我们注意到，近期行业发展正在改善该模式的上行不确定性，原因在于中国存在根本性的算力短缺，加之低利率环境。这支持更易获得融资租赁，而向客户收取预付款可显著缓解金山云的资产负债表不确定性。

我们的单位宏观环境分析表明，以下各项变化（并非互斥）可带来4-6个百分点的内部回报表现上行空间

\- 服务器可运行并收取租赁收入的时间更长（六年），超出预期（五年）。

\- 新云公司可获得融资租赁，覆盖50%的初始资本开支。

\- 新云公司向客户收取一年期租赁预付款。

大多数新云公司向中小客户提供按小时计价的短期算力租赁，读者可监控实时价格以判断市场动态。由于大部分成本本质上是固定的，这对盈利的弹性相当大。然而，这仅是新云业务的一小部分（个位数百分比），新云的大部分产能是通过长期合同及预定定价方案租赁给大客户的。正因如此，我们认为我们的单位宏观环境分析更贴合该业务的基本面。

收入与利润结构

8/11

KC主要通过采购AI服务器并构建网络，为客户提供AI相关训练/推理服务（主要为大型客户提供长期合同下的裸金属租赁）来产生AI收入。该服务的主要成本是服务器采购（折旧），其次是数据中心成本（托管、电力和网络）以及相对较少的人员成本。由于中国算力严重短缺导致AI服务器价格上涨，KC根据服务器采购价格定价，以锁定一定的毛利率（我们估计为20-25%的毛利率）。

对于KC而言，与大型客户的裸金属租赁合同通常为4-5年（以覆盖GPU的生命周期），总资产回报表现超过30%，或研究回收期约为3-4年（现金流入覆盖初始资本支出）。通常，生态客户会向KC提供预付款。这在2025年业绩中非常明显，其经营现金流增长了5倍，达到38亿元人民币，主要得益于小米提供的22亿元人民币预付款。2026年，由于产能短缺，这一模式逐渐扩展到其他客户，大型客户预付一定比例的租金，小型客户甚至预付设备整个生命周期的费用。换句话说，KC正在将其部分定价权转移到现金流条款上。经过4-5年的租赁，服务器在完全折旧后应以极低的残值（会计假设为初始成本的0-5%）进行处置。服务器设备运行时间超过或短于5年折旧寿命，将分别对业务带来上行和节奏变化不确定性。

图表41：商业模式 来源：MS。

资金来源——融资租赁和客户预付款变得更加重要

由于GPU服务器价格高昂，新云业务属于资本密集型，常被视为“资产负债表即服务”。通过融资租赁（最初来自小米资金，但后来来自其他独立资金租赁合作伙伴）和客户预付款（从年租金的某个百分比到整个合同生命周期不等），资产负债表能力有限。这两种方式都要求客户签署长期租赁合同，这对于纯粹训练大语言模型

的客户（他们只想短期使用最先进的GPU）可能没有吸引力，但如果客户拥有多样化的工作负载（例如，前2-3年训练大语言模型，当下一代GPU可用时进行推理或小模型训练），则相当可行。

- 对于大型客户，KC采用融资租赁以更好地管理现金流出，并利用境内债务市场的廉价融资成本。这种模式通常需要为特定研究级客户提供专用产能。我们注意到，KC一半的服务器采购是通过融资租赁进行的，以平滑现金流出。融资租赁合同期限通常为5年，与其客户租赁合同的期限相匹配。2025年，KC的现金资本支出为47亿元人民币，同时增加了35亿元人民币的融资租赁合同，使其有效资本支出达到82亿元人民币。我们预测，2026年KC的现金资本支出将达到100亿元人民币，而融资租赁合同将再贡献100亿元人民币的服务器采购，总计200亿元人民币的服务器采购将推动AI收入增长。
- 对于生态客户和小型客户，KC收取大量预付款（有时甚至覆盖整个合同生命周期）。在卖方市场中，客户可以获得有吸引力的定价（以换取资金的时间价值）。这有效地将业务模式从前期现金流出和逐步流入/收入，转变为前期现金收款和逐步确认收入，从而显著减轻了资产负债表/现金流负担。

我们的分析表明，不同的结构不会影响报告的营业利润率，但对项目的现金周期和内部回报表现有显著影响。我们认为，在这种模式下，KC的整体不确定性和波动性将显著降低，原因如下

- 更好的期限匹配——5年融资租赁（损益表中的折旧）将与具有预设利润率的租赁合同期限相匹配。这提高了损益表的整体盈利能力，并带来了更好的现金流管理（与一次性大额支出相比，现金流出更平滑）。
- 更快的现金循环——由于合同价值在第一天就收回，KC可以更好地利用该现金进行进一步研究（如果需要），或者只是改善公司的整体现金和杠杆结构。

另一个关键假设是终值。我们注意到，在会计上，公司通常假设AI服务器的处置价值为0-5%。然而，最近的行业实践是，AI服务器可以运行超过5年（例如，早期的英伟达A系列和H系列GPU即使在完全折旧后也能继续产生租赁收入）。美国同行甲骨文、亚马逊、Alphabet、微软和CoreWeave已宣布将GPU服务器折旧周期从4-5年延长至6年，而中国云服务商尚未这样做。这将导致中国云服务商在头4-5年利润率相对较低，随后利润率显著提升。我们近期的渠道调研显示，在中国，一台使用了5年的英伟达A系列GPU服务器的二手市场价格几乎是其初始成本的70%。

对财务报表的影响：正如我们在单位宏观环境效益计算中所展示的，基准情况下，一份5年租赁合同可产生9%的税前无杠杆内部回报表现，我们认为这尚可但并不令人兴奋。然而，借助租赁、预付款和延长运营寿命，回报率可以显著提高。

- 融资租赁：融资租赁减少了前期研究的现金负担，但由于需要向融资提供方支付租赁费和额外的利息成本，后续的现金流和营业利润会降低。在租赁结构下，年现金流减少，但被较低的前期支出所补偿。我们的情景分析表明，50%的租赁融资可将无杠杆内部回报表现提高4个百分点。我们还注意到，当地银行支持更高的杠杆率。
- 预付款：预付款对现金流和净利润率都有利。由于前期现金收款，现金内部回报表现得到改善，如果考虑对其他项目的研究，还可以进一步提高。预付款还通过减少融资需求和相关的利息负担来支撑净利润率。我们的情景分析表明，与基准情况相比，一年的预付款安排可将内部回报表现提高约6个百分点。
- 延长使用寿命：如前所述，服务器在5年折旧期后仍可提供服务，这将显著提升盈利能力。一旦服务器完全折旧，净利润率可从折旧前的8%大幅提升至64%。我们的分析还表明，将使用寿命延长一年可使无杠杆IRR提高约5个百分点。

实际上，金山云综合运用上述因素，推动其税前IRR远高于基准情形，而中国的债务成本约为3%。

为何这一点很重要？我们认为，过去两年资本结构一直是读者对金山云的主要担忧。在缺乏可持续净现金流入的情况下，公司的融资需求可能持续增长——无论是通过股权融资（会稀释现有股东权益），还是增加债务（将进一步给资产负债表和现金流带来不确定性）。我们认为，金山云商业模式的改善使其资本结构更易于管理。虽然不能排除进一步融资的必要性，但这很可能伴随着更清晰的项目回报和回收期。利用融资租赁已显著改善了杠杆率，净债务/EBITDA从2024年的6.6倍降至2025年的2.0倍。

图表42：金山云在Neocloud上的单位指标

来源：公司数据，MS估计。

图表43：金山云总研究与现金支出构成

来源：公司数据，MS估计。

图表44：预付款预测

来源：公司数据，MS估计。

与小米生态的合作

小米的AI雄心与金山云在生态中的角色

雷军先生是小米和金山集团（包括金山软件、金山办公和金山云）的最终控制人。他们共同形成了一个充满活力的技术生态，金山云作为底层算力平台，支持各类模型和应用，包括AI模型（MiMo）、智能手机、家电、汽车、游戏、办公软件及其他新兴应用。除金山软件旗下的游戏业务和金山办公旗下的办公软件外，其余需求均来自小米，驱动着算力需求。

正如雷军在小米2026年读者日上所述，小米的AI战略最好理解为"AI无处不在"，嵌入其整个生态而非独立业务线。公司正为此投入大量资源，计划2026-2030年研发投入约2000亿元，其中相当一部分用于AI和芯片，未来几年还将进行数十亿美元的专项AI研究。AI在研发支出中的占比已不断上升，并部署在小米的整个技术栈中，从自研大模型（MiMo系列）到操作系统、芯片和边缘设备。战略上，这支撑着小米向"硬核科技公司"转型，AI作为其"人×车×家"生态的智能层。重点在于务实：规模化部署和产品集成优先于前沿模型领先地位，利用小米庞大的装机量作为主要变现引擎。

在智能手机领域，AI被视为用户体验升级和高端化的关键驱动力。小米正在将AI集成到其操作系统和设备端能力中，实现更智能的助手、影像增强和个性化交互等功能。目标是提高设备粘性并支撑更高的平均售价，同时推动基于手机终端的互联网服务获得更高参与度。

在电动汽车领域，AI在智能驾驶和车内用户体验中均扮演核心角色。小米将AI应用于自动驾驶系统、感知与决策以及智能座舱功能。这使得电动汽车业务与更广泛的生态紧密相连，汽车成为另一个连接节点，AI实现车辆、用户和家庭设备之间的无缝交互。

在AIoT和智能家居领域，AI增强了小米广泛互联设备组合的自动化、互操作性和用户便利性。通过将AI嵌入这些产品，小米旨在创造更直观、响应更快的家居环境，强化生态凝聚力并提升跨设备使用率。这一领域作为规模优势尤为重要，小米庞大的装机量可放大AI驱动功能的影响力。

在AI模型方面，小米是后来者，但MiMo AI模型的首次亮相给市场带来了积极惊喜。小米在研究多家AI初创公司后获得了大量行业洞察。结合小米独有的生态数据、独特的融合应用场景、强大的人才储备和资金支持，这种后发优势正在再次显现，类似于其在智能手机和汽车领域的发展历程。小米的AI模型专注于与硬件生态的集成，不同于其他聚焦智能排名或Token使用量的AI模型。MiMo有三个版本：1) MiMo-Pro（旗舰版）服务于编码等智能体应用，以证明其能力；2) MiMo-Omni版本作为世界模型，服务于硬件融合应用场景；3) MiMo-TTS/ASR版本专注于语音输入、识别和生成。

最后，在平台和基础设施层面，AI支撑着小米在操作系统和半导体领域的努力。公司正在将AI能力集成到其操作系统中，并研究芯片开发以优化设备端性能并减少对外部供应商的依赖。这一层面对长期差异化至关重要，因为它能实现更紧密的垂直整合，并在所有终端用户产品中更高效地部署AI。

双方如何合作？

根据关联交易协议，金山云向小米提供云服务，2026/27年新上限分别为40亿元和60亿元（此前为31亿元和40亿元）。我们预计生态收入将占我们营收预测的35%/39%。金山云需以公平市场价格向小米提供云服务（不高于金山云向第三方提供的价格，且不低于第三方供应商向小米提供的价格），且向小米提供的算力为专用。小米将为金山云提供融资，年度上限为42亿元，包括12亿元融资租赁、12亿元保理和20亿元担保贷款。

我们注意到，小米生态的进展可能通过以下方式对金山云的营收增长至关重要

- AIoT × 智能手机：这是小米的传统业务，截至2024年上半年，占小米对金山云营收贡献的三分之二以上。金山云继续为小米生态提供云支持，以及存储和相关的互联网服务支持。然而，我们认为随着云相关服务的进一步增长，该贡献比例应会下降。
- 电动汽车：小米2025年累计电动汽车交付量已达41.1万辆，金山云通过以下方式提供支持：1) 研发流程，2) 图像处理与传感器数据带来的存储增长，以及3) 智能电动汽车的物流与运营。根据我们的硬件分析师预测，到2026年底，累计电动汽车交付量预计将达到110万辆。
- 小米基础模型：小米AI模型MiMo已被Artificial Analysis评为中国领先模型之一。该模型在发布后前两周内，在Open Reuter上的Token使用量也位居前列。我们认为，金山云可能受益于MiMo未来版本的训练与升级，以及该大语言模型在小米传统业务和汽车业务中的内部应用。金山云未来还可能成为MiMo闭源模型的专有API供应商（模型即服务）。这可能成为推动MaaS收入增长的看涨情形。

我们估计，金山云可能受益于小米不断增长的业务需求（既来自新设备出货，也来自现有用户群使用量的增加），推动其2026-27年收入增长31%/30%。根据金山云数据，2026年前四个月，小米已为其贡献云服务收入7.49亿元人民币，同比增长81%。

图表45：金山云股权结构（截至2025年12月31日） 来源：MS。

图表46：金山云收入构成（生态系统 vs. 其他） 来源：公司数据，MS估计。

来源：公司数据，MS。

图表48：小米智能手机出货量 来源：公司数据，MS估计。

图表49：小米AIoT出货量 来源：公司数据，MS估计。

小米MiMo大模型

图表50：小米电动汽车交付量 来源：公司数据，MS估计。在开源模型中全球并列第一 Artificial Analysis排名显示，MiMo在推理能力和智能体任务能力方面均与国内主要开源模型持平或领先。

图表51

小米MiMo性能亮点

来源：小米，Artificial Analysis，OpenReuter MS。Hermes-Agent的第一贡献模型该排名突显了MiMo相较于其他模型的强大贡献量。

盈利预测与估值

我们预测，受AI相关云服务持续增长的推动，2026-28年收入将同比增长37%/37%/31%。

- 公有云服务预计2026-28年同比增长50%/47%/37%，得益于生态系统收入（主要是小米）和AI相关服务的强劲增长。同期，AI相关收入预计同比增长109%/74%/49%，主要由GPU采购驱动，总资产回报表现约为28-31%。
- 企业云服务预计保持稳定，2026-28年每年增长8%/5%/4%。

我们预测2026-29年毛利率为15-17%，主要受业务结构向利润率更高（20-25%）的AI相关业务倾斜所驱动。由于支持业务扩张需要大量资本支出和租赁，折旧将成为销售成本的最大组成部分。

我们预测，在低基数基础上，调整后EBITDA在2025-28年将以79%的复合年增长率扩张。我们预计利润率将从2025年的24%迅速扩大至2028年的57%。

我们预测调整后净利润将实现盈亏平衡，主要得益于更大规模和更高利润率的业务。

图表52：金山云总研究规模 来源：公司数据，MS估计。

图表53：金山云新增总资产回报表现假设（看涨/基准/看跌） 来源：公司数据，MS估计。

图表54：金山云收入预测 来源：公司数据，MS估计。

图表55：AI收入增长预测 来源：公司数据，MS估计。

图表56：金山云毛利润与毛利率预测 来源：公司数据，MS估计。

图表57：金山云调整后EBITDA与利润率预测 来源：公司数据，MS估计。

图表58：金山云调整后营业利润与利润率预测 来源：公司数据，MS估计。

图表59：金山云调整后净利润预测 来源：公司数据，MS估计。

估值方法：公司情况更新

。我们使用目标EV/EBITDA倍数对金山云进行估值，以考虑其业务的大量折旧，并与CoreWeave等全球新云厂商保持一致。鉴于云业务是重资产行业，且运营商采用不同的债务杠杆率和服务器折旧政策，我们认为EV/EBITDA优于EV/销售额或市盈率等指标，并指出考虑到折旧政策的差异以及息税前利润有限，我们更倾向于使用EBITDA进行跨公司比较。在我们的基准情形下，我们采用2027年预期EV/EBITDA倍数5.5倍，相较于美国新云同业平均13倍和中位数10倍有所折价。我们认为，较低的资产回报表现和供应链可用性的更大不确定性是折价的合理理由。

我们的看涨情形估值为每ADS 27美元，基于2027年预期EV/EBITDA倍数7倍。

- 我们假设看涨情形下2027年预期EBITDA为106亿元人民币，较基准情形高出21%。这主要反映了算力价格更强劲的上涨，导致AI收入增长更快。

我们的看跌情形估值为每ADS 4美元，基于2027年预期EV/EBITDA倍数4倍。

- 我们假设看跌情形下2027年预期EBITDA为67亿元人民币，较基准情形低19%。这主要反映了无法获取额外算力以及定价较低，导致AI收入增长节奏变化。

图表60：金山云：EV/EBITDA估值

来源：公司数据，MS估计。

我们将金山云的估值与美国的新云厂商作为主要可比对象进行对标。美国新云厂商2026-27年预期EV/销售额倍数平均为15倍/7倍，2026-27年预期EV/EBITDA倍数平均为36倍/13倍。剔除主要服务中小企业的Digital Ocean（与其他主要服务大客户的可比对象不太可比），同业2027年预期EV/EBITDA倍数平均为6倍。金山云的交易价格较同业平均水平有显著折价，我们认为部分原因是其美国同行在获取芯片方面具有更高的确定性，并且来自超大规模云服务商的积压订单更为强劲。

金山云目前对应2027年预期EV/EBITDA倍数为4.3倍，远低于自2024年（开始转型为新云厂商）以来15倍的平均水平。我们认为，这在一定程度上是由于早年基数较低，但与其历史相比，估值仍然偏低。

图表61：主要可比公司表

注：对于未覆盖的公司，我们使用Factset一致预期。

来源：FactSet，MS估计。注：数据截至2026年7月2日收盘。

图表62：金山云历史EV/EBITDA估值 来源：FactSet，MS。

图表63：CoreWeave历史EV/EBITDA估值 来源：FactSet，MS。

图表64 自IPO以来金山云相对表现的关键驱动因素

图表65：金山云 vs. 小米报价表现：金山云被广泛视为小米的高贝塔值替代标的 来源：Factset

关于GPU寿命与长期估值关系的思考

11/11

基于上述单位宏观环境分析，我们假设在稳态下（无产能/营收增长，GPU服务器寿命到期，且寿命不再变化），新云服务商每年需支出初始资本开支除以GPU寿命，以维持其收入流。这将导致长期自由现金流和EV/EBITDA倍数（假设不同回报表现）出现显著差异。我们的结论

- 在美国，若GPU寿命从五年延长至六年和七年，长期企业价值应分别扩张35%和61%。若维持六年，8.7倍稳态EV/EBITDA相当于5%回报表现。
- 在中国，若GPU寿命从五年延长至六年和七年，长期企业价值扩张幅度更大，分别达56%和97%。若维持六年，7.1倍静态EV/EBITDA相当于5%回报表现。
- 相反，若GPU寿命从五年缩短至四年，美国新云服务商EV/EBITDA倍数应收窄53%，中国新云服务商EV/EBITDA倍数应收窄85%。考虑到新云服务商的杠杆，这将导致其股权价值归零。
- 由于折旧占收入比重更高（GPU在价值链中占比更大），中国价值变化对GPU寿命的敏感度远高于美国。在相同回报表现和六年GPU寿命假设下，中国新云服务商长期EV/EBITDA应较美国同业存在18%的折价。

上行不确定性（更长GPU寿命）可能出现在：1）算力短缺情景下，旧款GPU在市场中仍受欢迎；2）通过软件升级提升旧款GPU性能（英伟达在2026财年第一季度财报电话会议中表示：“我们在两年内将Hopper推理性能提升了4倍。这得益于英伟达可编程CUDA架构和丰富的生态系统。”）。节奏变化不确定性可能出现在：若下一代GPU技术性能、性价比和可用性均提升数十倍，旧款GPU将被淘汰。我们认为，当推理在工作负载中占比更大时，这种情况极不可能发生，因为推理可由低端GPU处理。

图表66：基于不同GPU寿命的美国新云服务商长期估值

来源：MS。

图表67：基于不同GPU寿命的中国新云服务商长期估值

来源：MS。

公司情况更新

上行不确定性

- 高端GPU需求强于预期
- 利率低于预期，推动回报率改善
- 小米AI模型开发好于预期

节奏变化不确定性

- 供应端限制导致采购短缺
- 利率高于预期，导致融资成本上升
- 中国AI模型开发慢于预期

本报告提及美国第14032号行政令和/或其中指定的实体或标的。美国人士可能被禁止购买本报告所述实体的某些标的。读者全权负责确保其研究活动符合适用法律。

本报告提及美国第14105号行政令和/或可能属于该行政令范围的实体。美国人士可能被禁止从事某些交易，或需将某些其他交易通知美国财政部。读者全权负责确保其研究或交易活动符合适用法律。

本报告提及出口管制和/或可能受出口管制限制的实体。读者全权负责确保其研究或交易活动符合适用法律。

不确定性收益参考链接

- 查看期权概率方法说明 - Options_Probabilities_Exhibit_Link.pdf
- 查看不确定性收益主题说明 - RR_Themes_Exhibit_Link.pdf
- 查看区域层级说明 - GEG_Exhibit_Link.pdf
- 查看主题/敞口方法说明 - ESG_Sustainable_Solutions_External_Link.pdf
- 查看HERS方法说明 - ESG_HERS_External_Link.pdf