


KC桌面——外资精译

GS：GS拆解中国AI竞争格局，定价权与成本优势成赢家关键

从去年DeepSeek时刻（成本效率）到今年智谱GLM时刻（模型智能）

我们认为，中国AI开源/开放权重模型在智能性能方面正达到与全球闭源模型的关键临界点，国内企业及全球中小企业的采用率显著提升，这将形成进一步模型改进的良性数据飞轮。我们评估：这些模型如何在低成本/紧张计算资源下实现如此性能；为何采用开源/开放权重方法以及如何变现；随着全球企业从"token最大化"转向ROI优先，关键可寻址市场是什么，我们在此为中国模型指出两个受青睐的ARR象限；以及在我们的竞争定位框架下，哪些是潜在的长期赢家。我们注意到，对中国未来最前沿模型在海外市场的更严格准入、西方市场对中国模型的政策、以及模型训练中对高端计算资源的获取，是影响我们中国AI模型token/收入增长轨迹的三个关键摇摆因素/不确定性。

我们基于定价能力、成本优势和财务实力，叠加token规模与市场份额进展，引入中国AI模型竞争定位框架，并认定知识图谱（智谱，首次覆盖）和DeepSeek（未上市）在基础模型中定位最强，字节跳动（未上市）在多模态中定位最强。



图表 1


□ □ □ □

目录：公司情况更新

剖析中国开源模型当前单位宏观环境模型及盈利路径 4 PM摘要 5 对比中国主要LLM参与者 11
解码中国AI模型token及我们对token/收入份额的预测 12
中国模型如何在低成本/紧张计算资源下实现有竞争力的性能？ 13
为何中国模型采用开源/开放权重方法，以及变现方式？ 20 国内外关键可寻址市场及主要不确定性是什么？ 23
谁最有可能成为长期赢家？引入我们的竞争定位框架 26 基础模型 26 多模态生成模型 32
主要上行与节奏变化不确定性 37 中国主要AI参与者概览 40
披露附录 49


CHINA AI MODEL & HYPERSCALERS ECOSYSTEM

Our mapping of key players, revenue/profit pools & interdependencies




图表 2

China CSP capex breakdown



图表 3

- 中国云收入计算包括阿里巴巴、腾讯、字节跳动、百度和金山云。2)
- 中国CSP资本支出细分基于GS大中华区科技团队估算；3) 所列公司仅供说明用途，可能并非完整列表。



图表 4

剖析中国开源模型当前单位宏观环境模型及盈利路径

图表1：中国高性价比智能体模型与顶级编程模型的单位宏观环境模型，对比全球SOTA模型的假设宏观环境模型 两级中国AI模型的单位宏观环境模型（每100万混合token）

以绝对美元（十亿）计

我们估算到2026财年末，中国AI模型行业ARR合计达100亿美元；我们估算到2030财年将达到1250亿美元

2026财年中国AI模型行业推理成本为70亿美元，我们估算到2030财年达550亿美元，这转化为超大规模云/新云的收入

2026财年中国AI模型行业训练成本为40亿美元，到2030财年达200亿美元，因模型规模持续扩大

2026财年中国AI模型公司EBIT利润率为负；我们估算到2030财年将达到18%的EBIT利润率/230亿美元的利润池

PM摘要：公司情况更新

从去年DeepSeek时刻（成本效率）到今年智谱GLM时刻（模型智能）

中国AI开源/开放权重模型在智能性能方面正达到与全球闭源模型的关键临界点，国内企业采用率显著提升，全球消费者和中小企业需求激增。在本报告中，我们评估：这些模型如何在低成本/紧张计算资源下实现如此性能；为何采用开源/开放权重方法以及如何变现；关键可寻址市场是什么，我们在此指出两个受青睐的ARR象限及不确定性因素；以及在我们的竞争定位框架下，哪些是潜在的长期赢家。

我们认为中国模型正达到智能体任务/特定编程场景的关键"足够好"阶段，中国AI模型格局日益分化（但强者恒强）。虽然前沿性能/多模态模型的定价能力依然强劲，低端市场却陷入价格战；然而，智能体AI正在推动对这些低端高性价比模型的爆炸性需求。计算资源获取将是一个摇摆因素，其中美国/中国监管、资产负债表和推理效率是关键。

据此，我们基于定价能力、成本优势和财务实力，叠加token规模与市场份额进展，引入中国AI模型竞争定位框架，并认定知识图谱（智谱，首次覆盖）和DeepSeek（未上市）在基础模型中定位最强，字节跳动（未上市）在多模态中定位最强。

中国模型如何在低成本/紧张计算资源下实现有竞争力的性能？通过利用更小参数规模的模型实现同等基准性能，以及混合专家模型和新的架构创新。中国AI模型正分化为两级市场，其中性能和上市时间对定价能力至关重要，从而基于token采用率和定价形成两个"ARR最大化"象限。对于顶级中国AI模型，受实际编程采用率提升驱动，良性飞轮正在生效，并减少对模型蒸馏实践的依赖。

为何中国模型采用开源/开放权重方法，以及变现方式？开源允许模型训练/部署具有更大灵活性，并实现最广泛的采用和开放社区。我们认为开源模型披露的ARR可能低估了总部署和收入潜力，我们预计未来中国AI模型将更多转向开放权重（附带社区许可，即若用于商业用途则需遵守商业条款）。

国内外关键可寻址市场及主要不确定性是什么？

我们重点指出两个受青睐的ARR象限，并预计到2030年，中国/中国AI模型市场的token增长将达到25倍；编程领域将趋于整合，而代理/低端细分市场可能保持分散。国际化（出海）应是关键上行因素，具有更高定价和全球扩张的潜力，尤其是在非美国市场，因为全球企业正越来越多地从追求token最大化转向优先考虑回报表现率的模式，该模式优先考虑明确的任务边界、每日代理数量、后端流程自动化以及实际产出，而非纯粹的计算token量。主要不确定性因素包括市场准入/反蒸馏和监管，例如对中国未来最前沿模型在海外市场的任何更严格准入、对最高端租赁计算设备（用于训练）的获取、对西方市场的准入、进一步的限制清单/实体清单指定（但这可能对中国在软件/CPU/ASIC领域进一步实现AI自给自足有利），以及来自SLM/AI架构的竞争威胁。

谁最有可能成为中国AI模型公司的长期赢家？

我们预计，拥有最大ARR规模、毛利率优势及财务实力的参与者将成为长期赢家。我们强调，独立AI模型公司大多在我们的竞争定位框架中，在定价权+成本优势方面表现突出（根据最新市值/融资轮次，隐含估值总计超过2000亿美元），其中智谱和DeepSeek在基于文本的基础模型方面定位最强，而字节跳动在我们的框架下在多模态能力方面领先。

我们关注2026年下半年的信号指标

\- 工具链/代理应用：我们预计中国AI模型公司将日益专注于将其工具链/代理应用定位为关键入口，尤其是在编程领域（例如，智谱的ZCode、腾讯的Workbuddy和阿里巴巴的Qoder，这些是支持全套AI模型的聚合平台），因为模型公司试图闭环，以获取更多真实世界的编程和代理数据用于规模化。协同工作和行业专家代理产品可能是下一个优先事项。企业将日益关注每项任务的总体成本，而非每token的标价，并愿意使用不同模型（多模型方法）。

\- 多个大参数高端编程模型发布，以及可能对中国境外最先进AI模型实施更严格准入：我们预计2026年下半年将有多款新的中国AI模型发布，其总参数量显著增大，达到2-5万亿。编程/程序设计领域的竞争将加剧，因为中国模型试图通过使用高质量真实世界编程数据（在可用的情况下）进行训练，并扩展到更大的参数模型规模，来挑战智谱GLM的领导地位。我们还预计，对于性能最佳的模型，可能会从开源转向开放权重的方法（即从免费使用转向商业使用需要收入分成/抽成）。多模态/视觉理解的增加将是中国AI基础模型的下一次升级（例如，GLM、DeepSeek），而MiniMax M3在这些方面已经表现出色，因为MiniMax从一开始就专注于多模态。尽管如此，我们注意到新闻报道称，未来可能对海外获取中国最先进AI模型（包括闭源和开源，如果属于前沿水平）实施限制，因为尖端人工智能日益被视为关键国家资产。

\- 低端代理细分市场API定价持续承压：尽管DeepSeek最近宣布从7月中旬起提高高峰时段定价，但我们预计，到下半年，低端定价区间（约每百万token 0.1-0.2美元）的API定价及因此的毛利率仍将面临不确定性，因为中国AI模型公司在融资后拥有大量现金储备，可以在短期内以零/负毛利率补贴竞争性定价。因此，我们将财务实力视为评估中国AI模型公司的三个最重要指标之一（与定价权和成本效率并列），其中在手现金、净现金占资产百分比和估值倍数将是长期成功的关键财务实力指标。尽管如此，我们对MiniMax更新公司观点，因为该公司在我们的竞争定位框架下，在成本效率/成本优势指标方面表现突出。其M3模型在受青睐的ARR最大化象限中定位良好（有吸引力的定价+高token量），加上其折价估值（13倍2026年底ARR市盈率，而中国/全球同行在类似ARR阶段享有数倍更高的倍数），我们认为不确定性回报偏向上行，并重申我们的公司观点。影响MiniMax整体竞争定位的关键摇摆因素将取决于其定价权和财务实力。我们预计其H3视频生成模型性能（与文本模型相比，在更有利的行业环境中即将推出）及其下一次M3更新的上市时间（重点是通过后训练/强化学习进一步提升编程智能水平，我们估计在7-8月，以及2026年下半年晚些时候推出更大参数规模的M3模型）将是下一个关键驱动因素。

\- 多模态/视频生成模型将从全球采用中看到ARR进一步攀升：我们预计视频生成领域（不同于基础文本）将继续保持健康的行业定价和毛利率，其中主要参与者字节跳动的SeeDance、快手的Kling和MiniMax的Hailuo/即将推出的H3模型将在2026年下半年享受健康增长，这得益于新功能突破（视频生成与大语言模型的结合）以及需求远超容量的紧张计算资源。根据《晚点LatePost》和36氪等中国新闻报道，字节跳动的Seedance在其最新超过20亿美元ARR运行率下的毛利率已达到健康的70%。

我们还预计，国内ASIC供应将增加，海外计算资源的获取将趋紧，以及潜在的市场准入限制（可能效仿TikTok的轨迹，即在西方市场快速扩张后，随之而来的是更多监管/关注确保数据安全，计算必须在当地司法管辖区内进行）。

我们对AI模型公司的评估：ARR规模 x 毛利率优势 + 财务实力

- 最大ARR规模（Token规模 x 定价权）
- 毛利率优势（训练与推理效率、技术）
- 财务实力（资产负债表、计算资源获取能力）


据此，我们基于可量化指标列出了AI模型参与者的竞争定位框架：1) 定价权（其中，基于模型发布的上市时间、基于实际使用案例和定价的Arena评分）

3/9

-

成本优势（基于代币量规模、吞吐量/缓存命中率、参数规模/激活比率以及我们对推理毛利率的估算），以及
3) 财务实力（基于在手现金、净现金占资产百分比及估值倍数）。

图表 2：AI 模型厂商竞争定位框架



图表 5

图表 3：主要大语言模型实验室定位的竞争分析概览

阿里巴巴通义千问：全栈 AI 厂商，拥有多年 AI/云上行空间，在多数领域处于领先地位



图表 6

智谱 GLM：在编程/智能体场景中具备领先的模型能力 腾讯混元：AI 战略重组后的强劲竞争者；在微信 AI 智能体方面具有潜力



图表 7

MiniMax M 系列：独立厂商中独特的全模态能力；高性价比计算架构




图表 8

DeepSeek：极致成本效率，以有竞争力的定价维持可扩展的代币使用量




图表 9

DeepSeek/字节跳动估值倍数不适用




图表 10

字节跳动 Seedance：模型性能领先，拥有强大的财务/生态系统支持，可实现快速采用与商业化



图表 11

图表 4：我们识别出两个有利的 ARR 象限（在最大化 ARR 方面），这是最大化代币量和/或定价水平的组合



图表 12

相关研究：公司情况更新

美洲科技：解码智能体宏观环境——AI 使用与利润率的即将到来的拐点，2026 年 5 月 5 日，作者 James Schneider、Eric Sheridan 及团队


全球服务器：上调 AI 与通用服务器预期；更好的组合与更高的内存成本推动 CSP 支出，2026 年 6 月 24 日，作者 Allen Chang 及团队

知识图谱科技 (2513.HK)：以 1100 亿美元估值更新公司观点；中国顶级企业/编程 AI 模型，2026 年 7 月 10 日

MiniMax 集团 (0100.HK)：股份解禁后的关键关注点；不确定性回报偏向上行；买入，2026 年 7 月 10 日


比较中国主要大语言模型厂商

性能：中国大语言模型实验室在文本竞技场排名中持续攀升，旗舰模型创下新高




图表 13

双层定价：模型智能的溢价定价 vs. 价格敏感型需求的低成本




图表 14

速度：第一方 API 性能反映推理效率与基础设施能力




图表 15

损益表：大型科技公司以稳定利润资助 AI，而独立厂商仍在商业化中扩大规模




图表 16

估值：大语言模型厂商的最新市值与已披露的私募估值



图表 17


进入 2026 年的模型更新：迭代加速，智能水平不断提升



图表 18


解码中国 AI 模型代币及我们对代币/收入份额的预测

到 2030 年，我们估计中国 AI 模型公司生成的代币量将是今天的 25 倍




图表 19

我们估计，到 2030 年，中国 AI 模型公司在海外生成的代币量将达到全球代币量的 55%




图表 20

我们预计，到 2030 年，字节跳动和 DeepSeek 将占中国 AI 模型公司生成代币量的 80%




图表 21

我们的美国研究团队估计，消费者和企业智能体可能将代币消耗推高至当前全球容量（除中国外）的 24 倍




图表 22

我们估计，到 2030 年，中国 AI API + 订阅收入池将达到 1250 亿美元



图表 23

我们预计智谱和 DeepSeek 将占据增量收入池的大部分



图表 24

DeepSeek/字节跳动/智谱（未覆盖）的相关指标（例如代币消耗/收入）是通过分析我们所覆盖的行业和公司，然后将其推算至 DeepSeek、字节跳动和智谱计算得出。

中国模型如何以低成本/紧张的计算资源实现有竞争力的性能？

更小参数规模的模型实现同等基准性能，混合专家模型与新型架构创新

与一年前相比，中国模型的编程和智能体能力已达到关键水平，能够以更高的成功率完成更多编程和自主智能体任务，上下文窗口已扩展至 100 万个代币。中国模型较小的参数规模（范围从 2000 亿到 1.6 万亿参数，仅为领先 SOTA 模型的 2-10%，原因是高端计算资源受限）以及高效架构（MoE、稀疏注意力、OCR 等，仅激活 3-5% 的参数 vs. 总参数规模），均有助于中国模型相比美国领先模型实现更低的训练和推理成本。我们认为，根据 Arena.ai 的数据，中国模型在编程方面的近期阶跃式改进可归因于数据整理、蒸馏技术和强化学习后训练，尽管其参数模型规模相对较小（DeepSeek V4 Pro 为 1.6T，智谱 GLM5.2 为 0.7T，MiniMax M3 为 0.4T）。6 月 27 日，DeepSeek 推出了 DSpark，这是一种推测解码框架，可使现有的 DeepSeek-V4 模型服务更快。DSpark 已部署在 DeepSeek-V4 Flash / Pro 在线服务中，在不改变模型权重或输出质量的情况下，使每位用户的 DeepSeek-V4 生成速度在 V4-Flash 上提升 60-85%，在 V4 Pro 上提升 57-78%。

中国 AI 模型正分化为双层市场（性能和上市时间对定价权至关重要），基于代币采用和定价形成两个“ARR 最大化”象限

我们看到，性能最高的中国 AI 模型具有定价权，例如智谱的 GLM5.2 模型和阿里巴巴的通义千问 3.7 Max 模型，其混合每百万代币价格约为 1 美元，是中国低端 AI 模型的 5 倍。据报道，美国在允许大多数 SOTA 模型访问方面流程趋紧，这也为中国顶级编程模型面向企业和中小企业开辟了新领域。较小的参数和激活比率使得中国顶级模型定价为 1 美元，仅为美国 SOTA 模型混合每百万代币 4-8 美元的 10-25%，同时产生两位数的 10-20% 毛利率（GS 估计），低于全球 SOTA 模型，原因是定价权相对较低。

在低端市场，专注于智能体的模型定价为混合每百万代币 0.06-0.2 美元，这使得这些模型能够进入对价格敏感的中小企业和一人公司的新全球 TAM。MiniMax 60-70% 的收入来自海外。

我们还注意到，DeepSeek 宣布其 V4 正式版将于 7 月中旬发布，同时引入高峰/非高峰 API 定价，以更好地分配资源并提高服务稳定性。V4 Pro/Flash 非高峰定价保持不变，而高峰时段（北京时间上午 9 点至中午 12 点/下午 2 点至下午 6 点）将按非高峰费率的 2 倍收费，这意味着混合


文本/网页开发（编程）竞技场排名的基准日期 = 2026 年 3 月 18 日，当前日期指最新可用日期，即 2026 年 6 月 16 日和 2026 年 6 月 20 日。智能体竞技场排名始于 2026 年 6 月 5 日，当前日期 = 2026 年 6 月 30 日

中国顶级 AI 模型的正向飞轮效应正在显现，源于实际编程采用量的增加，对模型蒸馏的依赖减少
4/9


与过去从全球 SOTA 模型学习及蒸馏策略不同，我们认为以 GLM5 为代表的顶尖中国模型正进入被中国大型企业和全球用户采用的关键阶段。据晚点 LatePost 报道，部分中国超大型公司中 AI 生成代码的比例已从 2025 年下半年的 20-30% 提升至高达 90%，我们认为这将通过利用实际用户数据（包括成功与失败的编程案例）进行强化学习及后训练，形成正向数据飞轮效应，推动模型进一步改进。我们认为这些因素支撑了 GLM5.2 在 2026 年仅数月内从 GLM5.1 实现的阶跃式提升，并预计未来 6-12 个月中国 AI 模型将迎来更多阶跃式进步。

图表5：在文本、编程及智能体等使用场景的顶级排名中，中国模型数量正在上升
LMArena 文本、WebDev（编程）及智能体竞技场排名

图表6：尤其在编程/智能体任务中，中国玩家正达到全球顶尖水平 截至2026年6月20日
中国AI模型在智能体基准排名（共52个模型）GDPval-AA v2 - 评估真实工作任务表现




图表 25



图表 26


图表7：与参数规模达数十万亿美元的全球SOTA领先模型相比，中国开源模型参数规模大多在1万亿左右或以下，并采用MoE结构，激活参数与总参数比率较低，以实现更高推理效率



图表 27

混合专家（MoE）结构是一种稀疏激活的神经架构，它动态选择一小部分专家网络处理每个输入，使模型能够在推理时不激活所有参数的情况下增加总容量。


图表8：混合LLM代币价格（SDLLMTK）自6月初以来持续下降，可能受性价比高的中国模型采用率上升推动每百万代币美元



图表 28

硅谷数据LLM代币支出指数（SDLLMTK）是衡量市场为运行前沿及开放权重模型推理实际支付价格的每日混合指标。

图表9：中美主要云服务提供商历史及预测资本支出 十亿美元



图表 29

图表10：中国超大规模云服务商的资本支出与运营现金流比率仍处于健康水平

我们通过分析所覆盖的行业及公司，并将其推算至字节跳动（未覆盖），来计算其相关运营指标。

美团LongCat 2.0案例研究：中国本土AI基础设施的里程碑

我们认为，于2026年6月30日发布的美团LongCat 2.0标志着一个重要里程碑，它是中国首个正式发布的1.6万亿参数开源混合专家（MoE）模型，完全在5万张国产计算集群上训练和部署。该模型专为智能体编程和复杂软件工程设计，具备由LongCat稀疏注意力（LSA）支持的原生百万token上下文窗口，每个token动态平均激活480亿参数以优化推理成本。对更自主、减少对外国高端芯片依赖的中国AI模型前景的影响：我们认为，在中国芯片上（据报道使用华为Atlas-950 SuperPods）成功端到端预训练和推理万亿参数级模型，从根本上推动了中国AI模型发展的更可持续前景。虽然此前中国旗舰模型（如DeepSeek V4-pro）提及使用国产芯片进行推理，但LongCat 2.0在计算密集的预训练阶段克服关键内存瓶颈和分布式稳定性挑战的能力，证明了未来AI模型训练采用更广泛、更本地化硬件栈的可行性。

图表11：阿里巴巴资本支出与收入转化比率 vs. 亚马逊和谷歌
滚动12个月增量云收入/滚动12个月资本支出（滞后1个季度）

资本支出与收入转化率 我们将阿里巴巴外部云收入增长与谷歌和亚马逊云（滞后约2年）进行对标

图表12：中国互联网年度资本支出预测 百万美元

对于字节跳动（未覆盖），我们根据行业趋势推算其资本支出。

为何中国模型追求开源/开放权重方法，以及变现方式？

开源允许模型训练/部署具有更高灵活性，并实现最广泛采用和开放社区

阿里巴巴的Qwen模型家族长期追求开源方法（在采用闭源方法用于其最大且性能最高的Qwen-Max模型以更好变现之前），而其他主要中国AI模型玩家大多采用开源/开放权重方法，包括DeepSeek、智谱GLM和MiniMax M3系列模型，但字节跳动对其Seed模型采用完全闭源专有方法除外。我们认为开源方法在模型训练地点（从而决定训练后模型可在中国大陆内外部署的地点）方面提供了最高灵活性。开源方法还允许AI社区最高程度的采用，模型参数/架构完全透明以建立信任，并通过开放社区推动更多用户反馈，从而促进模型迭代/改进。与全球领先的闭源/专有方法相比，开源方法也为全球AI用户提供了另一种选择，尤其是当性能最佳的闭源模型因溢价定价而具有更严格的用户访问权限和更高成本时，特别是在“代币最大化”已成为许多企业关键成本考量之际。

开源模型披露的ARR可能低估了总部署和收入潜力

虽然开源模型公司提供自己的编码计划和收费的开放平台API渠道（模型公司在此进行自己的模型推理），但大多数开源模型也允许个人/第三方超大规模云服务商/新云提供商免费部署模型，甚至用于商业用途（例如，阿里云百炼MaaS平台可托管GLM5.2开源模型，无需向智谱支付费用/抽成）。因此，尽管智谱最近公布的2026年底ARR目标为10亿美元，但我们认为GLM5.2模型在全球的实际部署量将是智谱自身API渠道代币量和收入的数倍甚至更高。此外，越来越多的中国AI模型被全球公司重新品牌化后进行后训练（例如Composer 2等），由于开源精神，这些中国AI模型不一定能获得任何收入。

我们预计未来中国AI模型将更多转向开放权重（附带社区许可）方法

5/9

虽然智谱的开源GLM模型采用MIT许可证，允许所有使用场景免费（无论是否产生收入），但MiniMax的M系列模型采用了限制性许可证（行业术语称为开放权重+社区许可证模式），要求商业使用时获得MiniMax的同意并签订商业条款（例如收入分成/抽成）。我们认为，这很可能成为中国AI模型行业其他开源模型未来的发展方向，以便推理token的最终毛利润能够覆盖训练成本，并使每家AI模型公司都能实现可持续的回报路径。

图表13：不同开源许可证对比

什么是API平台服务？

中国AI模型通常通过订阅计划或自有的API平台服务实现商业化。API访问通常通过OpenRouter、Cline或编码代理平台等第三方平台提供。随着我们预期更多开源模型可能转向开放权重，我们认为中国AI模型公司的单位宏观环境效应可能改善，因为不仅官方API渠道可以实现商业化，而且当这些开放权重模型在AWS Bedrock、阿里云百炼等第三方新云/超大规模云平台上部署和销售时，还可以通过收入分成协议获利。此类安排可能带来极高的利润率增长，因为AI模型公司无需自行承担推理/计算成本。

图表14：客户可通过其访问中国AI模型的API平台国际企业客户

国内和国际的关键可寻址市场及主要不确定性是什么？

我们估计，随着模型智能的提升，特别是近期如GLM5.2等模型达到全球采用的关键节点并具备有吸引力的定价，中国AI模型的API+订阅总收入将从2026年预计的350亿元人民币增长至2030年的8790亿元人民币。我们对中AI模型收入池的估算意味着，中国AI模型每日token消耗总量将从2026年预计的350万亿，增长至2030年的4600万亿。

我们预计到2030年，国内市场的token增长将达到25倍；编码领域将趋于整合，而代理型/低端细分市场可能保持分散

根据国家统计局数据，2026年3月全国每日token量为140万亿，到2026年6月将达到数百万亿级别，我们估计开源/开放权重模型约占30%的token份额（相比之下，仅字节跳动一家就占70%的token市场份额，其模型为闭源，主要由其豆包应用的企业和个人用户群驱动，豆包是中国排名第一的AI聊天机器人）。我们预计，与美国类似，

编码细分市场（定价较高）将继续由最先进的模型主导。与此同时，我们预计专注于代理型AI的低端细分市场将保持分散，参与者众多，因为AI模型公司/大型科技公司的财务实力将支撑低端细分市场更长时间的价格战。

国际化（走向全球）将是关键的上行因素；尤其是在非美国市场，存在更高定价和全球普及的潜力

我们的美国研究团队估计（链接），到2030年，代理型AI将推动token消耗量从2026年增长24倍，达到每月120万亿（即每天4万亿，而目前估计为每天170万亿）。最大的驱动力来自企业代理（55倍增长）和消费者代理（12倍增长）。全球（除中国外）市场，中国AI模型的token份额已显著增长，因为模型智能的提升和有吸引力的token成本推动了在24/7 Hermes/Claw/生产力代理中的更高采用率，并促使全球中小企业转变观念，开始使用中国模型来管理token成本，因为中国模型在智能/性能方面已达到“足够好”的阶段。

从“token最大化”转向以ROI为中心的指标，例如每日活跃代理/代理工作单元

我们认为，AI

tokens的普及正在经历范式转变，从“token最大化”（2025年底至2026年初的初始关注点，企业将高AI token消耗直接等同于组织生产力）转向“ROI优先”模式，该模式优先考虑清晰的任务边界和产出，而非原始计算量。

- “token最大化”已被归因于企业效率低下和成本超支：来自Jellyfish AI工程趋势研究的数据显示，企业中重度AI用户消耗的token量是普通用户的10倍，但产出仅增加2倍。同时，我们注意到，多家美国互联网公司在2026年4月曾表示，其工程团队在使用代理产品后，仅四个月就用完了全年的AI预算（从而促使对每个工具实施更严格的月度上限），或者更改了内部token使用排行榜，该排行榜此前错误地激励员工启动低效/低价值的自主代理任务。

\- 企业框架正在转向ROI优先模式，该模式优先考虑清晰的任务边界、每日代理数量、后端流程自动化和实际产出，而非纯粹的计算token量。除了中国AI模型采用率显著增加外，全球企业已将默认模型降级为更便宜的快速模型，用于更常规的任务（同时将最先进的模型仅保留给最具价值创造的任务，如编码/编程）。我们看到，指标正从单纯的token追踪转向每日活跃代理和代理工作单元，并认为每任务总成本将变得比每token价格指标更具相关性。

开源/开放权重方法允许美国超大规模云服务商托管中国模型，并在美国云生态系统内运营

Alphabet和亚马逊（均由Eric Sheridan覆盖）各自的云服务Gemini Enterprise Agent Platform（通过其Model Garden）和AWS Bedrock已提供广泛的中国AI模型选择，包括DeepSeek、MiniMax、Moonshot、GLM和Qwen，这些模型由美国超大规模云服务商完全管理。除了模型层，在应用层面，值得注意的是微软（由Gabriela Borges覆盖）CEO近期在《华尔街日报》采访（链接）中的言论，他表示微软正在考虑在Copilot上托管DeepSeek的版本，作为可选的宏观环境高效模型，这可以使其客户在拥有美国专有模型的同时，获得更便宜的选择。微软表示，如果托管DeepSeek，该模型将在其云生态系统内运行，确保客户数据留在Azure内部。

鉴于中国AI模型进入西方市场，需注意任何潜在的地缘政治政策收紧不确定性。

“走向全球”机会的主要不确定性将取决于终端市场准入（尤其是在西方国家，并重点关注计算/数据存储地点）、用于AI模型训练的高端计算资源获取（可能影响中国模型的迭代速度和成本结构），以及对中国AI模型公司的限制可能影响供应商关系/美国公司准入和/或美国资本准入。更多内容见主要不确定性部分。

图表 15：根据 OpenRouter 数据，中国 AI 模型目前在不同任务中的支出占比仍然有限 截至 2026 年 7 月 1 日开始的一周

图表 16：中国 AI 模型凭借价格竞争力，尤其在长时编程/代理任务中，已占据大部分 Token 使用量 截至 2026 年 7 月 1 日开始的一周

图表 17：Token 消耗正集中于编程/技术等复杂、高价值场景 按用例划分的 OpenRouter Token 消耗占比 ■ 编程 ■ 技术 ■ 法律 ■ 资金 ■ 翻译 ■ 其他

谁最有可能成为长期赢家？介绍我们的竞争定位框架

我们预计，拥有最大 ARR 规模、毛利率优势及财务实力的参与者将成为长期赢家。

ARR 规模 x 毛利率优势 + 财务实力

- 最大 ARR 规模（Token 规模 x 定价能力）
- 毛利率优势（训练与推理效率、技术）
- 财务实力（资产负债表、算力获取能力）

据此，我们基于定价能力、成本优势和财务实力，并结合 Token 规模与市场份额进展，推出了中国 AI 模型竞争定位框架，并认定智谱（Zhipu）和 DeepSeek（私有）在基础模型领域，以及字节跳动（私有）在多模态能力领域，定位最为强劲。

基础模型：公司情况更新

我们从各主要参与者的旗舰基础模型评估其竞争定位，从三个方面进行评分：定价能力、成本优势和（公司）财务实力，每个方面又进一步基于细化的量化指标构建。

图表 18：AI 模型参与者竞争定位框架

图表 19：主要大模型实验室定位竞争分析概览

- 阿里巴巴 通义千问：拥有多年 AI/云业务增长前景的全栈 AI 参与者，在大多数领域处于领先地位
- 腾讯 混元：AI 战略调整后的有力竞争者；在微信 AI 代理方面具有潜力
- MiniMax M 系列：独立参与者中独特的全模态能力；成本高效的算力架构
- 智谱 GLM：在编程/代理场景中领先的模型能力
- DeepSeek 估值倍数不适用
- DeepSeek：极致的成本效率，以在竞争性定价下维持可扩展的 Token 使用量

定价能力：公司情况更新

上市时间：我们从参与者多快、多有效地交付具有前沿竞争力的模型来评估这一点。通过比较公司旗舰模型与其上一代及其他同等性能水平模型的发布时间，我们旨在评估该版本是否相较于其过去版本实现了有意义的能​​力跃升，以及是否缩小了与当前全球 SOTA 模型的差距。

- 竞技场得分（整体文本）：我们将模型智能视为定价能力的主要决定因素，因为能够处理更高价值任务的模型可以带来更清晰的 ROI，从而维持其定价溢价。我们使用 LMArena 的得分而非任何静态基准，因为它反映了大规模盲审用户评价，是对真实世界能力更客观的解读。
- 定价（混合，每百万 Token 美元）：我们还参考旗舰模型的实际标价（涵盖输入/输出/缓存输入），其中通过迭代维持较高定价表明定价能力更强，而降价则可能表明更倾向于以量取胜的策略。

图表 20：国内主要 AI 模型文本竞技场得分 截至 2026 年 6 月 图表 21：主要参与者模型加权定价（每百万 Token 美元）

成本优势：结构性的服务成本（即推理成本），为价格和利润率设定下限

我们参考以下指标作为推理效率的代理变量

- 吞吐量（Token/秒）：以单个 GPU 每秒生成的 Token 数量衡量。GPU 每秒输出的 Token 越多，固定的每小时算力成本就被摊得越薄。因此，吞吐量是推理效率的强有力指标，其取决于模型架构（稀疏性与注意力设计）和服务效率（批处理与利用率）。
- 缓存命中率（%）：从缓存而非重新计算提供的输入 Token 占比。在对话和代理 workflows 中，大量输入在多次调用中重复出现，因此模型可以从缓存内存中读取这些 Token，而无需根据新输入重新计算。更高的命中率可降低计算量，并且尽管缓存 Token 以折扣价计费（比输入成本便宜 10-100 倍），但其服务成本几乎为零，因此也能提升利润率。
- 参数量/激活比率：每个 Token 激活的总参数占比（适用于开源 MoE 模型），在给定性能水平下，激活参数越少，每个 Token 的 FLOPs 就越少，推理成本也就越低。我们也会关注绝对参数量，因为计算量随这个自由度而扩展。
- 推理 GPM（若披露，或 GS 基于总参数量/激活参数量的估算）：模型 API 的实际毛利率，其中约 90% 的销售成本为推理成本，是成本效率的直接体现。

图表 22：主要参与者模型吞吐量（Token/秒） 单位时间处理能力，代表模型写入速度 截至 2026 年 6 月 图表 23：主要参与者模型缓存命中率 从缓存内存而非新输入提供的请求占比，越高表示成本/速度表现越好 截至 2026 年 6 月 图表 24：主要参与者模型激活参数与总参数比率 每个 Token 激活的参数占比；在相同性能下，越低意味着推理成本越低 闭源模型（阿里巴巴的通义千问和字节跳动的 Seed）参数数据不可用；截至 2026 年 6 月

财务实力：在盈利能力好转前持续为前沿研发和训练提供资金的能力

- 在手现金及净现金/债务占资产百分比：我们使用总在手现金作为资产负债表实力的衡量标准，并使用净现金占总资产百分比来对不同规模的参与者进行标准化。我们认为，大型科技公司（相较于独立参与者）拥有更多资源来积累算力、资助多模态探索并推动更快速的产品分发。
- 估值倍数：对于独立参与者，我们使用 2026 年预期市销率（P/ARR），因为它们尚未盈利，P/ARR 是衡量业务规模和未来变现潜力的更具可比性的指标；对于大型科技公司，我们使用 2026 年预期市盈率（P/E）。

图表 25：主要参与者在手现金（人民币十亿元）

图表 26：主要参与者净现金占总资产百分比 截至 2026 年 7 月

图表 27：阿里巴巴、腾讯和小米的净现金估算（人民币十亿元，GS 预测）

图表 28：主要参与者估值倍数 大型科技公司按市盈率估值，独立参与者按市销率估值，2026 年预期 阿里巴巴、腾讯和小米使用市盈率；MiniMax 和智谱使用市销率；数据截至 2026 年 6 月 26 日 图表 29：独立 AI 参与者累计外部私募融资（实际）及 GS 预测的 2026 年底净现金（人民币十亿元）

DeepSeek 在手净现金不适用


多模态生成模型

7/9

我们采用类似框架，从三个维度评估视频生成玩家（字节跳动、阿里巴巴、快手和 MiniMax）的竞争定位：定价能力、成本优势和财务实力，每个维度均基于更详细的指标构建。

图表30：中国AI视频模型ARR最新披露（百万美元）

中国视频模型ARR（百万美元）




图表 30

图表31：多模态生成玩家竞争定位框架

CHINA AI MODEL & HYPERSCALERS ECOSYSTEM

Our mapping of key players, revenue/profit pools & interdependencies




图表 31

图表32：关键多模态实验室定位竞争分析概览

字节跳动：模型性能领先，拥有强大的财务/生态系统支持，可实现快速采用与商业化

阿里巴巴：资源丰富，支持快速迭代以追赶性能/功能供给

快手：优先服务企业与专业用户，定价能力强，变现路径更清晰，支撑更可控的回报表现率



图表 32

MiniMax：原生多模态训练（文本+视频），在成本效率与能力上实现协同，预计H3发布是关键催化剂

字节跳动（未覆盖）的相关指标通过分析我们覆盖的行业和公司计算得出，然后外推至字节跳动。字节跳动的估值倍数不适用。

定价能力：公司情况更新


上市时间：衡量玩家交付前沿竞争模型的速度和有效性。通过比较公司旗舰模型与其上一代及同等性能水平其他模型的发布时间，我们旨在评估该发布是否相比上一代实现了有意义的能力跃升，以及是否缩小了与当前全球SOTA模型的差距。

Arena评分（文本生成视频与图像生成视频的平均分）：我们将模型智能视为定价能力的主要决定因素，因为更强的生成模型能处理更高价值的任务/商业工作，并提供更清晰的ROI。我们使用LMArena评分而非任何静态基准，因为它反映了大规模盲测用户评价，是对真实世界能力更客观的解读。

■ 功能多样性：反映模型的生成质量和可及性，我们进一步考察：1) 原生音频（是/否）：模型是否直接输出与画面匹配的音频，而非需要叠加单独的语音/音频模型；2) 最大时长：模型能生成单段视频的最长时间；3) 最大分镜数：模型在一个片段内能生成的不同镜头数量，暗示其维持叙事连贯性的能力；4) 最大多模态参考输入数：用户可输入除文本提示外的多少参考材料（图像或视频片段）来引导生成。


\- 定价（文本生成视频，1080p，不含音频，美元/分钟）：我们还参考了旗舰模型的实际标价，持续的高定价伴随迭代意味着更强的定价能力。

图表33：关键玩家视频Arena评分 文本生成视频与图像生成视频的平均分 截至2026年6月



图表 33

图表34：关键玩家功能多样性
原生音频（是/否）、最大时长（秒）、最大分镜数及最大参考输入数（图像/视频，超出文本提示）



图表 34

图表35：相同设置下关键玩家API定价 美元/分钟



图表 35

字节跳动Seedance 2.0数据点为720p视频生成（默认设置），其他条件相同，数据来源：Artificial Analysis

成本优势：公司情况更新

■
生成速度：生成一段5秒1080p片段所需的秒数，速度越快表示单位算力利用率越高，每段视频推理成本越低。

图表36：关键玩家生成速度 秒，数值越低越好



图表 36

截至2026年7月初

财务实力：公司情况更新

\- 在手现金及净现金/债务占资产百分比：我们使用总在手现金衡量资产负债表实力，并用净现金占资产百分比对不同规模的玩家进行标准化。我们认为大型企业（相比单一玩家）拥有更多资源来积累算力、资助多模态探索并推动更快的产品分发。

生态系统支持：玩家生态系统内的客户获取和分发渠道（包括内容平台、编辑工具和MaaS），字节跳动和快手等平台公司在加强企业商业采用和消费者流量获取方面具有优势，从而推动其数据飞轮。

估值倍数：对于MiniMax和快手（Kling AI投后隐含估值为180亿美元，见我们团队的分析），我们使用2026年预期P/ARR倍数。

图表38：关键玩家生态系统支持与估值倍数 P/ARR倍数，截至2026年末



图表 37

主要上行与节奏变化不确定性

上行不确定性

■ 自持正向飞轮带来超预期的模型智能提升：编码和多模态性能的突破，实现文本、图像和音频的无缝集成与理解，将解锁新应用、物理AI和AGI潜力。

\- 盈利可见性路径快于预期：如果中国AI模型公司更快转向开放权重（从纯开源），并展现出卓越的运营效率，例如优化模型推理成本和训练基础设施，或多元化变现渠道以更快实现更高收入增长或更优单位宏观环境，将加速实现正现金流和净利润的时间线。早期盈利能力将增强读者对AI模型行业的信心，可能减少未来外部融资需求。

■ 额外的非推理抽成收入流：如果中国AI模型公司能够训练并达到SOTA模型性能，采用开放权重方式，对托管这些模型并向客户销售的云服务商/超大规模云平台收取抽成/收入分成，可能将AI模型公司的商业模式转变为高毛利率业务（无需为每个售出的token进行推理，而是通过销售顶级中国模型的平台收入分成获利）。

■ 超预期的商业化能力：新应用、代码和协作者平台的增长，加上“数字员工”代理模型，可为收入生成提供多种渠道。如果这些渠道实现高于预期的采用率、转化效率或ARPU，中国AI模型可能超越当前收入预测。

节奏变化不确定性

\- 全球基础模型行业的竞争，对比美国/中国科技巨头：中国AI模型在全球基础模型行业中运营，该行业竞争激烈且快速演变，不确定性包括难以跟上快速的技术进步、频繁的新产品推出以及动态变化的客户需求。若未能以宏观环境高效且及时的方式调整产品并大力研究研发，可能导致竞争力下降。此外，市场机会尚处早期阶段，使得客户需求难以预测，无法满足用户需求将面临失去现有用户的不确定性，并对收入产生不利影响。

因高研发支出导致近期盈利可见度有限：中国AI模型公司在近期内实现并维持盈利可能面临挑战，因为成功取决于持续的技术开发、用户体验改善和有效的商业化。若未能管理不断攀升的成本并产生足够的收入，可能对公司的财务状况和盈利能力产生重大影响。

知识产权/内容生成相关不确定性：中国AI模型，尤其是多模态生成模型，面临生成不当内容的不确定性。与其他AI应用遇到的挑战类似，例如针对Character AI聊天机器人涉嫌与青少年安全问题相关的诉讼，图像/视频生成模型可能面临声誉损害和潜在诉讼。稳健的内容审核和合乎道德的AI开发对于防止不良输出和确保安全的用户体验至关重要。中国公司还可能面临第三方知识产权/蒸馏方法侵权的索赔不确定性，这些不确定性既来自用于训练模型的数据，也来自模型生成的内容。

现金消耗/自我造血能力：先进AI模型训练所需的巨额资本，加上竞争对手快速的技术进步，可能给相对分散的中国AI模型格局带来融资不确定性。此外，任何未能跟上领先同行步伐的模型，都可能难以产生足够的收入（ARR x 推理毛利率）来覆盖训练成本。

中美科技竞赛加剧背景下的地缘政治不确定性：美国对中国AI模型的任何使用限制都可能限制其市场准入和采用，如果中国AI模型公司被禁止使用美国云服务提供商进行模型训练，或被列入任何限制采购美国硬件到软件等物资的清单，其成本也可能增加。全球芯片供应动态的演变也构成了关键的供应链不确定性。

MaaS ARR目标（十亿人民币）

中国主要AI玩家概览

科技巨头：公司情况更新

图表 39：阿里巴巴

阿里巴巴：全栈AI玩家，拥有多年AI/云业务增长潜力，在大多数领域处于领先地位
AI相关/MaaS收入快速增长，对云业务增长加速和利润率扩张的贡献日益增加
竞争定位：在模型性能和资金实力方面具有定价权领先优势

AI相关产品收入/对外部云的贡献
持续的AI研究继续巩固在云/AI基础设施领域的领导地位，同时逐步转化为收入
资本支出与收入转化比率

中国AI云市场份额（2025年）

图表 40：字节跳动

字节跳动：拥有强大消费者基础和产品组合，为广泛AI探索提供深厚资源

在Token消耗增长和消费者采用方面领先
多模态竞争定位：Seedance凭借强大的财务/生态系统支持实现卓越性能，可快速采用和商业化
中国Token消耗激增，由字节跳动引领，万亿
豆包达到1.5亿+日活跃用户，成为中国最受欢迎的AIGC应用
AI资本支出快速增加，视频模型（主要面向企业）逐步贡献收入：Seedance年化运行率20亿美元

字节跳动（未覆盖）的竞争定位指标是通过分析我们覆盖的行业和公司，然后将其推算至字节跳动得出的。竞争定位图中的估值倍数不适用。

图表 41：腾讯

腾讯：AI战略重组后的有力竞争者；微信AI代理潜力巨大

竞争格局：资金实力最强，成本效率相对领先

代理产品快速扩张：腾讯元宝（WorkBuddy）在桌面办公代理中月访问量国内第一，面向消费者的微信代理是下一个催化剂

腾讯元宝在用户满意度和流量增长方面均领先于中国PC原生办公AI代理

AI资本支出增加（2026年AI相关支出至少达到360亿人民币），但相对于强劲主营业务带来的不断增长的现金储备，仍只占一小部分

图表 42：小米

小米：推动大语言模型效率前沿；在面向消费者、面向企业和物理智能领域拥有丰富的应用场景

2026年上半年Token使用量激增27倍；AI变现策略正在成型

MiMo API Token使用量在2026年6月较1月扩大27倍

面向消费者变现

- \- AI驱动的操作系统
- \- 通过流量、广告、电子商务等方式变现

面向企业变现

- \- Token计划 - 编程和企业生产力

物理智能：公司情况更新

- \- 通过Miclaw和Miloco实现AIoT生态系统协同
- \- 机器人
- \- 智能驾驶

MiMo-V2.5系列在成本（MiMo-V2.5）和速度（MiMo-V2.5-Pro-Ultraspeed）方面实现差异化

全栈自研能力与跨层协同

主要独立AI玩家

图表 43：智谱

智谱：在编程/代理场景中具有领先的模型能力

AI路线图侧重于基础模型迭代和编程/代理能力

竞争定位：在运营效率和编程模型智能方面领先，智谱认为这决定了定价权

顶尖的编程/代理模型性能支持持续的价格提升

LMarena文本到文本任务排行榜，涵盖数学、编程、创意写作等

GLM系列API和订阅定价年初至今随新模型发布呈上升趋势

3月底ARR年化运行率为2.5亿美元（同比增长60倍），目标到2026年底达到10亿美元，基于更高的定价和Token消耗

通过持续效率改进实现具有竞争力的混合定价

图表 44：DeepSeek

DeepSeek：极致的成本效率，以在竞争性定价下维持可扩展的Token使用量

竞争定位：强大的架构创新以最大化成本效益

极致的效率转化为低价格和持续的Token使用份额

2026年6月首次外部融资，投后估值4000亿人民币，得到强大产业读者的支持 DeepSeek（未覆盖）的竞争定位指标是通过分析我们覆盖的行业和公司，然后将其推算至DeepSeek得出的。DeepSeek最新融资轮次基于路透社报道。

图表 45：MiniMax

MiniMax：在独立玩家中拥有独特的全模态能力；成本高效的算力架构

全模态产品矩阵与路线图，长期目标为统一多模态模型

API毛利率超过60%，其中高毛利的多模态业务贡献显著，纯文本模型毛利率约40%，且API定价远低于行业水平

竞争定位：在独立厂商中，多模态产品能力与成本效率优势突出

4月ARR年化收入达3亿美元（较2月翻倍），目标2026年底前突破10亿美元，其中API+Token计划收入占比超过50%

MiniMax API毛利率达到60%以上（高毛利多模态模型贡献积极）

文本模型毛利率约40%（据MiniMax数据），API定价显著更低

公司情况更新

公司情况更新

估值方法：我们对BABA/9988.HK更新公司观点。

主要不确定性：（1）宏观/竞争导致GMV增长不及预期；（2）中国零售业务变现速度慢于预期；（3）关键战略研究执行弱于预期；（4）云业务收入增速节奏变化。

公司情况更新

估值方法：我们对腾讯（0700.HK）更新公司观点。

主要不确定性：效果广告行业竞争加剧、游戏上线/版号审批意外延迟、资金科技与云业务增长节奏变化、AI发展进度慢于预期、再研究不确定性。

公司情况更新

我们对小米更新公司观点，基于SOTP估值方法：1) 小米核心业务按16倍目标12个月远期EV/NOPAT估值；2) 小米汽车按DCF估值420亿美元（WACC 12%，终值增长率3%）；3) 控股公司折价10%。主要节奏变化不确定性：1) 全球智能手机行业竞争加剧，市场份额增长仍在调整；2) 智能手机/汽车业务毛利率不确定性增大；3) 小米品牌高端化及汽车业务执行不及预期；4) 地缘政治不确定性与监管不确定性加剧；5) 宏观环境疲软，智能手机/IoT需求走弱；6) 汇率波动。

公司情况更新

我们对MiniMax更新公司观点。估值基于DCF模型，WACC为12%，终值增长率为2%。

主要不确定性：全球基础模型行业竞争下模型性能不及预期；盈利可见性路径慢于预期；商业化能力弱于预期；知识产权/内容生成相关不确定性；现金消耗/自我造血能力；中美科技竞赛加剧背景下的地缘政治不确定性。

公司情况更新

估值方法：我们对快手更新公司观点，基于市盈率估值（目标市盈率15倍，应用于2026E-27E平均每股收益）。

主要节奏变化不确定性：1) 广告预算恢复慢于预期；2) 可灵商业化弱于预期；3) 用户总参与度基数（日活×人均使用时长）增长慢于预期；4) 盈利能力低于预期；5) AI进展不及预期。