

KC桌面——外资精译

GS：小米AI日处理67万亿token，市场或低估其能力

7月10日，小米向中国工业和信息化部（MIIT）申报了其第二款NEV系列车型——SkyNomad N70和N90。该系列定位为智能、可配置且空间宽敞的SUV，可满足除家庭/商务需求之外的多种使用场景，并迎合与SU7/YU7（注重驾驶动态）不同的消费者需求。

这开启了我们在《场景设定》报告中讨论的、催化剂密集的第三季度，我们认为从叙事和财务两个角度来看，这可能为报价提供潜在的转机机会（本季度至今报价上涨19%，对比恒生科技指数上涨6%）。具体而言，我们强调

■ 多种互补车型以应对更广泛的需求：我们认为SkyNomad N90是旗舰长轴距5/7座车型，而SkyNomad N70是标准轴距5座车型，面向小家庭，注重城市灵活性，旨在提供高性价比的智能出行体验。尺寸方面，SkyNomad N70与理想L6/L7、赛力斯AITO M6/M7相当，而N90则与理想L9、赛力斯AITO M9、极氪9X等车型相当。此外，SkyNomad N90 Max提供了创新的可选功能，如内置车顶帐篷，可将SUV变成大型露营车（图表3）。

长续航支持，吸引燃油车消费者的关键价值主张：SkyNomad搭载大容量电池（N70为52/76千瓦时，N90为76千瓦时），可实现265-370公里的续航里程，是同级别车型中纯电续航最长的，并配备由哈尔滨东安汽车发动机制造有限公司（600178.SS，未覆盖）提供的1.5T、112千瓦增程器。尽管电池容量更大，但SkyNomad的车重与同级车型相当，我们部分将其归因于小米创新的EREV前舱左右分体式布局，以增强结构安全性和空间利用率，同时通过轻量化降低整车功耗。

\- 智能且完全可配置的内饰，新制造平台上的一个令人耳目一新的特点：据管理层称，包括功能和使用场景在内的内饰配置是SkyNomad车辆设计的出发点。SkyNomad采用带有滑轨的纯平地板，不同设备可在滑轨上滑动，实现无缝、智能的内饰空间变换。小米展示了多种配置（图表4），包括可平躺的床、工作站、两人会议设置以及围绕中央桌子的四个座位等可能性。

我们还在关注什么？我们预计SkyNomad将在8月底前正式发布，并认为以下因素对其成功至关重要。1) 其可配置内饰和EREV系统的机械耐久性；我们对小米过去两年广泛的路测以及领先的智能制造能力充满信心；2) 与小米AIoT生态系统的集成；3) 发布前后的公关/营销策略和竞争；4) 订单势头与制造能力提升之间的平衡；我们认为小米已增强了在初始发布时平滑峰值订单并在初始发布后维持健康订单量（例如SU7新改款）同时扩大制造产能的能力。

GSe预计2026年销量24万辆，牛市情景下为50万辆：正如我们之前的报告所述，我们预计小米可能会将SkyNomad N70定价在具有竞争力的水平作为销量锚点，以凭借供应链能力和更有利的电池成本抢占入门级高端市场（例如起售价20万元人民币以上），同时为更高端互补车型和功能（例如N90高达40-50万元人民币）提供广泛的定价范围，以与同行建立高端价格对标。我们预测SkyNomad在2026/2027年的交付量为11万/24万辆，2027年销量相当于2025年售价20-40万元人民币的160多万辆SUV（不含纯电动车）销量的15%（图表6）；在我们的牛市情景中，如果小米能够从大众市场抢占部分消费升级/燃油车需求，基于2027年售价10-40万元人民币的500万辆SUV（不含纯电动车）销量的10%，我们预计潜在销量可达约50万辆。

除了电动汽车，我们对小米近期在人工智能方面的发展充满信心，我们认为市场低估了这一点。我们估计，MiMo目前的日处理token量可能已达到约6-7万亿，主要由编码和智能体任务驱动。虽然MiMo凭借推理工程优化（例如，MiMo-V3可能采用更激进的11:1稀疏率）继续在推理成本方面推动大语言模型的效率边界，但V2.5-Pro-UltraSpeed版本也展现出定价能力，该版本在标准商用硬件上提供1000 TPS的吞吐量，对每百万输入（缓存未命中）/输出token收费1.3/2.6美元（仅比GLM-5.2和Qwen3.7-Max便宜）。尽管如此，我们认为小米在大语言模型行业中的定位与纯大语言模型公司不同，其人工智能货币化战略正在面向消费者、面向企业和物理世界逐步成型（详见我们的《场景设定》报告）。

SkyNomad：智能、可配置且空间宽敞的SUV系列

图表1：与小米SkyNomad可比的车型

图表2：小米SkyNomad N90外观设计



图表 1

来源：公司数据 图表3：小米SkyNomad N90 Max配备内置弹出式车顶帐篷




图表 2

来源：公司数据

图表4：SkyNomad提供可配置布局，可用作工作室、咖啡馆、会议室和客厅

SkyNomad完全可配置布局




图表 3

来源：公司数据

图表5：2025年售价20-40万元人民币的SUV车型销量为320万辆， 占中国SUV/汽车零售量的27%/13%

图表6：我们预计小米的第三款电动汽车将瞄准中国SUV市场总量（不含纯电动车）， 该市场包括售价10-40万元/20-40万元的500多万/160多万辆车型 2025年售价10-40万元车型按细分市场划分的销量

图表7：2026年1-5月， 小米SU7/YU7车型占中国售价20-30万元轿车/SUV市场的15%/12%
小米SU7/YU7出货量及份额




图表 4

4月2日突破1万亿，6月月度API请求量较1月增长27倍，较4月增长6-7倍（图表8）；假设API调用与token消耗基本呈线性关系，我们估计MiMo日token消耗运行率约为6-7万亿。第三方统一API及市场平台（如OpenRouter）

也呈现类似增长轨迹，MiMo在该平台的日均token消耗量6月增至6000亿（较4月增长4倍，约占GSe估算MiMo总token消耗量的10%），平台token份额6月升至约9%，主要由编程和智能体任务驱动（token份额分别为13%/10%）。

图表8：小米MiMo API请求量6月较1月增长27倍，较4月增长6-7倍



图表 5


资料来源：公司数据

图表9：MiMo在OpenRouter上的token份额6月升至约9%




图表 6

图表10：编程和智能体任务占MiMo-V2.5在OpenRouter上token使用量的近80%
OpenRouter最新token使用量分布（蓝色=编程，绿色=智能体）



图表 7

图表11：MiMo-V2.5在OpenRouter的编程和智能体任务中token份额更高
按模型划分的OpenRouter最新token使用量分布



图表 8

处于LLM成本效率前沿：尽管6月API请求量较1月增长27倍，但据公司称，同期使用的推理芯片数量仅增长3倍，这得益于推理工程优化，特别是混合SWA（滑动窗口注意力）技术，该技术将注意力计算复杂度降至近乎线性，同时仍保持建模长距离依赖的能力。据中国开源软件推进联盟认定，MiMo与DeepSeek并列为国内推理成本


最低的模型，MiMo已通过成本

图表14：中国主要大语言模型输入和输出价格（每百万token美元）


效率（例如有效KVCache容量提升近5倍，服务端缓存命中率平均93-95%）惠及开发者，于5月宣布永久性降价最高达99%，降至全球最低水平。

MiMo-V2.5-Pro-UltraSpeed展现定价能力：该模型吞吐量达1000 TPS（仅需标准商用硬件，即单节点8 GPU），定价为标准V2.5-Pro费率的3倍（其1.3美元/2.6美元的输入/输出价格仅低于GLM-5.2和Qwen3.7-Max，图表14），同时绝对吞吐量提升10倍。MiMo于6月23日宣布延长V2.5-Pro-UltraSpeed测试版访问权限，此前在不到1个月内收到超过6.6万份使用申请。


图表12：与其他中国大语言模型相比，MiMo-V2.5系列在成本（MiMo-V2.5）和吞吐量/速度（MiMo-V2.5-Pro-Ultraspeed）方面具有差异化优势




图表 9



图表 10




图表 11




图表 12

图表13：基于OpenCode数据， MiMo在同行中提供相对较高的缓存命中率，这是降低推理成本的关键因素



图表 13



图表 14

■ 更具成本效益的MiMo-V3系列正在开发中：据公司在2026年国际机器学习大会（ICML）上透露，即将推出的V3模型将采用HySparse（混合稀疏注意力），这是小米大语言模型核心团队于2026年2月引入的新架构，使稀疏注意力层能够复用全注意力KV缓存，从而减少计算量和内存占用。与V2/V2.5的7:1稀疏率相比，MiMo-V3可能采用更激进的11:1稀疏率，意味着有望进一步推动效率前沿并降低推理成本。

研究论点 - 小米集团

我们认为，小米作为全球第三大智能手机品牌及领先的消费级AIoT/智能电动汽车平台，在其"人车家全生态"战略背景下，仍处于多年生态系统扩张的早期阶段。长期来看，我们相信小米稳健的资产负债表、强大的生态系统整合能力，以及因规模和深度参与电动汽车供应链而获得的成本优势，将提升其在电动汽车领域的竞争力和吸引力，且小米具备利用其互联消费终端构建全球最大消费级物理智能生态系统之一的有利条件。我们更新公司观点。

公司情况更新

我们对小米更新公司观点，基于分部加总估值方法：1) 小米核心业务16倍目标12个月远期EV/NOPAT；2) 小米电动汽车业务基于DCF估值为420亿美元（WACC 12%，TGR 3%）；3) 10%控股公司折价。主要节奏变化不确定性：1) 全球智能手机行业竞争加剧，市场份额增长不及预期。2) 智能手机/电动汽车业务毛利率不确定性加大。3) 小米品牌高端化及电动汽车业务执行不及预期。4) 地缘政治不确定性加剧及监管不确定性。5) 宏观环境疲软，智能手机/IoT需求减弱。6) 外汇波动。