

KC桌面——外资精译

JPM：服务器CPU出货量模型

在本报告中，我们介绍了一种JPM专有的服务器CPU出货量模型，并预测服务器CPU总出货量将从2025年的2600万颗增长至2028年的6800万颗（年复合增长率38%）。我们将服务器CPU需求分为三类：(1) AI头节点CPU，(2) 代理型AI服务器CPU，以及(3) 通用服务器CPU。根据半导体团队基于CoWoS的估算（链接），AI加速器出货量在2025-2028财年预计将呈现约50%的年复合增长率，我们认为AI头节点CPU需求将出现阶梯式增长，且CPU与加速器的配比趋势正在上升。虽然通用服务器CPU应会继续保持约5%的稳定年复合增长率，但代理型AI CPU是突破性增长向量，预计2025-2028年年复合增长率达155%。总体而言，我们认为未来几年整体通用服务器出货量可维持20%以上的增长。这一超级周期对台积电、欣兴电子、信骅科技、嘉泽端子、纬颖科技、健鼎科技、创意电子、日月光投控以及SK海力士和三星电子等亚洲科技领域的存储厂商有利。

- AI需求重塑服务器CPU格局。我们预测AI加速器出货量将从2024年的760万颗增至2028年的3250万颗，且由于AI加速器日益复杂，头节点CPU配比不断提高。加速器与CPU的比率也在压缩——从传统HGX服务器的约4:1降至NVL72计算托盘中的约2:1，下一代TPU设计可能达到约1:1。在英伟达Vera和谷歌Axion的推动下，基于ARM的CPU正在抢占份额，我们估计到2028年ARM可能占AI头节点CPU需求的约90%。我们还预计ARM将在代理型AI服务器中扩大份额，因为超大规模云厂商正倾向于为新兴工作负载采用内部CPU路线图。因此，我们测算到2028年基于ARM的CPU将占混合服务器CPU市场的约43%（高于2025年的约22%）。尽管如此，我们仍预计x86 CPU市场在此期间将实现加速的25%年复合增长率（而上一周期为持平至低个位数增长）。
- 新型AI推理编排驱动代理型AI服务器需求。随着AI工作负载从训练转向推理，我们预计超大规模云厂商将在加速器周围部署更多通用服务器以改善总拥有成本。增量需求主要出现在外部存储服务器（例如KV缓存）和处理GPU周围查询编排的计算服务器中。虽然没有固定的加速器与CPU服务器比率，但我们的粗略分析表明今年约为0.5倍（每两个加速器配一个CPU），且随着加速器复杂性增加，该比率将随时间上升。这将成为通用服务器需求的关键增量驱动因素（到2028年占通用服务器CPU市场的50%以上，而去年不到10%）。
- 受益于服务器CPU超级上升周期的公司。服务器CPU、BMC、基板和插座需求之间存在高度相关性。我们预计信骅科技、嘉泽端子和欣兴电子将成为这一服务器CPU超级周期的主要受益者，驱动因素包括强劲的单位需求、持续的内容升级以及潜在的产品涨价。AMD在x86服务器CPU中的持续份额增长也有利于台积电和日月光投控作为主要晶圆代工/封测供应商。DRAM厂商可能受益于DIMM/SOCAMM需求的增长。在下游，我们认为服务器PCB制造商（如健鼎科技）和通用服务器ODM（如纬颖科技、英业达）也可能受益于强劲的服务器需求。

科技 - 硬件

目录：公司情况更新


AI推理周期加速服务器CPU增长周期 3 自上而下方法论 3 强劲加速器需求 + 上升的CPU配比 =
AI服务器头节点CPU指数级增长 4 代理型AI CPU成为服务器CPU需求的新驱动因素 5
用自下而上估算三角验证自上而下预测 7 基于ARM的CPU加速普及，受ARM CPU配比上升推动 7

AI推理周期加速服务器CPU增长周期

我们推出专有的服务器CPU需求模型。我们将CPU需求分为三类——(1) AI服务器头节点CPU、(2) 常规服务器CPU和(3) 代理型AI CPU——并预测服务器CPU总出货量将从2025年的2600万颗增长至2028年的6800万颗（年复合增长率38%）。随着AI应用从训练转向推理，我们预计代理型AI和AI头节点CPU需求将驱动一个"超级"通用服务器CPU周期。

我们还通过将出货量预测与三个子板块的ASP假设相结合来估算服务器CPU市场规模。鉴于持续的供应紧张和持续的CPU升级周期，我们假设CPU价格每年上涨约10%。因此，我们预测2025-2028年服务器CPU市场规模年复合增长率为53%，到2028年达到约1000亿美元，受出货量增长和ASP持续扩张的双重驱动。


图1：服务器CPU出货量趋势及年复合增长率



图表 1

来源：JPM估算。Gartner®。

图2：服务器CPU收入市场规模预测及年复合增长率



图表 2

来源：Gartner®。JPM估算。

自上而下方法论

我们以Gartner数据为基础确定了2024年服务器CPU总出货量，并预测了未来几年各细分板块的服务器CPU需求。我们基于JPM半导体团队（由Gokul Hariharan牵头）的AI加速器预测（链接）以及每个服务器节点中AI加速器与头节点CPU的比率来预测AI服务器头节点CPU需求。我们假设2024年没有代理型AI活动，并据此推导出2024

年隐含的常规服务器CPU需求。

对于2025年和2026年，我们假设非AI服务器头节点CPU出货量（常规服务器加代理型AI CPU）同比增长11%/30%，从2024年的2000万颗增至2300万颗/2900万颗。再加上300万颗/700万颗的AI服务器头节点需求，2025/2026年服务器CPU总出货量可能达到2600万颗/3600万颗（同比增长16%/42%）。

表1：服务器CPU预测 - 自上而下方法论

来源：JPM估算。2024年服务器CPU总出货量数据来自Gartner®。全球AI加速器出货量基于半导体团队的CoWoS估算（链接）。

强劲加速器需求 + 上升的CPU配比 = AI服务器头节点CPU指数级增长

我们看到AI服务器头节点CPU的配比正在上升。每台AI服务器中每个CPU对应的AI加速器数量从4:1降至2:1，未来几代甚至降至1:1，尤其是在AI ASIC服务器中。我们将此归因于AI服务器架构日益复杂，导致对AI服务器中CPU编排的需求增加。值得注意的是，AI加速器预测基于JPM半导体团队（由Gokul Hariharan牵头）的CoWoS估算（链接）。

\- Nvidia GPU服务器：NVL72计算托盘中的加速器与CPU比率从HGX服务器的4:1降至2:1。我们还在NVL72服务器机架的NVLink交换托盘中看到了CPU需求。有趣的是，我们观察到未来几代HGX服务器中加速器与CPU的比率有所上升（从4:1升至8:1），这可能是由于HGX服务器架构对CPU的需求相对较低。

\- AMD GPU服务器：我们的研究显示，MI300系列和AMD MI455 Helio服务器的GPU与CPU比率为4:1。

\- Google TPU服务器：我们的研究表明，TPU v8服务器有两种设计，TPU与CPU比率分别为1:1和2:1，未来几代可能采用1:1比率。我们假设TPU v8代中1:1和2:1设计的比例为50%/50%。

\- AWS Trainium服务器：我们的研究显示，T3液冷项目的Trainium与CPU比率将从T2和风冷T3项目的16:1降至4:1。

\- MSFT/Meta/其他AI ASIC服务器：我们假设其余AI ASIC服务器的加速器与CPU比率为4:1。


表2：AI服务器头节点CPU预测

来源：JPM估计。AI加速器单位估计基于我们半导体团队的CoWoS估计（链接）。

代理型AI CPU成为服务器CPU需求的新驱动力

随着我们迈向代理型AI时代，聚焦于测试时扩展（即长思考），CPU在编排、运行工具和技能、存储以及安全方面扮演着越来越重要的角色。例如，Vera CPU不仅位于NVL72机架系统中，还作为整个Vera Rubin平台（包括存储服务器和CPU服务器）中的独立CPU使用。


图3：智能阶段



图表 3

来源：Nvidia。

图4：代理 = 大语言模型 + 工具集；CPU在代理型AI生态系统中扮演关键角色



图表 4

来源：Nvidia。

我们将今年强劲的通用服务器需求（根据我们的估计同比增长30-40%）主要归因于代理型AI的新兴需求。为了量化代理型AI需求，我们假设2023/2024年没有代理型AI活动，并计算2025年和2026年代理型AI CPU与AI加速器的隐含比率。然后，我们基于该比率以及2027/2028年AI加速器需求的估计，预测代理型AI CPU需求。

用自下而上的估计三角验证自上而下的预测

在以下分析中，我们用自下而上的估计三角验证我们的自上而下预测。我们将2024年和2025年Intel/AMD服务器CPU出货量锚定于Gartner数据。对于2025-28年，我们预测x86/Arm服务器CPU出货量的复合年增长率分别为25%/72%。我们基于行业研究和AI服务器头节点CPU需求框架，估算其余ASIC CPU供应商的CPU需求。

表3：JPM服务器CPU自下而上估计

来源：Gartner®。JPM估计。

对于每个供应商，我们将需求分为三类：AI服务器头节点CPU、常规服务器CPU和代理型AI CPU。我们使用AI服务器头节点CPU预测（表2）来锚定AI头节点CPU需求。我们假设2024/2025年代理型AI CPU部署规模较小，并推导出隐含的常规服务器CPU需求。对于2026-28年，我们假设各类别常规服务器CPU需求的复合年增长率为5%。

然后，我们使用代理型AI CPU需求（2026-28年）和其余CPU类别作为平衡项，使我们的自下而上构建与自上而下总量保持一致。总体而言，我们预计代理型AI CPU需求将全面上升。


表4：JPM服务器CPU自下而上估计 - 按应用分类

来源：Gartner®。JPM估计。

Arm架构CPU的更快普及，得益于Arm架构CPU搭载率的上升

我们预测，到2028年，Arm架构CPU的采用率将达到约43%，而2025年约为22%，这得益于AI服务器头节点中采用率的上升以及x86 CPU的短缺。我们估计，到2028年，Arm架构CPU将占AI服务器头节点CPU总需求的90%，而2024年这一比例不到10%，主要推动力是采用Nvidia Arm架构CPU的NVL72服务器架构的普及，以及Google在其TPU服务器中采用自研CPU。


图5：服务器CPU总量 - x86/Arm架构出货量占比



图表 5

来源：Gartner®。JPM估计。其他主要包括Arm架构CPU。

图6：AI服务器头节点 - x86/Arm架构出货量占比



图表 6

来源：Gartner®。JPM估计。