

KC桌面——外资精译

NOM：中国互联网与新媒体，LLM专家电话会要点-超100家企业客户部署

LLM专家电话会要点

开源不等于公开操作手册

NOM中国互联网团队与一家隶属于研究机构的中国AI实验室专家举行了小组电话会。该实验室目前拥有自研基础模型，部署于超过100家企业客户。

专家指出，高端英伟达（NVIDIA US，未评级）芯片持续供应紧张和价格上涨，使得国产AI加速器越来越具吸引力。虽然中国模型提供商普遍在降低token价格，但专家强调基础模型与高级模型之间存在明显分化。提供商正积极降低处理标准化任务的基础模型价格以获取客户，同时对其高级模型维持溢价定价。专家认为，模型提供商可通过将模型深度嵌入企业工作流程来增强客户忠诚度。这种集成使得切换模型耗时且成本高昂，有效阻止客户流失。

专家认为，DeepSeek（未上市）凭借推理工作负载期间卓越的运营效率，拥有显著的成本优势。其他托管相同开源DeepSeek模型的平台极难复制这种效率。专家认为，资金服务、办公生产力、编程、制造业、法律和医疗保健是最可能率先采用大语言模型（LLM）的行业。因此，这些领域预计将成为LLM提供商未来的核心收入来源。

硬件限制：芯片供应依然紧张

专家所在公司是华为（未上市）昇腾加速器的早期大规模采用者，并在近期中国AI芯片需求激增前数年就开始适配国产硬件和软件。专家观察到，由于高端训练硬件需求旺盛且供应紧张，英伟达和国产加速器的价格均有所上涨。值得注意的是，某些高端英伟达芯片的定价在过去一年大幅攀升。虽然国产加速器也经历了涨价，但涨幅较小。因此，国产硬件在推理工作负载方面提供了越来越有吸引力的宏观环境性。

DeepSeek：开源不等于公开操作手册

与许多能力相近的模型相比，DeepSeek的推理成本显著更低。重要的是，专家认为，即使DeepSeek开源其模型权重和部分软件栈，竞争对手也无法轻易复制这一成本优势。

专家将DeepSeek的优势归因于卓越的系统级优化，包括更高的缓存效率、更低的延迟和更好的硬件利用率。尽管DeepSeek的大部分模型架构是公开的，但关键的实现细节和运营诀窍仍属专有。因此，当腾讯、阿里巴巴和字节跳动（未上市）等云服务商在类似硬件上部署相同的开源DeepSeek模型时，DeepSeek的原生部署实现了更高的运营效率和更低的平均推理成本。这一成本优势使DeepSeek在官方API token定价上拥有更大的灵活性来低于第三方平台。

我们注意到其他行业消息来源也有类似反馈。虽然大多数开源模型可免费部署——有些还允许免费商业使用——但用户仍难以达到原始开发者的运营性能。此外，无法保证中国AI实验室会继续开源其前沿模型。例如，阿里巴巴曾是开源策略的早期倡导者，但其最新旗舰模型Qwen 3.6 Max以闭源产品形式发布。正如来自Moonshot AI的近期专家所言，开源模型有助于建立品牌知名度和开发者生态系统，但闭源仍是规模化变现专有模型的主要途径。

LLM定价的分化

尽管基础设施成本上升，专家预计低端模型的价格将继续下降。供应商将这些模型作为引流产品，以获取开发者和企业客户，特别是用于转换成本低的通用工作负载。由于客户可以轻松将基础API工作负载迁移至竞品模型，当供应商的唯一差异化因素是token成本时，它们缺乏定价权。

相反，服务于大型企业的高级模型定价前景更为强劲。这些客户优先考虑模型可靠性、任务完成质量、延迟和服务稳定性。一旦模型深度嵌入生产工作流程，转换成本将变得极高。例如，专家所在机构继续降低基础模型价格以推动客户获取，同时提高面向战略客户的高性能模型和定制化服务的定价。

最终，表面上的token价格下降并不代表行业价格变化。模型提供商完全有能力通过为深度融入企业运营的高级定制模型收取溢价，来抵消标准化工作负载的折扣。

企业采用：安全性与回报表现率

专家将企业AI客户分为两个截然不同的群体

政府和国企：讨论优先考虑数据安全、合规性和本地化部署。该群体强烈偏好使用国产硬件进行本地部署的模型。虽然国有背景供应商目前在此拥有客户获取优势，但专家指出，国企正开始在非敏感工作负载中部署来自私营供应商的优质模型。

私营企业：回报表现率是主要驱动力。私营客户不接受模糊的长期生产力提升承诺，而是期望在12至18个月内清晰看到收回初始AI研究的路径。

高潜力商业化垂直领域

专家指出了几个具有巨大商业化潜力的行业

资金服务：被视为最具吸引力的垂直领域之一。机构拥有大量专有数据集，且对优质AI工具的付费意愿相对较高。

办公生产力：应用涵盖文档生成、会议管理以及与ERP和CRM系统的无缝集成。未来的企业智能体预计将能跨多个软件平台自主执行常规运营流程。

编程：被强调为具有战略重要性的市场。编程能力是更广泛的智能体AI、机器人和自动化运营的基础层。专家认为GLM-5.2是中国领先的编程模型，其次是DeepSeek、Moonshot（未上市）和阿里巴巴Qwen的最新迭代版本。

工业制造：目前处于早期采用阶段（估计工作流渗透率低于10%）。随着模型提升解读物理过程的多模态能力，与工业设备的交互预计将加速。

医疗和法律：这两个领域为基础模型提供了重要的长期增长机会。

附录A-1：公司情况更新