

KC桌面——外资精译

UBS：中国人工智能智能，2026年下半年关键主题

2026年下半年关键主题：模型能力、变现与Token回报表现率

三大关键主题

在2026年初智谱和MiniMax上市后，读者对中国AI模型的兴趣有所提升，市场讨论在模型迭代、变现和竞争方面变得更加深入。我们提出2026年下半年值得关注的三大关键主题：1) 虽然我们预计以编程能力为主导的模型智能将持续提升，但我们注意到早期迹象表明，得益于数据飞轮、产品化改善带来的用户粘性提升以及AI在模型研发中的日益普及（如递归式自我改进），最先进的模型可能捍卫其领先地位；2) 我们预计模型层的变现将持续加速，因为编程TAM（总可寻址市场）正扩展到开发者之外，而多模态方面的进展可能被忽视；3) 我们预计市场将更加关注Token回报表现率，企业和用户从Token最大化转向Token优化应会推动分层需求，并扩大最先进模型与其他模型定价权的差距，而中国模型因其结构性成本效率可能受益于这一趋势（参见报告）。

编程仍是模型智能提升最清晰的路径

我们重申观点：编程是支撑模型智能的核心能力，且有一条清晰的路径推动能力前沿。我们认为AI编程是基于强化学习的后训练中最易处理的领域之一，因其结果相对可验证、可扩展的合成数据以及来自AI编程代理的真实任务反馈。我们注意到新兴的中国AI实验室在产品化方面更加积极主动，通过构建编程代理产品/工具包，这应能创造潜在的数据飞轮，并通过积累的项目上下文、技能和偏好提升用户粘性。我们注意到AI在模型研发中的使用日益普及，更强的编程能力可能加速模型迭代（递归式自我改进的早期进展）。这可能使具备最先进编程能力的模型巩固其领导地位。

巨大的变现潜力，回报表现率纪律日益增强

在变现方面，AI编程TAM持续扩大，从开发者工具转向面向知识工作者的更广泛生产力工具，通过功能创新（如应用插件、Claude Tag）与更多工作流集成并加速采用。多模态方面的进展也值得关注，中国模型在视频生成能力和变现方面展现出早期领先地位（例如快手可灵2026年5月ARR达5亿美元）。随着企业采用从Token最大化转向回报表现率纪律，我们对全球市场份额增长潜力更为乐观，这得益于日益增长的认可度（如GLM-5.2）和明显的回报表现率优势，尤其是在高容量、重复性编程和代理工作流中。然而，我们承认算力供应仍是ARR加速增长的关键瓶颈。

上市公司估值分化

智谱和MiniMax上市后的报价表现显示出日益扩大的分化，反映了智谱在最先进编程模型（如GLM-5.2）方面领导地位的加强，以及在编程用例中更清晰的变现潜力。虽然我们不排除MiniMax在模型性能上迎头赶上的可能性（得益于其在算力获取和研发效率方面的优势），但我们预计其估值折价在短期内将持续，同时我们将继续关注未来模型迭代的拐点。在Token需求上升的背景下，我们大幅上调了两家公司2026年收入/ARR预测。，基于2026年12月ARR分别为15亿美元/10亿美元，对应85倍/20倍P/ARR。

公司：公司情况更新

中国


评论：公司情况更新

AI编程中模型能力提升的清晰路径

我们认为AI编程是基于强化学习的后训练中最易处理的领域之一，因其结果可通过代码执行、单元测试和自动评分器相对可验证，而可扩展的合成数据和来自编程代理的真实任务反馈可进一步支持模型的持续改进。

我们注意到AI编程在前沿模型研发中的早期采用，更强的编程能力可能有助于加速未来模型迭代，形成通向递归式自我改进的早期路径。这体现在Anthropic的最新报告《当AI构建自身》中，该报告表明编程代理越来越多地被用于AI模型研发，包括优化训练小模型的代码和运行实验。OpenAI的Codex披露也指向内部采用中的类似趋势。

图1：AI编程正深入前沿模型研发




图表 1

来源：公司数据

产品化与早期数据飞轮

在进一步开发基础模型之外，我们注意到新兴的中国AI实验室在推出第一方编程代理产品/工具包方面变得更加积极主动，包括智谱的ZCode、MiniMax Code以及据报道DeepSeek正在组建的Code Harness团队（新闻）。我们认为这可能创造一个早期数据飞轮，因为用户交互和真实任务工作流可以反馈到模型改进中。同时，我们认为，积累的项目上下文、技能和用户偏好也可能随着时间的推移提高用户粘性。

图2：中国AI实验室越来越多地推出第一方编程代理产品/工具包



图表 2

来源：公司数据


AI编程TAM持续扩大

我们观察到AI编程TAM持续扩大，因为编程代理正从开发者工具转向面向知识工作者的更广泛生产力工具。OpenAI最新的Codex使用更新为此趋势提供了明确证据：Codex的使用始于开发者，但随着其扩展到更通用的知识工作，非开发者用户成为增长最快的用户群体。截至2026年6月初，非开发者个人用户自2025年8月以来增长了137倍，非开发者组织用户增长了189倍，OpenAI的非开发者内部用户增长了12倍。

同时，我们认为持续的功能创新可能进一步加速在软件工程师之外的采用。例如，OpenAI的Codex插件将编程代理扩展到数据分析、创意制作、销售、产品设计、公开公司研究和国际机构等特定角色工作流，而Anthropic的Claude Tag将Claude引入Slack作为团队代理，可访问特定频道、工具、数据和代码库。我们也在中国的编程代理产品中观察到类似功能（例如智谱的Zcode和Kimi Code/Work）。


图3：AI编程代理的采用正扩展到开发者之外

Non-developer



图表 3

LLM Token Expenditure Index; Unit: US\$/M tokens




图表 4

来源：OpenAI（代理如何改变工作）。注：上述数据指以2025年8月1日为基准的28天活跃用户指数。

随着企业采用从追求代币最大化转向注重ROI纪律，我们更加看好中国模型在全球市场份额增长方面的潜力，其在编程和智能体工作流中展现出更明显的ROI优势，尤其适用于高并发、重复性的推理任务，海外应用和平台的集成度不断提升即为明证（参见我们关于中国AI模型成本效益的亚太聚焦报告）。


图4：大语言模型代币支出指数



图表 5

资料来源：SiliconData。注：数据截至2026年7月1日。标准化混合费率取自前沿API提供商、开放权重推理平台、代理专用实例市场及自托管参考部署的观测数据


图5：OpenRouter上中国与美国AI模型代币使用趋势



图表 6

资料来源：OpenRouter。注：数据截至2026年7月1日


图6：海外应用和平台正越来越多地集成中国AI模型



图表 7

资料来源：公司数据

图7：主要AI模型的模型智能与API价格



图表 8

资料来源：公司数据、Artificial Analysis。注：数据截至2026年7月9日。混合价格使用缓存输入、非缓存输入和输出代币价格计算，比例为7:2:1。AA = Artificial Analysis

盈利预测调整

资料来源：公司数据、Refinitiv、UBS预测。注：一致预期基于Refinitiv。数据截至2026年7月10日

智谱华章（智谱；2513.HK）

我们大幅上调2026年营收预测71%，主要反映我们对智谱年度经常性收入（ARR）增速更为乐观的看法。我们目前预计其2026年12月ARR将达到15亿美元（2026年3月为2.5亿美元），高于此前管理层内部10亿美元的目标。支撑因素包括其在AI编程领域领导地位的加强、通过内部AI基础设施优化和供应采购努力扩大算力，以及在获取全球前沿模型渠道趋紧背景下潜在的市场份额增长。我们还上调了远期营收预测，同时保守地假设2027年之后增速将更为温和。

图9：关键假设变动

资料来源：公司数据、UBS预测

MiniMax（0100.HK）

我们大幅上调MiniMax 2026年营收预测108%，反映其ARR加速增长。（据管理层称，2026年4月ARR较2026年2月增长超过100%，而2025年12月至2026年2月期间增速为超过50%）。我们目前预计2026年营收为4.61亿美元，意味着2026年12月ARR约为10亿美元，与管理层内部目标基本一致。

我们还上调了2026-2028年研发费用预测18-23%，反映其通过扩大模型参数规模来追求模型领先地位的更积极策略。得益于更大营收基数带来的运营杠杆改善，我们预计MiniMax 2026年非GAAP净利润率将从之前的-229%收窄至-119%，尽管非GAAP净亏损绝对值增加9%至5.5亿美元。

图10：关键假设变动

资料来源：公司数据、UBS预测

估值：公司情况更新

智谱华章（智谱；2513.HK）

我们对智谱2026年营收55亿元人民币（此前为32亿元人民币）应用160倍市销率（此前为145倍），基于更高的2025-2027年营收复合年增长率332%（此前为231%）和0.4倍2026年市销增长率（PSG），与国内AI芯片公司（0.6倍PSG）相当。

通过分部加总估值法交叉验证，若我们假设智谱开放平台业务85倍P/ARR（此前为100倍），基于我们预测的2026年12月ARR 15亿美元，以及本地部署业务40倍2026年市销率（此前为60倍），反映Palantir最新估值基准（40倍2026年市销率），估值可达2258港元。

资料来源：UBS预测

图12：分部加总估值

资料来源：UBS预测

MiniMax（0100.HK）

我们对MiniMax 2026年12月ARR 10亿美元（此前为3.18亿美元）应用20倍P/ARR倍数。我们的P/ARR倍数已下调至20倍（此前为125倍），反映我们ARR预测的大幅上调以及我们认为MiniMax的模型仍需时间追赶前沿SOTA模型的观点。即便如此，该估值仍处于当前OpenAI/Anthropic 20-34倍P/ARR估值区间的低端，尽管MiniMax作为上市公司具有更高流动性。

该P/ARR倍数与当前全球AI领导者的私募市场估值倍数相当，但显著低于智谱，反映市场对SOTA与非SOTA编程模型之间估值差距的分化。我们认为SOTA模型瞄准高端用例，可占据更大营收份额并享有更强定价权，而其他模型可能服务于大众市场代币使用，其模型智能长期面临更大的商品化不确定性和激烈竞争。

虽然我们认识到估值差距在扩大，但我们不排除MiniMax凭借算力获取和研发效率优势实现追赶的潜力，同时将持续关注未来模型迭代中可能带来报价正面动能的拐点。

资料来源：公司数据、UBS预测

图14：可比估值

资料来源：公司数据、Refinitiv。注：一致预期基于Refinitiv。数据截至2026年7月10日

图15：OpenAI与Anthropic的估值及ARR历史

资料来源：The Information、Pitchbook

UBS论点地图——指引我们的思考及本报告内容分布

问：智谱能否在编程和智能体能力方面保持全球前沿地位？

很可能。我们强调智谱的模型开发和商业化策略与全球领导者Anthropic高度相似，后者高度聚焦编程和智能体能力，并已获得来自企业和开发者的加速需求，展现出已验证的变现潜力。尽管行业竞争依然激烈，我们看好智谱的先发优势、强大的研发团队和经验，以及持续的技术创新，以不断开发能力提升且快速迭代的前沿模型。

问：智谱在开放平台和本地部署方面的商业化潜力如何？


我们预测2025-2027年营收复合年增长率为332%，其中开放平台占比从2025年的26%上升至2027年的87%。我们认为智谱开放平台业务具有显著的变现潜力，受强劲的企业AI需求驱动，同时模型能力的提升支撑代币消耗和定价权。我们还预计本地部署业务将持续增长，受政府和企业渗透率提升支撑，但可能优先级较低。

我们重申对智谱的公司观点。我们对其在国内的模型领导地位更加乐观，这得益于其经过验证的过往记录以及近期成功推出的 GLM-5.2 获得了全球认可。鉴于 AI 编程需求随着用例的扩大而增长，我们也对其在 2026-28 年预测期内的收入增长轨迹更加乐观。长期来看，我们认为智谱是从当前从“Token 最大化”向“Token 优化”转变过程中的关键受益者，因为企业和用户越来越关注回报表现率。我们预计将持续看到模型迭代，这将巩固智谱在中国 AI 编程市场的领导地位并缩小与全球领导者的差距，同时实现持续的结构性能效率，而其长期全球市场份额增长节奏变化不确定性主要在于算力可用性以及地缘政治/监管不确定性。

模型升级：1) 智谱于 5 月面向部分企业客户推出了 GLM-5.1 高速版，输出速度高达 400 TPS，约为标准版 GLM-5.1 的 8 倍，且高于全球同行约 200 TPS 的水平。2) 智谱还在 6 月中旬推出了其升级版旗舰模型 GLM-5.2，具有 100 万 Token 的上下文窗口和更强的长程能力。GLM-5.2

进一步缩小了与全球顶级编程模型的差距，同时保持了有竞争力的定价。AI 基础设施：1) 智谱推出了 LayerSplit，一种分层 KV 缓存存储解决方案，将系统吞吐量提高了 10-132%。2) 通过 ZCube 的新网络架构，智谱实现了交换机与光模块资本支出降低 33%，平均 GPU 推理吞吐量提升 15% 并降低了延迟。3) GLM-5.2 实现了在七个主要国产 AI 芯片平台上的 Day-0 推理适配。

我们认为读者认可智谱的国内领导者地位，并给予其相对于同行的估值溢价。即将到来的催化剂，如中期业绩、模型升级以及 A 股上市，可能在短期内维持报价动能。长期来看，我们认为市场仍然低估了智谱及其他中国模型的结构性能效率，这使其在全球市场份额增长中占据有利地位，也低估了由智能体采用率上升所驱动的 Token 消费激增带来的变现潜力。



图表 9

来源：UBS估计

智谱是一家总部位于中国、致力于实现通用人工智能的通用大模型开发商。它提供定制化的本地部署解决方案和基于云的服务。

Z.ai (2513.HK)

来源：公司账目，UBS估计。(UBS) 指标使用经UBS分析师调整的已报告数据。\$^{1}\$ 现金每股收益 (UBS，摊薄) 使用UBS净收入加上折旧和摊销计算。

来源：公司账目，UBS估计。(UBS) 指标使用经UBS分析师调整的已报告数据。

UBS研究 论点地图 指导我们的思考及本报告内容分布

问：在激烈的竞争中，MiniMax 能否在 AI 模型能力上实现差异化？

有可能。我们认为 MiniMax 采取了差异化策略，从第一天起就致力于跨多种模态的模型开发。尽管竞争激烈，我们仍对其在算力获取和研发效率方面的优势持乐观态度。这可能使其能够进一步扩展到更大参数的文本模型（例如，数万亿参数模型），从而有可能在未来迭代中推动更强的性能。我们将持续关注其视频生成模型（即海螺 AI）的升级，这可能会进一步加强其在多模态方面的差异化定位。

问：随着模型能力的提升，MiniMax 能否扩大其商业化规模？

可以。我们对 MiniMax 的收入增长潜力持建设性看法，这得益于其涵盖面向企业（2B）和面向消费者（2C）服务的全面产品线以及全球化的市场进入策略。我们预计公司持续的模型迭代和对商业化的日益重视将支撑其收入的快速扩张，并预测其 2025-27 年收入复合年增长率为 258%，其中 2B 服务的收入占比将不断提高。


问：MiniMax 能否维持其持续的研发投入？

可以。我们预计 MiniMax 将保持持续的高研发投入以支持持续的模型迭代，这可能会对短期盈利能力和现金流造成不确定性。尽管如此，我们认为其在研发效率方面的优势，得益于更好的算力利用率和组织效率，可能使其能够利用现有资源追求模型性能领先地位。

我们维持对 MiniMax 的公司观点。我们认为它是企业 AI 应用从“Token 最大化”向更注重回报表现率的使用方式转变过程中的关键受益者，并对其长期的全球市场份额增长潜力持乐观态度。我们也对其收入/年度经常性收入（ARR）的增长持建设性看法，并相信公司有望在 2026 年 12 月前实现 10 亿美元的 ARR 目标。虽然我们承认被视为 SOTA 与非 SOTA 模型提供商之间的估值差距正在扩大，但我们不排除 MiniMax 凭借其在算力获取和研发效率方面的优势而迎头赶上的潜力。

- 管理层分享称，4 月份的 ARR 较 2026 年 2 月增长超过 100%，增速较 2026 年 2 月相对于 2025 年 12 月超过 50% 的增长有所加快，这得益于 API 和 Token 计划收入的快速增长，而订阅收入（例如海螺 AI）保持稳健。
- 2) MiniMax 的文本模型 M2.7 的 API 毛利率超过 40%，高于国内同行（约 20%）。
- 3) MiniMax 的算力扩张依然稳健，每分钟 Token 数（TPM）保持 10-20% 的周环比增长，这得益于其与国内供应商的长期合作关系以及更好的全球算力供应渠道。
- 4) 据报道，MiniMax 正在开发一个 2.7 万亿参数的开源权重模型，最早可能于 2026 年第三季度推出。

随着近期报价走弱，我们认为读者对 M3 发布和锁定期结束的谨慎反馈已基本被市场消化，而即将到来的催化剂包括纳入相关市场通、中期业绩以及 M 系列/海螺 AI 模型的发布。我们也认为市场可能忽视了多模态的变现潜力，以及 MiniMax 在算力获取和研发效率优势支持下，其 ARR 和毛利率的上行空间。



图表 10

来源：UBS估计

MiniMax 是一家全球性的 AI 基础模型公司，专注于开发先进的基础模型和 AI 原生产品……

MiniMax (0100.HK)

来源：公司账目，UBS估计。(UBS) 指标使用经UBS分析师调整的已报告数据。 $\$^{\{1\}}$ 现金每股收益(UBS，摊薄) 使用UBS净收入加上折旧和摊销计算。

来源：公司账目，UBS估计。(UBS) 指标使用经UBS分析师调整的已报告数据。

估值方法与不确定性声明

我们认为行业主要不确定性包括：1) 竞争格局不断演变，竞争日益激烈；2) 技术趋势以及互联网用户需求和偏好快速变化；3) 变现前景不确定；4) 流量获取、内容及品牌推广成本上升；5) IT系统维护；6) 向国际市场扩张；7) 市场情绪出现不利变化；8) 监管不确定性。

MiniMax：我们对MiniMax采用价格/年度经常性收入（Price/ARR）估值方法。主要节奏变化不确定性包括：宏观和地缘政治不确定性可能制约AI应用；竞争和运营挑战延迟变现并挤压利润率；与数据相关的模型训练不确定性；用户生成内容治理不确定性；以及关键服务提供商中断。

主要上行不确定性包括：地缘政治紧张局势和出口限制缓解，可能改善先进硬件的获取并加速模型升级；AI训练和基础设施效率方面的技术突破，可能提升模型能力和利润率；以及用户采用和商业化速度加快，推动更强的变现能力和盈利能力。

知识图谱技术（智谱，或Z.ai）：我们对智谱采用市销率（P/S）估值方法，并辅以分类加总估值法（SOTP）进行交叉验证。

主要节奏变化不确定性包括：宏观和地缘政治不确定性可能制约AI应用；竞争和运营挑战延迟商业化并挤压利润率；关键客户（KA）因自身内部模型能力提升而可能减少采购；影响模型训练和性能的数据相关不确定性；与数据安全和AI治理相关的监管不确定性；以及关键计算基础设施和服务提供商的接入可能中断。

主要上行不确定性包括：地缘政治紧张局势和出口限制缓解，可能改善先进硬件的获取并加速模型升级；模型能力在规模和迭代速度上超预期提升，支撑更高的使用量和定价；模型训练和推理效率方面的技术突破，可能提升模型能力和利润率；企业采用超预期，尤其是在企业端/政府端（to-B/to-G）领域，推动更快的商业化；以及新AI应用场景的出现，支撑更高的变现能力和收入增长。

量化研究回顾

智谱

MiniMax