

KC桌面——外资精译

Bernstein：美国多行业与电气设备-数据中心液冷，单相DTC之后是什么

数据中心液冷：单相DTC之后是什么？有了CoolIT的15kW冷板，还需要其他技术吗？

如今当你听到“液冷”这个词时，大多数人指的是单相直接到芯片（DTC）。之所以称为单相，是因为冷却液保持液态（不会发生相变成为蒸汽）。更广泛的市场似乎认为，我们正接近单相冷却未来几代GPU的理论极限（尤其是当TDP达到Rubin Ultra级别、超过约2.5kW时）。有两种技术被视为单相DTC的继任者：（i）两相DTC和（ii）直接到晶圆。下文将对此进行更详细的解释。

两相DTC：在未来约12-18个月内，大约与Rubin Ultra同期，更有可能实现商业可行性。冷却液在冷板中发生相变（蒸发），使其能够在类似运行条件下比单相DTC捕获更多热量。大多数主要参与者可能正在研究这一领域，要么直接投入（例如VRT、CoolIT），要么通过合作（例如JCI与Accelsius、Carrier与ZutaCore等）。但仍需解决实际的工程挑战（回流、制冷剂选择等），因此这绝非板上钉钉。

直接到晶圆：完全消除了冷板的需求，通过硅晶圆本身进行冷却。技术复杂得多，研发处于极早期阶段，但理论上可提供比DTC显著更好的热通量。我们预计2030年前不会出现大规模应用。微软和台积电都在进行研究并已发出信号（可能在2026年制造），但由于更实际的挑战（例如去离子水导致硅腐蚀），我们尚未听到任何关于广泛采用的消息。

变数：CoolIT的15kW单相冷板。大约一个月前，CoolIT还宣布，他们已证明单相DTC可以在相对标准的运行条件下（1.2升/分钟、45 °C入口温度、导热膏、PG25冷却液等）与额定功率15kW的冷板配合工作。这与单相无法在GPU TDP超过2.5kW时工作的说法相悖（CoolIT的数字是其6倍）。虽然根据其白皮书，该技术是在实验室规模装置中测试的，但我们认为这是一款可信的产品。如果能够大规模商业化，它基本上将两相DTC的需求推至2030年之后。数据中心电力和冷却方面的大多数技术演进都是由需求驱动的，如果我们不再需要两相或直接到晶圆，数据中心运营商继续使用单相冷却设置会更容易。如果15kW冷板能够商业化，我们认为它对机房冷却设备（CDU和冷板）的影响是混合的。一方面，新技术带来的结构性转变减少，这可能对这些组件造成定价不确定性（因为创新溢价开始枯竭），商品化可能加速。需要明确的是，未来几年内不太可能实质性影响收入或利润率，因为需求远超供给，但在此之后这是一个不确定性。这取决于竞争对手复制CoolIT方法的速度（可能不会很快，因为他们拥有底层技术的专利）。从积极的一面看（特别是对冷板而言），它在可预见的未来确实消除了过时不确定性（因为不再真正需要直接到晶圆）。

BERNSTEIN公司代码表

O - 跑赢大盘，M - 与大市持平，U - 跑输大盘，NR - 未评级，CS - 暂停覆盖

来源：彭博社、Bernstein估计与分析。

观察提示：公司情况更新

我们给予VRT跑赢大盘评级

我们给予NVT跑赢大盘评级

我们给予TT跑赢大盘评级

我们给予JCI跑赢大盘评级

我们给予CARR与大市持平评级

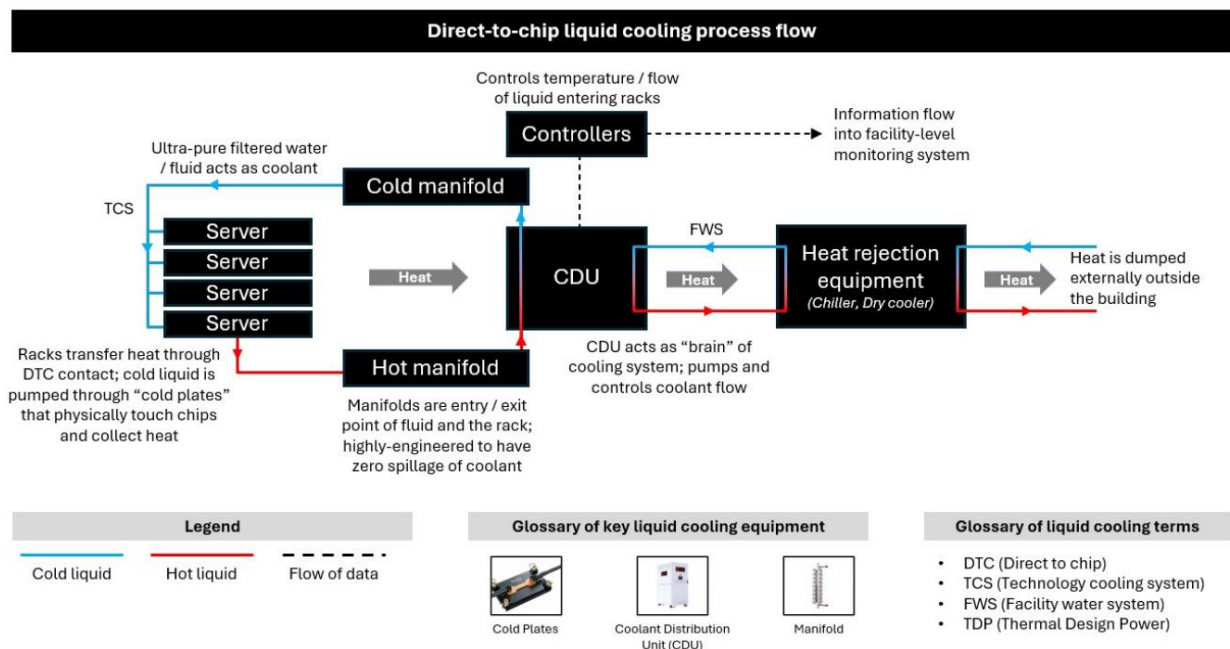
我们给予ETN跑赢大盘评级

回顾：单相DTC冷却概述

目前液冷的主要形式是单相DTC。DTC代表直接到芯片。它涉及冷板（顾名思义，由于内部循环的制冷剂而温度降低的金属板）与GPU接触以提取热量。在冷板内部，液体流经阵列和流路，旨在最大化从GPU提取的热量。冷却液分配单元（CDU）将低温冷却液（在单相设置中通常是水和丙二醇的混合物）泵送通过冷板，并在冷却液从服务器提取热量后回收用过的液体。

然后热量从冷却液中提取出来（使其再次冷却），过程重复。之所以称为单相，是因为冷却液保持单相（液态），不会通过蒸发从液态变为气态。这个循环（即从CDU通过服务器中的冷板循环）称为TCS或技术冷却系统。一旦用过的冷却液到达CDU，它会通过一个热交换器，将热量传递给另一个称为FWS或设施水系统的冷却回路。FWS连接到冷水机组或干冷器，将这些热量排放到数据中心外部。然而，随着机架功率密度持续增加，单相DTC似乎正达到其可提取热量的理论极限。

图表1：直接到芯片流程概览




图表 1

来源：Bernstein分析

通常，在当前的GPU表面积下，单相DTC预计将在GPU TDP达到2-2.5kW时达到其热极限。Rubin GPU开始逼近这个2-2.5kW的极限，而Rubin Ultra预计将超过它。在此之后，技术共识一直是需要更激进的热传递形式（例如两相或直接到晶圆）。

还有一种替代方案是降低流经冷板的冷却液温度，但出于管理能耗的考虑，这并非首选。浸没式冷却也不被视为可行的替代方案，因为它涉及将服务器浸入冷却液中，这比当前的托盘式方法更笨重且更难维护。因此，两个真正的选择是两相DTC或“直接到晶圆”，下文将对此进行解释。


图表2：按GPU TDP划分的液冷形式



图表 2

来源：Bernstein分析与估计

图表3：多种液冷输送形式



图表 3

冷却液在吸收GPU热量时蒸发（相变）（提取的热量远多于单相）

微流体通道直接蚀刻在晶圆上

来源：Bernstein分析与估计

图表4：显热与潜热；有何区别？ 图示（以水为例） 1千克水升温1 ° C

两相DTC：公司情况更新

概述：公司情况更新

顾名思义，两相DTC冷却在冷却过程中涉及两种物态。在单相DTC中，TCS冷却液（一种水乙二醇混合物）在流经冷板时，在整个传热过程中保持液态。然而，在两相DTC中，冷却液（另一种化合物，非水基）在冷板中蒸发为气态，然后再次冷却为液态并重复循环。蒸发过程能够捕获大量热量，而制冷剂的底层温度不会发生显著变化。

要理解其工作原理，我们需要定义几个科学术语：显热和潜热。显热是指在不发生相变的情况下，升高物质温度所需的热量。潜热是指在保持发生相变的物质温度不变的情况下，引起相变（例如，通过蒸发从液态变为气态）所需的热量。

$Q_{\text{显热}} = m \cdot c \cdot \Delta T$ 其中 m 是物质的质量， c 是其比热容（即，将 1 千克材料的温度升高 1°C 所需的热量）， ΔT 是温度变化。

$Q_{\text{潜热}} = m \cdot L$ 其中 m 仍然是物质的质量，而 L 是特定的“潜”热（即，引起 1 千克材料相变所需的热量）。注意，与显热不同，温度变化在这里并不重要；这是因为当发生相变时，它是在恒温下进行的。如果冷却液或制冷剂具有足够大的潜热，与显热传递相比，它本质上可以在保持相对恒定温度的同时捕获更多的热负荷。这与制冷压缩循环中应用的原理相同，在该循环中，制冷剂在捕获热量时蒸发，并在循环回系统之前冷凝。

$$Q = (1) \times (4.18) \times (1) = 4.18 \text{ kJ}$$

单相 DTC 的核心原理（冷却液只是“升温”）——带走的热量为 4.18 kJ

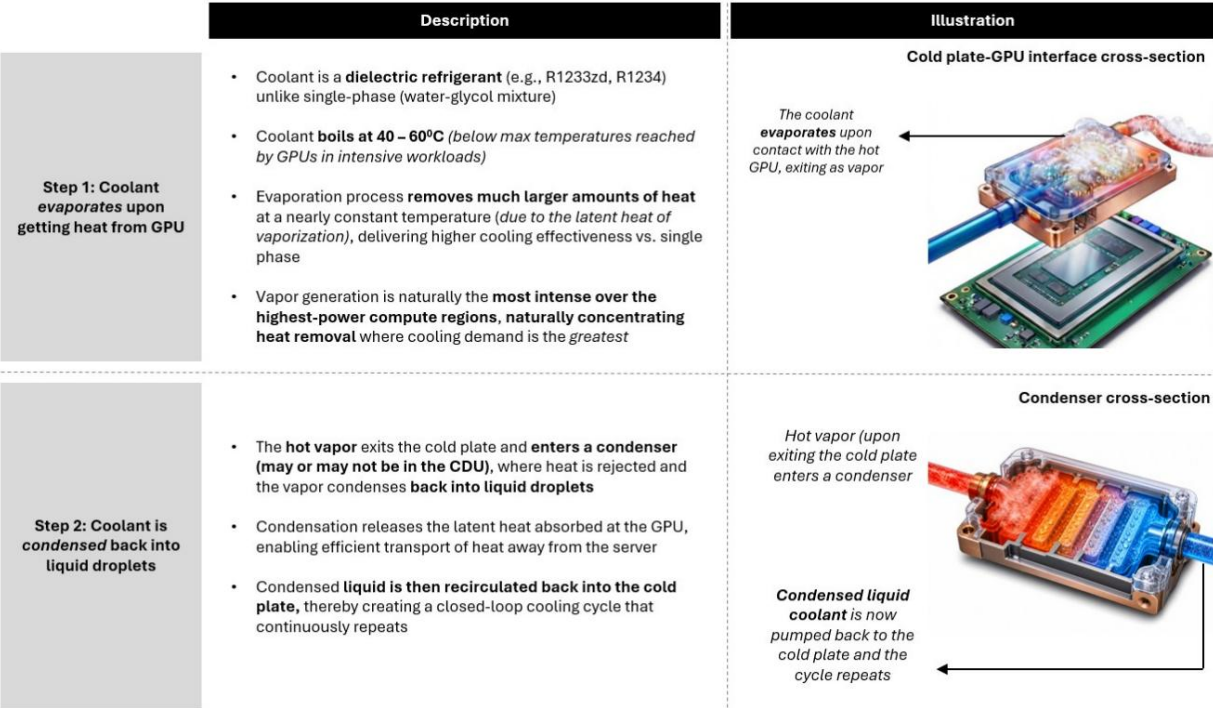
1 kg 水沸腾（恒温过程）

$$Q = (1) \times (2260) = 2260 \text{ kJ}$$

两相 DTC 的核心原理（冷却液“沸腾”）——带走的热量为 2260 kJ

来源：Bernstein 分析与估算

图表 5：两相冷却机制（示意）



图表 4

来源：Bernstein 分析；使用 AI 生成的图像展示代表性过程

两相 DTC 的优势

两相 DTC 的关键优势在于其相比单相操作具有更高的热通量；当冷却液可以蒸发时，在相同条件下可以捕获多得多的热量（通常 >3 倍）。这使得在保持相同尺寸的同时，可以开发具有更高 TDP 的 GPU。由于蒸发也使冷却液保持相同温度，因此通过冷板可获得均匀一致的热分布，这有助于更好地管理热点。根据所使用的冷却液和芯片 TDP，与单相下类似的热负荷相比，还可以使用更小的泵、更少的冷却液量，并花费更少的能量将其泵送通过系统。由于这些制冷剂/冷却液很可能不是水基的，因此它们也不太可能出现腐蚀或细菌滋生。它还使冷却液具有介电性（不导电），因此万一发生液体泄漏，不会烧毁

GPU。而且，本质上，两相冷却液溢出时会蒸发，而不是在托盘上积聚。

两相 DTC 的劣势

最大的工程问题与两相系统中的流动有关。大多数物质从高压区域流向低压区域。对于液体来说，即使在冷板内的复杂微通道阵列中，这也是简单的。然而，当发生蒸发时，气体可能会产生高压区域，将其推向与应流动方向相反的方向。这个问题尚未在大规模应用中得到解决。另一个劣势是复杂性；两相系统比单相 CDU/冷板设置具有显著更多的变量。满足所需特性的制冷剂/冷却液通常是 PFAS（永久性化学品），这对于部署来说并不理想。因此，仍然需要进行研究以开发并大规模生产这些化合物。

谁在研发方面处于领先地位？

这很难说，因为公司提供的可见度水平不同。根据我们公开看到的信息，Vertiv 和 Accelsius 最接近拥有可商业化的产品。事实上，Accelsius 在其网站上宣传 CDU。Zutcore 非常关注这个主题，但我们尚未在其网站上看到具体产品（尽管他们确实有演示）。我们知道 CoolIT 也在该领域进行研究；他们几年前也在 OCP 论坛上就此主题进行了演讲。Boyd 拥有两相技术的经验，即使不专门针对 CDU，而 Schneider 最近就此主题发表了一篇博客文章。JCI 和 Carrier 分别研究了 Accelsius 和 Zutacore。我们尚未看到 nVent 和 Trane 的公告，尽管作为 NVIDIA 参考设计合作伙伴，我们相信他们在需要时会推出相关产品。

图表 6：液冷厂商的两相研发状态



图表 5

来源：Bernstein 分析，公司报告

图表 7：阻碍两相商业化的关键挑战



图表 6

来源：Bernstein 分析

1 流体和蒸汽的同步管理是根本性挑战

\- 两相冷却需要在冷板上采用双通道阵列（较大直径用于低密度蒸汽，较小直径用于液体） \- 这会导致流量分配不均——板上某些通道主要承载蒸汽，而另一些主要承载液体，这可能导致局部热点（进而导致冷却不均匀）

2 高控制复杂度

• 需要主动管理多个变量：制冷剂温度、避免蒸汽过热、冷凝液冷却以及系统整体不确定性 \- 现代 GPU 工作负载是非稳态的：推理批处理会产生快速的功率瞬变（0 -> 100% 在毫秒内），这需要持续监控 \- 这需要比单相更精细校准的传感器和控制算法；控制软件的复杂性可能是一个重大负担

3 多氟烷基物质 (PFAS) 法规

\- 行业目前依赖 PFAS 制冷剂，由于环境因素，这些制冷剂面临越来越多的监管审查 \- 这可能会给数据中心运营商带来潜在的合规、报告和长期供应链不确定性

4 技术仍处于商业化的早期阶段

\- 两相 DTC 目前仍处于早期试点阶段，Zutacore（Carrier 作为读者之一的 1 亿美元 C 轮融资）和 Accelsius（JCI 作为读者之一的 6500 万美元 B 轮融资） \- 如果 GPU 功耗范围（Feynman / Kyber）超过 $\$6\mathrm{kW}+\$$ （Blackwell Ultra 为 $\$1.4\mathrm{kW}+\$$ ），那么两相将成为必需品

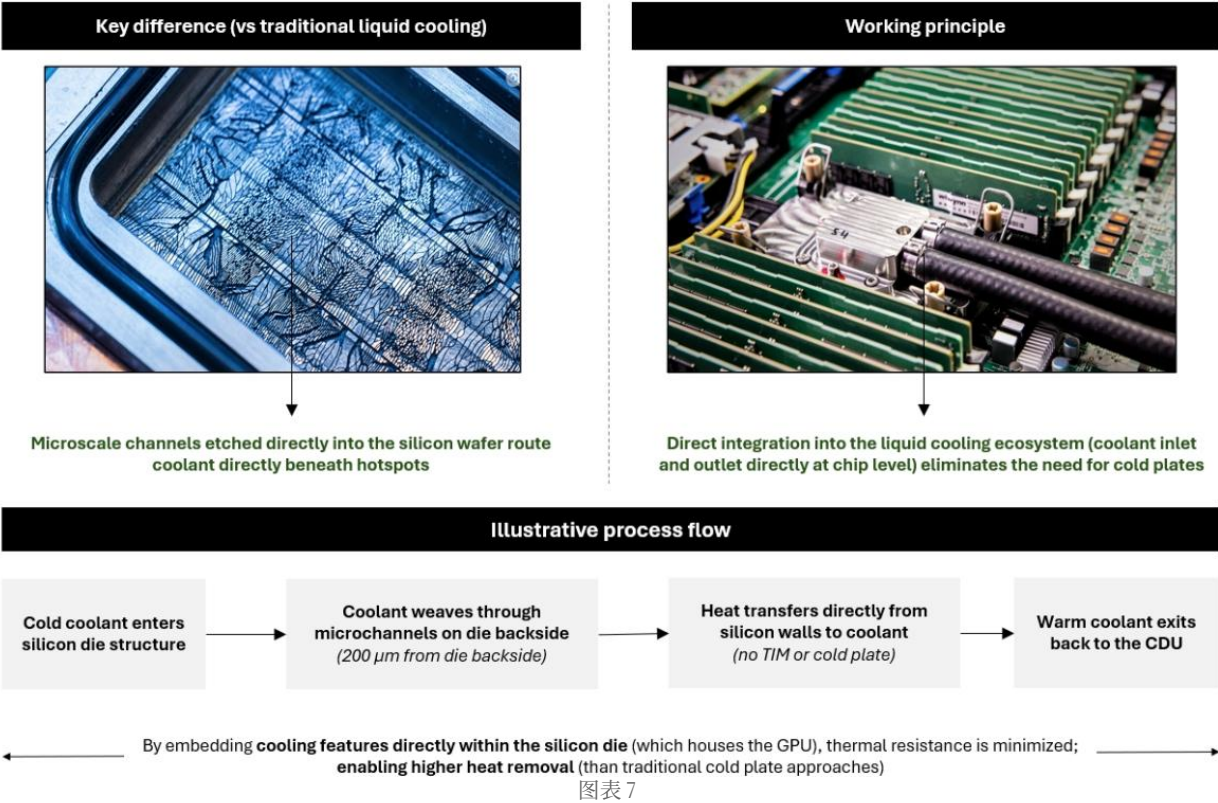
直接到芯片液冷 概述

3/5

直接到芯片（D2D）是传统液冷生态系统的新时代演进，其中冷却液被显著地更靠近发热的芯片晶体管。热量并非通过热界面材料（TIM）和冷板传递，而是直接在硅晶圆（芯片所在之处）上蚀刻出微通道。冷却液随后流经该通道阵列，几乎在源头处带走热量。

因此，D2D冷却也简化了热管理堆叠。随着冷却结构在物理上与芯片封装集成，对传统冷板（如当前所用）的需求可以减少，甚至从根本上消除。随着GPU热设计功耗（TDP）持续上升，该架构提供了一条潜在路径，以支持未来几代可能难以仅依靠传统基于冷板的单相和两相直接接触冷却（DTC）来管理的TDP。

图8：直接到芯片冷却 | 它意味着什么，为何重要？



图表 7

通过将冷却功能直接嵌入硅芯片（容纳GPU的芯片）内，热阻被最小化；从而实现比传统冷板方法更高的热量移除能力 资料来源：Bernstein分析

直接到芯片的优势

直接到芯片冷却的主要优势在于热阻的降低。通过将冷却液带到距离有源晶体管微米级的范围内，热量在扩散到整个封装之前就被移除，从而实现了比传统冷板设计显著更高的热量移除能力。这使得该技术对下一代GPU架构特别有吸引力，因为其热设计功耗（TDP）正在快速增长。

另一个主要优势是热点管理——传统液冷可能导致芯片表面出现局部（非均匀）的温度峰值（由于非均匀发热）。D2D系统将冷却液直接引导至高功率区域下方，实现有针对性的热量移除，并改善GPU表面的温度均匀性。

此外，使用精细蚀刻的微通道创造了巨大的传热表面积，在不增加封装尺寸的情况下提高了冷却效率。该方法还消除了热界面材料（TIM）及其相关的热阻。从设施角度来看，与传统液冷方法相比，直接到芯片冷却可以实现更高的冷却液入口温度（高达45 °C）。这可以减少对冷水机组的依赖，提高电能使用效率（数据中心运营效率的衡量指标），并总体上支持更节能的数据中心运营。

直接到芯片的挑战

最大的挑战是制造复杂性。在硅晶圆内创建精确的微通道阵列需要先进的半导体制造工艺，如深反应离子刻蚀（DRIE），这会为整个流程增加工艺步骤、良率考量和成本。与传统冷板不同，冷却结构从一开始就与半导体

封装紧密结合，增加了设计和制造的复杂性。

冷却液质量要求也显著更为严格。由于冷却液流经距离有源硅极近的区域，污染物和颗粒积聚可能损坏芯片表面或损害长期可靠性。这通常需要半导体级别的回路洁净度、更严格的过滤标准，以及比传统液冷系统更严格的流体管理。


另一个挑战涉及不确定性管理和机械可靠性。精细蚀刻的微通道比更大的冷板结构产生更高的流动阻力，可能增加泵送需求并导致功耗。封装密封的完整性和长期可靠性变得更加关键，因为冷却系统直接集成在封装架构内。

谁在研发方面处于领先地位？

D2D仍处于非常早期的成型阶段，更不用说商业化。在已公开披露的努力中，微软和Corintis提供了一些最有力的概念验证，展示了蚀刻在GPU芯片背面的仿生（叶脉架构）结构。该原型实现了超过1000 W/cm² 的热容量性能，同时使用去离子水并消除了对TIM的需求。台积电是另一个宣布在该领域取得进展的主要参与者。通过其CoWoS生态系统，该公司展示了一种在硅表面直接蚀刻微通道的结构。

目前，业界似乎将D2D视为一种长期扩展解决方案，而非传统冷板冷却的即时替代品。随着GPU TDP持续攀升，商业化（以及随后的采用）可能会加速，尤其是在热约束成为未来性能提升主要瓶颈的环境中。目前的部署似乎仍是理论性的，大多数解决方案处于原型设计、验证或早期试点阶段。

图9：直接到芯片的热优势部分被制造和运营复杂性所抵消



图表 8

资料来源：Bernstein分析

图10：直接到芯片正缓慢但稳步地从概念阶段走向可制造阶段

资料来源：Bernstein分析

图11：总结 | 直接到芯片冷却是否是更好的技术？


资料来源：Bernstein分析

单相——理论极限真实存在吗？

CoolIT 近期（2026年6月初）发布了一份关于15kW单相冷板的白皮书。结合背景来看，市场共识似乎认为，在Rubin与Rubin Ultra之间的某个节点（当每颗GPU的TDP开始超过约2.5kW时），需要转向两相DTC。然而，如果相信CoolIT的技术，我们实际上在未来十年的大部分时间里都无需切换（假设芯片TDP持续上升）。根据我们的研究，这里唯一的专有工程是CoolIT的“分流”技术。这似乎是一种设计解决方案，能让冷却液更快速地到达GPU的较热区域（从而带来更好的热效率和更低的阻力）。结果基于1.2升/分钟的流速以及白皮书中所述的“行业领先的内部几何结构、经过验证的大规模制造技术和标准导热界面材料（此处为导热膏）”发布，因此我们认为除了这项技术之外，并无其他特别差异化的地方。这也基于45 ° C的入口冷却温度（因此符合NVIDIA预期的运行条件）。如果情况如此，我们认为这降低了冷板被直接芯片冷却取代的生存不确定性。数据中心电力/冷却方面的大多数技术创新都是因为需要而发生的，而不是因为它们能带来边际改善（例如液冷和800V直流），因此如果冷板能处理每颗GPU 15kW的功率，我们确实看不到在两相（因此像Accelsius或Zutacore这类两相领域的私营企业，客户兴趣可能会下降）或直接芯片冷却（目前仍基本处于概念阶段）方面继续创新的必要。研发资金最好花在其他地方。我们纠结的问题是，为什么其他厂商无法匹敌CoolIT的产品。分流技术是否如此独特（已获专利），以至于液冷领域的其他公司无法复制类似版本？CoolIT显然是在其测试生态系统中的标准操作条件下运行的。我们听说，与之前公布的4kW单元相比，这款15kW冷板的表面积略大，这解释了部分性能提升，但肯定无法解释4倍的提升，因此其中肯定还有更多门道。我们很想知道这将如何转化为CoolIT（以及艺康，如果交易完成的话）的订单。这款15kW冷板仍作为概念进行测试（因此尚未进行大规模制造），我们很想知道该单元的宏观环境性和定价与其他冷板制造商相比如何（市场对此缺乏可见性）。我们并不是说两相或直接芯片冷却永远不会发生，但如果该产品被证明在商业上可行（我们对技术可行性有信心），它很可能会推迟其他技术的应用，因为继续使用单相冷却是阻力最小的路径。

图表12：CoolIT 15kW冷板概览（1/2）

单相DTC的潜在突破 | CoolIT的15kW冷板



图表 9

于2026年6月初在Computex上展示，CoolIT宣布开发出一款15kW单相冷板设计（冷却能力约为现有冷板的4倍）

来源：Bernstein分析， 公司报告

专有的“分流”微通道架构产生两股反向流动的冷却液流：改善了GPU芯片上的温度均匀性，并提高了传热效率（从GPU到冷却液）


与此相辅相成的是“可变翅片间距刨削”冷板设计，在热点区域具有更高的翅片密度，而在其他区域具有更低的流动阻力

该平台支持高达45 ° C的冷却液入口温度，并具有标准的流量和导热膏规格

结果是一个热优化架构，同时提高了冷却能力并降低了压降损失

尽管目前已在热测试平台上验证，但规模化部署可能会显著提高单相DTC的可行热通量，将相关性延续到2030年代的下一代GPU平台

图表13：CoolIT 15kW冷板概览（2/2）



图表 10

来源：Bernstein分析与估算， 公司报告

评论：公司情况更新

1 在受控实验室环境中演示

- 商业规模的可制造性和部署宏观环境性有待验证

2 在更大的芯片封装上实现

\- 演示中使用的芯片大于传统GPU芯片，从而提供了更大的吸热表面积

3 在行业标准操作参数下实现的性能

\- 标准冷却液流速（约1.2升/分钟/千瓦）

- 标准冷却液（PG25）

\- 分流架构（冷却液进入冷板时分成两路）

4 大大降低了对未来十年两相DTC和直接芯片冷却的需求

\- 通过在单相内实现15kW热容量，该演示实质上延长了DTC液冷在下一代AI基础设施中的可行性

对CDU/冷板生态系统的更广泛影响？

我们认为，从长远来看，CDU和冷板都将面临产品同质化。我们从入门报告（冷板、CDU）中得出的观点是，冷板面临的不确定性更大，因为它们没有CDU那样的服务附加功能来推动基于安装基础的多年前市场收入。然而，我们认为这种同质化不会立即发生，原因是技术转变（如单相到两相，这使OEM能够增加创新溢价）、不断提高的运行要求（更高功率额定值、更低的接近温度差）以及供应链限制（需求仍超过产能）。我们还认为，如果直接芯片冷却等技术长期成为主流，冷板存在过时不确定性。

15kW冷板的存在改变了这一考量。我们确实认为同质化的时间线可能会提前，因为它消除了OEM在可预见的未来构建两相解决方案的需求。这进而使超大规模数据中心能够越来越多地指定设计方案（无论是CDU还是冷板），因为他们现在拥有了一条能为GPU TDP提供充足余量的冷却路线图。供应短缺和不断提高的性能要求仍然为抵御同质化提供了防御，但从我们的角度来看，防御能力确实有所减弱。同质化的速度还取决于（i）CoolIT能否以正确的单位宏观环境性大规模生产这些产品，以及（ii）竞争对手能以多快的速度达到CoolIT的性能标准。从更积极的方面来看，15kW冷板的开发也降低了过时不确定性，因为数据中心运营商不必被迫转向直接芯片冷却（这会增加显著的复杂性）。

总体而言，我们对冷板单元（CDU）的中长期看法更为谨慎（对2028年之前的预期不变），并对冷板保持中性看法（加速的商品化不确定性被较低的过时不确定性所抵消）。