

KC桌面——外资精译

GS：从KimiK3看中国AI模型新前沿-从成本效率到定价权

从成本效率（DeepSeek）、模型智能提升（GLM）到Kimi K3的新前沿/定价权

7月17日，Kimi K3开源权重模型发布，拥有2.8万亿参数，根据Arena.ai编程排名和Artificial Analysis Intelligence评分（图表1），该模型在编程和某些智能体能力方面树立了全球新前沿。相应地，我们注意到K3的定价在中国模型中创下新高，混合每百万token 2.3美元，而Qwen3.7 Max为1.4美元/智谱GLM5.2为0.9美元/MiniMax M3为0.22美元/DeepSeek V4 Pro为0.18美元，但仍低于全球最先进模型（图表3）。

正如我们在近期中国大语言模型入门报告中强调的，我们认为中国AI开源/开源权重模型正达到全球扩散的智能性能临界点。展望2026年下半年，我们预计竞争可能通过编程数据飞轮和规模化（向更大模型发展，参数规模达2-5万亿）在高端编程领域加剧。我们认为知识图谱/智谱（我们近期以公司观点首次覆盖，7月17日下跌28%）和MiniMax的报价反应源于对中国AI模型竞争以及潜在长期赢家的担忧，因为竞争格局/模型公司领导力的可持续性仍高度动态。

我们继续指出，独立AI模型公司在我们的竞争定位框架中脱颖而出。我们还注意到中国国家主席习近平在上海举行的世界人工智能大会开幕式上讲话的积极信号，他将AI的社会影响与电力和蒸汽机的发明相提并论，并表示中国将以持续开放的态度向发展中国家提供技术基础设施，同时也提醒需要人类监督/控制和不确定性缓解。

接下来关注什么？正如我们在LLM入门报告中强调的

工具链/智能体应用：我们预计中国AI模型公司将日益聚焦于将其工具链/智能体应用定位为关键入口，尤其是在编程领域（例如智谱的ZCode、腾讯的Workbuddy和阿里巴巴的Qoder，这些是支持全套AI模型的聚合平台），因为模型公司试图闭环以获取更多真实编程和智能体数据用于规模化。协同工作和行业专家智能体产品可能是下一个优先方向。

■ 多个大参数高端编程模型发布以及可能对中国以外地区获取最先进中国AI模型的更严格限制：在Kimi K3发布后，我们预计2026年下半年将有更多新的中国AI模型发布（智谱GLM、阿里巴巴Qwen、MiniMax M3 Pro等），中国AI模型参与者的总参数规模将显著扩大至2-5万亿。

编程/程序开发领域的竞争将保持激烈。多模态/视觉理解的加入也将是中国AI基础模型的下一次升级。

低端智能体聚焦领域的API定价持续受压：我们预计API定价及因此的毛利率在下半年的低端定价区间（每百万token约0.1-0.2美元）将继续面临不确定性，因为中国AI模型参与者在融资后拥有大量现金储备来补贴竞争性定价。因此，我们将财务实力视为评估中国AI模型公司的三个最重要指标之一（另外两个是定价权和成本效率）。

多模态/视频生成模型将通过全球采用实现ARR进一步加速增长：我们预计视频生成领域（不同于基础文本模型）将继续保持健康的行业定价和毛利率，其中关键参与者字节跳动的SeeDance（据报道毛利率70%，最新ARR运行率20亿美元）、快手的Kling和MiniMax的Hailuo/即将推出的H3模型将在2026年下半年享受健康增长，这得益于新功能突破（视频生成与LLM的结合）以及需求远超容量的紧张计算资源。

我们还预计国内ASIC供应增加、对中国未来最前沿模型在海外市场的任何更严格准入、西方市场对中国模型的政策、以及模型训练中高端计算的获取，将是我们中国AI模型token/收入增长轨迹的关键摇摆因素/不确定性。

我们的核心观点/公司选择


■ 在云与数据中心（我们在中国互联网中的首选子板块）中，我们继续强调核心观点（阿里巴巴、万国数据、世纪互联和金山云），这得益于2026年下半年AI超大规模资本支出的增加。

■ 在AI模型中，我们强调MiniMax具有偏向上的不确定性回报。MiniMax改善其整体竞争定位的关键摇摆因素将取决于其近期完成融资（增强了财务实力）后的定价权。我们预计其H3视频生成模型表现（即将在比文本模

型更有利的行业格局中推出）以及其下一次M3更新的上市时间（专注于通过后训练/强化学习进一步提升编程智能水平，我们估计M3更新在7-8月，以及2026年下半年早些时候更大参数规模的M3 Pro模型）将是下一个关键驱动因素。


另见我们近期报告

- 导航中国AI模型：LLM入门报告：全球扩散的智能临界点，2026年7月10日
 - 知识图谱科技（2513.HK）：以1100亿美元估值首次覆盖；中国顶级企业/编程AI模型，2026年7月10日
 - MiniMax集团（0100.HK）：股份解禁后的关键关注点；不确定性回报偏向上行；买入，2026年7月10日
- 图表1：Code Arena已更新其全球排名... 截至2026年7月16日的最新评分和模型排名




图表 1

图表2：...Artificial Analysis Intelligence指数也达到/接近全球最先进水平 Artificial Analysis Intelligence指数




图表 2

图表3：Kimi K3因模型智能和参数规模提升而提高了混合API定价



图表 3

图表4：完成AA Intelligence基准测试的总成本上升3倍，与API提价幅度相同 每任务成本（美元）



图表 4

图表5：主要LLM实验室/模型的竞争定位分析



图表 5

*Tencent Hunyuan: Strong contender after AI strategic revamp;
potential in Weixin AI agent*



图表 6

MiniMax M系列：独立参与者中独特的全模态能力；成本高效的计算架构



图表 7



图表 8

DeepSeek：极致成本效率以在竞争性定价下维持可扩展的token使用量



图表 9

Kimi K系列



图表 10

不适用：私营公司估值倍数

图表6：AI模型参与者的竞争定位框架

Key themes	Chinese models reaching critical stage of intelligence for wide adoption across agentic tasks/specific coding scenarios			Fragmentation between China AI models but strong to get stronger; pricing power to come from frontier performance/multi-modal			Agentic AI driving higher demand for value-for-money models/SLMs		Access to computing, where balance sheet and inference efficiency are key	
Drivers of corporate performance	Competitive positioning									
CP category	Pricing Power			Cost advantage				Financial strength		
CP metrics	Time to market	Arena score	Pricing	Token volume	Throughput /Cache hit rate	Parameter size/ activation ratio	Inference GPM	Cash on hand	Net cash as % of asset	Valuation multiples

图表 11

公司情况更新

我们对MiniMax更新公司观点。估值基于DCF模型，假设WACC为12%，终值增长率为2%。

主要不确定性：在全球基础模型行业竞争中，模型表现不及预期；盈利可见性路径慢于预期；商业化能力弱于预期；知识产权/内容生成相关不确定性；现金消耗/自我融资能力；中美科技竞争加剧背景下的地缘政治不确定性。

公司情况更新

我们对知识图谱科技更新公司观点。估值基于DCF模型，假设WACC为12%，终值增长率为2%（与覆盖范围一致）。

主要不确定性：(+) 模型智能程度强于预期，(+) 盈利可见性路径快于预期，(+)

额外的非推理服务收入来源，(+) 商业化能力强于预期，(-) 全球基础模型行业竞争，(-)

高研发费用导致短期盈利可见性有限，(-) 现金消耗/自我融资能力，(-)

中美科技竞争加剧背景下的地缘政治不确定性。

公司情况更新

估值方法：我们对腾讯（0700.HK）更新公司观点。

主要不确定性：效果广告行业竞争加剧，游戏发布/版号审批意外延迟，资金科技与云业务增长节奏变化，AI发展进度慢于预期，再研究不确定性。

公司情况更新

估值方法：我们对BABA/9988.HK更新公司观点。

主要不确定性：(1) 宏观/竞争导致GMV增长低于预期；(2) 中国零售业务变现慢于预期；(3)

关键战略研究执行弱于预期；(4) 云业务收入增长节奏变化。