

KC桌面——外资精译

NOM：中国AI实验室Moonshot推出高性价比大语言模型 KimiK3

Kimi K3——一个 2.8T 参数的开源 SOTA

大语言模型，在世界人工智能大会前发布，瞄准大语言模型无尽竞争格局中的前沿地位

2026 年 7 月 16 日，即 WAIC（世界人工智能大会，中国旗舰级 AI 会议）2026 在上海开幕的前一天，中国领先的 AI 实验室之一 Moonshot AI（未上市）发布了 Kimi K3（完整模型权重将于 7 月 27 日发布）——一个 2.8

万亿参数的开源大语言模型。Kimi K3

是迄今为止最大的开源大语言模型，其主要特性包括原生视觉（多模态）支持、100 万 token

上下文以及始终在线的推理能力。基于其 Kimi Delta Attention 和 Attention

Residuals，以及规模放大的混合专家架构（图 1），K3 的整体扩展效率相比 Kimi K2 提升了 2.5 倍。在 Artificial Analysis 的独立智能指数中，K3 得分为 57，在 189 个模型中排名第 3-4 位，落后于 Claude Fable 5 和 GPT-5.6

Sol（Moonshot 自身也承认存在差距），但与 Claude Opus 4.8 和 GPT-5.5 持平（图 2）。K3 定价为每百万 token 输入 3 美元（缓存命中 0.30 美元），每百万 token 输出 15 美元，即每任务约 0.94 美元——大约是 Opus 4.8

的一半和 Fable 5 的三分之一（图 3），但约为 K2.6（Moonshot 之前的旗舰模型）的 4

倍，标志着从低成本大语言模型向高性价比大语言模型的转变。

Kimi K3 如何改变大语言模型竞争格局？中国的大语言模型厂商会颠覆全球市场吗？

K3 的关键突破在于该模型是为长期自主工作而设计的，而不仅仅是聊天。在 Moonshot AI

的官方网站上，有关于复杂自主任务的用例，包括一个 48 小时无人值守的芯片设计流程、端到端的知识工作、以及带有交互式可视化的深度行业研究。例如，在我们看来，Kimi K3 现已与智谱（2513 HK，未评级）、DeepS

eeek（未上市）等一起，加入了全球市场的中国精英大语言模型俱乐部，并且它们的目标市场现在横跨整个价格区间（高端/宏观环境型/低端）。在每任务成本方面，K3（0.94 美元）与 GPT-5.6 Sol（1.04 美元）持平，远低于

Opus 4.8（1.80 美元）和 Fable 5（约 2.75 美元），但远高于 GLM-5.2（0.32-0.47 美元）和 DeepSeek V4 Pro（0.04 美元）。根据 Open Router 的统计数据，中国模型已占据全球开发者 token 总量的 45% 以上（一年前不到 2%，

链接）。我们认为，中国的大语言模型厂商（包括闭源和开源）将继续在全球市场获得吸引力，提供高性价比的模型，以满足广泛 IT 工作负载的需求。同时，我们认为，全球顶级大语言模型也可能加速创新，瞄准最复杂

的工作负载（即科学领域），并维持其技术和定价溢价。此外，由于地缘政治不确定性和脱钩趋势，我们认为主权 AI 趋势将变得更加流行，因为大多数国家/企业会发现，未来仅依赖少数精英俱乐部来承担所有生成式 AI

工作负载不确定性太大。因此，我们认为，只要能够保持在技术曲线的前沿，来自中国和美国的领先大语言模型厂商都将蓬勃发展。

这是 DeepSeek 时刻 2.0 吗？全球 AI

供应链需求会被削弱吗？我们对计算、网络、IDC/云以及软件/应用的想法。7 月 17

日，市场经历了大幅下跌，尽管抛售在 K3

发布之前就已开始，但我们认为该事件是加剧抛售的另一个催化剂，因为在我们看来，它可能唤起了人们对 1.5 年前 DeepSeek R1 发布的糟糕回忆（见我们的报告：我们对 DeepSeek

大语言模型的看法）。我们认为，来自一家受先进芯片供应限制的中国 AI

实验室的前沿模型的崛起，进一步引发了市场对全球 AI 供应链中计算能力需求的怀疑。然而，我们认为全球

大语言模型市场的竞争与创新不会停止，因为我们正越来越接近实现通用人工智能，这可能导致生成式 AI

应用在消费者和企业市场得到更广泛的采用。前沿 AI 实验室和超大规模 AI

云平台公司都可能在此阶段继续研究以留在牌桌上，并且随着规模定律的持续，我们将这种竞争解读为对 AI 基础设施价值链的利好。

对于计算领域，我们相信预训练和后训练的规模定律仍然有效，领先大语言模型厂商之间的激烈竞争将支撑对先进计算能力的持续强劲需求。在我们最近的亚洲 AI 半导体与服务器报告中，我们指出，鉴于超大规模企业到 2027 财年的支出仍有上行空间（尽管自由现金流不足），以及我们全球新建数据中心追踪显示还有进一步上行空间，AI 周期尚未达到周期顶峰。我们重申对以下公司的观点：1) 台积电（2330 TT，AI 芯片赋能者），2) 日月光投控（3711 TT，来自 WoS 和 CoW 的上行空间），3) 信骅（5274 TT，直接的 CPU 受益者），4) 联发科（2454 TT，TPU 上行空间），5) GWC（6488 TT，Feynman 中的 SiC 机会），6) 京元电子（2449 TT，AI 芯片测试受益者），7) EMC（2383 TT）/TUC（6274 TT），受益于 AI 升级趋势且作为主要供应瓶颈之一享有更多价格上行空间的 CCL，以及 8) ZDT（4958 TT），一家新兴的 AI PCB/HDI 制造商。我们的韩国科技分析师 CW Chung 还指出，由于 AI 行业前所未有的强劲需求，全球内存行业正经历非常严重的短缺状况，他首选的公司是三星电子。

对于网络领域，我们认为存在来自大规模 AI 工厂和对超级节点需求的结构性感赢家，我们看好：1) 光模块及组件领导者中际旭创和苏州天孚通信；以及 2) 光芯片供应商源杰科技（688498 CH，中性）。

对于 IDC 和云领域，我们看好能够构建繁荣 AI 云生态系统的公司，例如阿里巴巴。我们也看好可能受益于大型 AI 云公司资本支出增长的 IDC 运营商，包括万国数据和世纪互联。


对于软件和应用领域，我们认为大语言模型的颠覆性影响仍存在不确定性，但一些能够利用生成式 AI 解决方案并加强其行业“护城河”的垂直领域领导者可能在长期内脱颖而出。我们看好该领域的金蝶和金山办公。

Kimi K3 概览：架构、用例、定价与性能

首个开放的 3T 级模型，专为扩展效率而构建


K3延续了Moonshot在开放前沿领域的探索——据公司介绍，其模型基于Kimi Delta Attention和Attention Residuals架构，具备原生视觉能力和100万token上下文窗口，将开源大语言模型的数量上限提升至2.8T。根据Moonshot官网，Kimi K3构建于其Kimi Delta Attention（KDA）和Attention Residuals（AttnRes）两项架构更新之上，旨在改善信息在序列长度和模型深度上的流动。K3还提升了混合专家模型（MoE）的稀疏性，在配合Stable LatentMoE框架时，有效激活896个专家中的16个。结合优化的训练策略与数据配方，这些结构变化使得整体扩展效率相比Kimi K2提升约2.5倍，让模型能更高效地将算力转化为智能。

图1：Kimi K3架构



图表 1

Kimi K3架构：Stable LatentMoE与KDA模块（左）， AttnRes运算 α （右上）， 以及Block Attention Residuals主干（右）。 来源：公司数据



图表 2

来源：Artificial Analysis

图3：能力与价格评分卡——K3与其他前沿模型对比

来源：公司数据

应用场景：长周期编程、知识工作与数字创作

据公司介绍，Kimi K3的功能包括长周期编程、内核优化、游戏开发与数字创作等。Kimi K3在长周期编程方面表现强劲，可在极少人工干预下运行，维持长时间工程会话，浏览大型代码仓库，并编排终端工具。据公司称，Kimi K3还擅长结合软件工程与视觉推理的任务，利用截图和视觉信息优化游戏开发、前端和CAD设计。

- 自主编程与系统工作。公司在其官方博客上展示了多个自主编程与系统工作的应用案例：(i) 在H200和另一供应商GPGPU上，针对四项任务（AttnRes、KDA、一个512头维度的MLA内核）进行24小时沙盒化GPU内核竞赛，K3与Fable 5（含回退机制）竞争力相当，并大幅领先Opus 4.8、GPT-5.6 Sol和GPT-5.5——值得注意的是，早期版本的K3承担了团队自身大部分内核优化工作；(ii) MiniTriton，一个从零构建的类Triton GPU编程编译器（基于MLIR的瓦片级IR、PTX代码生成）；(iii) 在开源EDA（Nangate 45nm）上进行的48小时无人值守芯片设计运行：面积4mm²，时序收敛于100MHz，1.46M个单元，针对自身架构的纳米模型模拟解码速度超过8,700 tok/s。
- 知识工作。生产级案例：一个交互式42年ASIC行业研究网站，经过120多轮递归自我改进（2,800多次网页抓取、87份季度报告、99份PDF）；一次涉及20多个并发子代理的391个事件引力波分析；天体物理代码复现（I – Love – Q关系），将预计一到两周的专家工作量压缩至约2小时；原生多模态视频编辑，包括从56个源片段剪辑自己的预告片。
- 游戏开发与数字创作。Kimi K3使用Three.js WebGPU和GPU计算，构建了一款完全程序化生成的浏览器端3D探索游戏。它程序化生成了环境，同时使用3D资产生成工具创建骑手和马匹模型，打造了一个包含森林、木屋村庄、雪山和动态天气的广阔开放世界。

AI供应链影响：全球与中国

我们认为，来自中国AI实验室的前沿模型（该实验室一直受制于先进芯片的供应限制）的崛起，进一步引发了市场对全球AI供应链算力需求的质疑。然而，我们认为全球大语言模型市场的竞争与创新不会停止，因为我们正越来越接近实现通用人工智能（AGI），这可能导致生成式AI应用在消费和企业市场得到更广泛的采用。前沿AI实验室和超大规模AI云平台公司可能都会在此阶段持续投入以保持竞争力，并且随着规模定律的持续作用，我们将这种竞争解读为对AI基础设施价值链的利好。

算力：规模定律依然有效，推理工作负载将加速增长

我们认为，Kimi K3的成功故事并未削弱对大语言模型训练的需求；相反，它强化了预训练和后训练的规模定律，因为更多算力可能带来更优性能。由于大语言模型尚未达到其性能极限，我们认为全球AI供应链对先进算力的需求将保持旺盛。具体而言，我们认为领先的大语言模型玩家将加速向最先进的GPU或ASIC平台迁移，以使其前沿模型的性能实现差异化。随着Kimi K3等领先大语言模型拓展其业务边界，我们认为推理工作负载将获得增长动力，ASIC供应链可能继续受益于这一趋势。我们重申对以下公司的观点：1) 台积电（2330 TT，AI芯片赋能者），2) 日月光投控（3711 TT，WoS和CoW的上涨空间），3) 信骅科技（5274 TT，直接的CPU受益者），4) 联发科（2454 TT，TPU上涨空间），5) GWC（6488 TT，Feynman中的SiC机会），6) 京元电子（2449 TT，AI芯片测试受益者），7) EMC（2383 TT）/台光电（6274 TT，受益于AI升级趋势的CCL，且作为主要供应瓶颈之一拥有更大价格上行空间），8) ZDT（4958 TT，新兴AI PCB/HDI制造商）。我们的韩国科技分析师CW Chung还指出，由于AI行业前所未有的强劲需求，全球内存行业正经历非常严重的短缺状况，他首选的公司是三星电子。

网络：大规模AI工厂与超节点需求的结构性赢家

Kimi K3已展现出在长周期编程/代理工作以及多模态应用（视觉设计、游戏开发、数字创作等）方面的强大潜力，这些都是高token消耗的工作负载。我们认为，大规模AI工厂的日益普及将支撑对先进网络技术和解决方案的强劲需求，这些技术和解决方案在大型AIDC集群中扮演着关键角色。更具体地说，对于中国的AI供应链而言，超节点已成为一个重要趋势，这有助于缩小中国计算芯片性能与全球同行之间的差距，从而为中国网络解决方案提供商带来结构性增长机会。我们看好全球AI网络领域的中际旭创和苏州天孚光通信。

IDC与AI云平台：承载更多前沿模型，构建繁荣生态

我们认为AI云平台可从大语言模型发展趋势中通过三种方式获益：1) MaaS（模型即服务）需求（大语言模型的大多数客户将通过一个或多个云平台消耗模型/代币）；2) 相较于独家闭源模型厂商拥有更强的议价能力（因其托管了多种先进开源大语言模型）；3) 更高的利润率提升潜力，因AI云平台提供强大生态系统，不仅包含云基础设施和大语言模型，还涵盖应用与服务层，可满足私有部署和合规要求的定制化需求。我们看好中国AI云生态中的阿里巴巴，同时认为万国数据/世纪互联是中国IDC领域的赢家，因其受益于前沿模型公司训练和推理工作负载对IDC基础设施日益增长的需求。

软件与应用：大语言模型颠覆性影响仍存不确定性，但具备更强"护城河"的企业将在长期脱颖而出

受市场对大语言模型颠覆性影响的担忧，软件与应用市场仍面临不确定性。我们认为前沿大语言模型的进步可能通过利用编码和智能体解决方案，降低小型AI初创企业或企业开发自有AI应用和软件的门槛，从而削弱众多通用软件和应用领域现有企业的竞争优势。但我们相信，能够适应生成式AI市场的垂直领域领导者最终将脱颖而出，并在长期成为AI赢家。我们看好中国软件领域的金蝶国际和金山办公。

附录A-1：公司情况更新