

KC桌面——外资精译

JEF：K3发布后中国互联网七大要点-串联模型云与应用

要点 (1) 月之暗面：K3 的智能远未触及上限。次日 ARR 增速最快；(2) 更多万亿参数级中国模型（如 Qwen3.8、2.4T）即将到来；(3) 智谱与阶跃星辰的最新动态；(4) 算力是近期融资的关注焦点 /KC 预览 (链接)；(5) Token 支出指数依然疲软；(6) 视频模型格局未见显著变化；(7) 腾讯"元宝"势头渐起；(8) 更新公司观点阿里巴巴的全栈能力

在本报告中，我们为读者提供以下数据点：各公司模型定价、中美定价对比、来自 Artificial Analysis 的模型智能水平、OpenRouter 中的 Token 消耗量、Token 支出指数趋势及其他行业数据，以供分析。

在竞争中缩小差距。读者惊讶地看到 K3 (链接) 达到了新的智能里程碑，并在不同指标上位列前茅。根据 Arena (图表 5)。这是中国模型首次在 Frontend Code Arena 中领先于美国模型，而 2025 年初 (DeepSeek-R1 是最后一个接近美国模型的中国模型)。读者的反馈更多是关于智能差距的缩小，并预期未来几个月将有更多中国模型 (图表 2) 达到万亿参数级别。在供应受限的情况下，中国模型预计将在智能与易用性之间取得平衡。

月之暗面：模型智能远未触及上限。次日 ARR 达到最快增速。据《科创板日报》报道，总裁张先生强调：(1) Scaling Law 依然有效。尽管相比 K2.6 有巨大进步，但 K3 并非最智能的模型；(2) 谈论模型智能的上限还为时过早；(3) K3 发布后次日，ARR 经历了最快增速。

智谱与阶跃星辰关于行业趋势的最新策略。(1) 智谱：(a) Scaling Law

在数据、环境、强化学习和基础设施方面持续加速。(b) GLM-5.2 的参数比 K3 少。当规模达到 K3 水平时，其能力可以超越 K3。详情请参阅第 2 页；(2) 阶跃星辰：在世界人工智能大会期间 (a) Agent 成为生产力的原子单位；(b) AI 与终端的融合是下一个重点；(c) AI 编程超越人类；(d) Agent-to-Agent 是下一个互联网

算力是近期 AI 实验室与金山云融资的关注焦点 /KC 预览。近期 AI 实验室的融资 (链接) (1) DeepSeek (70 亿美元，2026 年 6 月)；(2) 智谱 (40 亿美元，2026 年 7 月) 和 (3) MiniMax (20 亿美元，2026 年 7 月)。我们认为，在需求激增的情况下，新融资可以加强各自的计算需求。对于金山云，我们略微调整了第二季度的收入预期，考虑到供应限制问题，资本支出更多发生在 6 月而非 4 月/5 月 (链接)

Token 支出趋势表明高成本效益模型至关重要。根据硅数 LLM Token 支出指数 (图表 4)，该指数在 7 月 12 日当周继续保持在 1.56 至 1.61 的疲软区间 (7 月 5 日当周为 1.63 至 1.65)，而 5 月 31 日为 2.04。根据 Artificial Analysis，中国模型相比美国模型具有极高的成本效益，API 成本仅为美国模型的一小部分 (图表 3)。我们研究了 (1) 各模型的混合价格与智能水平对比 (图表 1)。近期美国/中国科技公司的行业趋势显示，关于 Token 最大化与 Token 支出的争论意味着，在编程和 Agentic AI 领域，成本效益模型正变得越来越重要。

视频生成模型格局未见显著变化。据 Kimi

联合创始人周新宇先生称，当前重点是模型智能，视频生成模型并非首要任务。据 6 月的火山引擎大会 (链接) 称，其发布了 Seedance 2.5，并认为视频

接下一页……

生成占 MaaS 收入的一半以上

(链接)。另一方面，可灵筹集了新融资，将用于业务扩张、日常运营、营运资金、团队发展等 (链接)

腾讯"元宝"势头渐起。在应用方面，我们预计腾讯"元宝"将继续获得增长动力。根据易观分析 (链接)，其强调了 2026 年 3 月"元宝"在该细分领域的运营指标。这些指标包括：(1) 桌面端月访问量达到 885 万；(2) "元宝"领先于 Trae (字节跳动)、QClaw (腾讯) 和 Qoder

Work (阿里巴巴)。另一方面，阿里巴巴在世界人工智能大会期间发布了 Meoo (多元化 AI 企业应用)。百度则在世界人工智能大会期间展示了多项 AI 应用，如百度网盘、百度文库和小度


(链接)。此外，金山办公上周举办了 AI 生产力大会，并发布了 AI 产品灵犀专业版和 WPS AI Hub (链接)

接下来值得期待的是什么？这些包括：(1) 随着模型迭代周期缩短至不到 3 个月，我们预计即将推出的模型包括通义千问（Qwen 3.8、2.4T）、MiniMax（M3 Pro）、智谱（GLM）和腾讯（混元 4）。阿里巴巴强调，Qwen3.8 是一个开放权重模型（总参数 2.4T），将在近期发布。其 Qwen3.8-Max-Preview 模型已在 Token Plan、Qoder 和 Qoder Work 中可用。它也可在通义千问的 PC 端和移动端使用；(2) 多家公司预计将在 2026 年或 2027 年初实现超过 10 亿美元的 ARR：(a) 阿里巴巴；(b) 智谱；(c) MiniMax；(d) 可灵；(e) 火山引擎。我们预计 K3 发布后，Kimi 的 ARR 值得关注。我们认为阿里巴巴凭借其在模型、云、芯片和应用方面的全栈能力将脱颖而出。

智谱：电话会议要点

- Scaling Law 持续加速。这可以从 OpenAI 和 Anthropic 在通往 AGI 道路上取得的突破中看出。
- 对 K3 的看法。(1) K3 在规模化方面是成功的，接近全球前沿模型；(2) GLM-5.2 的参数比 K3 少 (图表 6)。预计当其规模达到 K3 水平时，其能力将超越 K3。
- GLM 系列。(1) 2026 年 2 月：GLM-5 对比 GLM-4 系列。参数量翻倍，预训练 30T tokens，并采用 DSA 架构；(2) 2026 年 4 月/6 月：发布了 GLM5.1/5.2 版本。(a) GLM5.1 强调长程任务；(b) GLM-5.2 将上下文长度扩展至 100 万，并能处理复杂的编程工作；(c) 下一个版本 GLM-5.3 将有小幅迭代，提供更好的编程体验；(d) 下一个模型系列将采用新架构，规模更大，同时保持成本效益。

图表 1 - Artificial Analysis 智能指数 vs 混合价格




图表 1

来源：Artificial Analysis, JEF

图表 2 - 不同旗舰模型的总参数量

来源：JEF


图表 3 - 中国模型 vs 美国模型的混合价格（2026 年第二季度）



图表 2

来源：Artificial Analysis, JEF


图表 4 - 硅数 LLM Token 支出指数



图表 3

来源：彭博, JEF

图表 5 - 截至 7 月 13 日的过去 12 个月每周 Token 消耗量（万亿）




图表 4

来源：OpenRouter, JEF

\- 规模化中的多个领域。包括：(1) 数据；(2) 环境；(3) 强化学习；(4) 基础设施。在数据方面，涵盖预训练/中训练，且 SWE 规模化可自动创建编码智能体环境。在强化学习方面，使用 SAO 技术相比 GRPO 优化能带来更高准确性，尤其是在长周期任务中。在基础设施方面，(a) ZCube 对比 Clos：成本降低 33%，吞吐量提升 15%；(b) LayerSplit：减少 KV Cache，吞吐量提升 132%；(c) 预填充-解码分离；(d) DSA+IndexShare 提升效率。

\- 触及高点。在新模型之上，其他领域包括：(1) 大语言模型驱动的自主智能体系统；(2) 递归自我改进。


图表 6 - GLM-5.2 与 K3 对比



图表 5

来源：公司，JEF

图表 7 - 前端代码竞技场：美国 vs 中国



图表 6

来源：Arena WebDev 和 Code Arena 公开历史数据 来源：Arena, JEF


根据 Artificial Analysis, 中国模型（DeepSeek、Qwen、Kimi、MiniMax 和智谱）在智能水平上正缩小与美国模型的差距。中国模型在混合专家架构、线性注意力机制和模型算力利用率方面具有高成本效益。根据 2026 年斯坦福 AI 指数报告（2026 年 4 月），截至 2026 年 3 月，美国顶尖模型领先中国模型 2.7%。此外，Anthropic（1503）、xAI（1495）、Google（1494）、OpenAI（1481）、阿里巴巴（1449）和 DeepSeek（1424）占据了 Arena Elo 评级的第一梯队。

中国模型在智能水平上正缩小与美国模型的差距。在输入/输出 API 方面，中国大模型相比美国模型具有高效率。

图表 8 - Artificial Analysis 智能指数

Artificial Analysis 智能指数

Artificial Analysis 智能指数 v4.1 包含 9 项评估：GDPval-AA v2、 τ^3 -Banking、Terminal-Bench v2.1、SciCode、Humanity's Last Exam、GPQA Diamond、CritPt、AA-Omniscience、AA-LCR



图表 7

推理模型以灯泡图标标示 来源：Artificial Analysis, JEF


图表 9 - 每任务编码成本评估：K3 与全球同行对比 Kimi Code Bench V2 · 得分 vs 每任务成本



图表 8

来源：月之暗面, JEF


图表 10 - 每任务浏览成本评估：K3 与全球同行对比



来源：月之暗面，JEF


各公司模型输入/输出价格

图表 11 - DeepSeek：输入价格




来源：Artificial Analysis，JEF

图表 12 - DeepSeek：输出价格



图表 11


图表 13 - Kimi：输入价格 来源：Artificial Analysis, JEF



图表 12

来源：Artificial Analysis, JEF


图表 14 - Kimi：输出价格



图表 13

来源：Artificial Analysis, JEF

图表 15 - 智谱：输入价格




图表 14

来源：Artificial Analysis, JEF 注：GLM-5.2 在所有上下文长度下 API 价格相同，而 GLM-5.1 采用分层定价 图表 16 - 智谱：输出价格




来源：Artificial Analysis, JEF 注：GLM-5.2 在所有上下文长度下 API 价格相同，而 GLM-5.1 采用分层定价

图表 17 - Qwen：输入价格



来源：Artificial Analysis, JEF


图表 18 - Qwen：输出价格



图表 18

来源：Artificial Analysis, JEF


图表 19 - MiniMax：输入价格



图表 19

来源：Artificial Analysis, JEF 注：MiniMax-M3 的输入 token 数 > 512k

图表 20 - MiniMax：输出价格




图表 20

来源：Artificial Analysis, JEF 注：MiniMax-M3 的输入 token 数 > 512k

来源：Artificial Analysis, JEF 注：32k < 输入 token 数 <= 128k


图表 21 - 豆包 Seed：输入价格



图表 21

来源：公司, JEF 注：doubao-seed-2.0-pro、doubao-seed-1.8 的输入 token 数：128k < 输入 token 数 <= 256k


图表 22 - 豆包 Seed：输出价格



图表 22

来源：公司，JEF 注：doubao-seed-2.0-pro、doubao-seed-1.8 的输入 token 数：128k < 输入 token 数 <= 256k


图表 23 - 小米：输入价格



图表 23


来源：Artificial Analysis, JEF

图表 24 - 小米：输出价格



图表 24


图表 25 - 腾讯：输入价格 来源：Artificial Analysis, JEF



图表 25


来源：公司, JEF

图表 26 - 腾讯：输出价格



图表 26


图表 27 - 百度：输入价格



图表 27

来源：公司，JEF


图表 28 - 百度：输出价格



图表 28

来源：Artificial Analysis, JEF 注：32k < 输入 token 数 <= 128k

图表 29 - StepFun：输入价格



图表 29

来源：Artificial Analysis, JEF

图表 30 - StepFun：输出价格 来源：Artificial Analysis, JEF

图表 31 - OpenAI：输入价格 来源：Artificial Analysis, JEF

图表 32 - OpenAI：输出价格 来源：Artificial Analysis, JEF

图表 33 - Anthropic Claude Opus：输入价格 来源：Artificial Analysis, JEF

图表 34 - Anthropic Claude Opus：输出价格 来源：Artificial Analysis, JEF

图表 35 - Anthropic Claude Sonnet：输入价格 来源：Artificial Analysis, JEF

图表 36 - Anthropic Claude Sonnet：输出价格 来源：Artificial Analysis, JEF

公司估值/不确定性