

KC桌面——外资精译

NOM：我们预计KimiK3将为AI模型开发提供新路径

在后Transformer时代迈出第一步，推出开源大规模编程模型

Kimi K3：融合Transformer与循环模型的混合架构，实现突破性创新

Moonshot AI 于7月16日发布的Kimi K3已成为热门话题，其编程性能与美国前沿AI实验室模型相当。除此之外，其创新的混合模型结合了Transformer（多头潜在注意力；MLA）与循环模型（Kimi Delta Attention；KDA），这让我们感到惊讶。就技术行业的影响而言，我们认为Kimi K3的出现为中国开发AI模型的强大能力提供了新的证据，因为这款前沿的智能编程模型已经撼动了美国闭源模型的主导地位。

通过使用KDA的循环模型大幅减少KV缓存，实现长程推理

Kimi K3是一个拥有2.8万亿参数的混合专家（MoE）模型。它由896个专家组成，在进行推理时，路由器为每个token选择并激活16个专家。最大上下文长度为100万token，该模型专为长程智能编程而设计。

如上所述，该模型的核心是结合了Transformer与循环模型的混合架构。根据公司过往公告，我们推测注意力架构由四个层组成一个单元：三个KDA层和一个MLA层。Transformer模型会保存上下文窗口中所有tokens的键和值，并根据与查询的相似度分析必要数据，而循环模型则将过往数据压缩并更新为固定长度的状态，并通过引用该状态进行推理，从而大幅减少对KV缓存的依赖。众所周知，更长的KV缓存会导致：（1）解码期间计算和内存访问量增加，以及MoE模型GPU间通信负载增加，从而导致计算成本上升；（2）由于注意力广泛分散，难以聚焦重要信息，导致长上下文和长程推理性能下降。为此，Kimi K3中采用KDA旨在通过将token级数据更新为固定长度状态，同时实现计算效率和长程推理性能。我们认为Kimi K3引入MLA层是为了提供从KV缓存中引用无法存储在固定长度状态中的详细token级数据的能力，即使数据存储位置较远也能精确搜索和引用。

由于循环模型不依赖于上下文长度，因此非常适合在与环境持续交互的同时进行学习和推理的自主学习模型，我们曾认为它们可能在未来两到三年内被应用于前沿模型。尽管Kimi K3是一个混合模型，但该公司能够在大规模前沿模型中实现循环模型，这让我们感到惊讶。

行业影响：长期正面，但需注意短期资金流减弱不确定性

我们预计Kimi K3将为AI模型开发提供新路径，并推动AI行业的长期增长。尽管如此，短期内更激烈的竞争可能会延迟美国AI实验室开发的闭源模型的商业化，我们认为需要注意资金从AI实验室流向云运营商，再流向内存和存储等电子设备制造商的链条可能减弱的不确定性。

附录A-1：公司情况更新

评级体系为相对体系，表示相对于为每只公司设定的特定基准（受有限管理层酌情权约束）的预期表现。。估值方法包括但不限于：贴现现金流分析、预期股本回报率和倍数分析。，定义为/当前价格。

公司：公司情况更新

“观点偏积极”评级表示分析师预期该公司在未来12个月内跑赢基准。“中性”评级表示分析师预期该公司在未来12个月内与基准表现一致。“观点偏谨慎”评级表示分析师预期该公司在未来12个月内跑输基准。，以遵守适用法规和/或公司政策。标记为“未评级”或显示为“无评级”的标的和/或公司不在常规研究覆盖范围内。读者不应期望NOM就此类标的和/或公司提供持续或额外信息。基准如下：美国/欧洲/亚洲（除日本）：请参阅估值方法以了解公司相关基准的解释，可访问：<http://go.NOMnow.com/research/m/Disclosures>；全球新兴市场（除亚洲）：MSCI新兴市场（除亚洲）指数，除非估值方法中另有说明；日本：Russell/NOM大盘指数。

行业：公司情况更新

“看涨”立场表示分析师预期该行业在未来12个月内跑赢基准。“中性”立场表示分析师预期该行业在未来12个月内与基准表现一致。“看跌”立场表示分析师预期该行业在未来12个月内跑输基准。标记为“未评级”或显示为“N/A”的行业不分配评级。基准如下：美国：标普500指数；欧洲：道琼斯STOXX 600指数；全球新兴市场（除亚洲）：MSCI新兴市场（除亚洲）指数。日本/亚洲（除日本）：不分配行业评级。

公司情况更新

，则表明分析师对未来12个月报价的预测，部分反映了分析师对公司盈利的预估。，并且如果公司盈利与预估不符，则可能无法实现。

免责声明：公司情况更新