

KC桌面——外资精译

Bernstein：AMD还宣布了一系列面向企业、个人和物理AI领域的小型产品

AMD 于 7 月 22 日至 23 日举办了 Advancing AI 活动，最终由首席执行官苏姿丰博士发表主题演讲并进行了读者问答。我们认为此次活动总体相当积极，公布了关于新客户合作、产品组合与路线图更新以及总可寻址市场（TAM）预期上调等关键信息。以下为主要公告摘要。

Helios（MI450）正式发布，其性能基准测试（不出所料）表现强劲，无论是与 Vera Rubin 还是与 MI350 相比（尽管对于此类数据，我们通常持保留态度）（图表 1，图表 2）。AMD 还提供了更新的 Helios 路线图，计划以年度发布节奏推出后续机架级系统，其中 MI500/MI600 系列预计分别于 2027 年和 2028 年推出（图表 3）。近期的 MI455X 产品预计仍将从今年第三季度开始启动，并在第四季度逐步放量。

AMD 宣布 Anthropic 成为其 Helios 架构的第三大客户，加入 OpenAI 和 Meta 之列。作为与 Anthropic 战略合作的一部分，AMD 将研究高达 50 亿美元（因此不涉及认股权证），双方将在 ROCm 平台上展开合作。Anthropic 将部署高达 2GW 的计算能力，首个 1GW 的部署将于 2027 年上半年开始，目标是在 2027 年内完成几乎全部 1GW 的部署。AMD 还宣布与微软合作，在 Azure 上大规模部署 Helios，但未提供具体目标。

CPU 2030 年 TAM 从仅 3 个月前提提供的 1200 亿美元上调至 2200 亿美元（图表 4），这意味着从 2025 年的 260 亿美元基数出发，年复合增长率（CAGR）超过 50%，其中绝大部分增长由代理型人工智能（agentic AI）驱动。他们还预计，到 2030 年，加速器 TAM 将增长至 1.4 万亿美元（从 2025 年的 2000 亿美元基数出发，CAGR 约 45%），主要受推理支出推动，整体计算 TAM 将增长至约 2 万亿美元（从 2025 年的 3650 亿美元基数出发，CAGR 约 40%）。

管理层就其 CPU 产品路线图提供了更多细节。AMD 的下一代 Venice CPU 产品组合通过多种 Venice 变体来满足需求，这些变体针对 GPU 服务器/主机节点（Venice HF/Verano）、代理型 CPU 服务器（高核心数、高 ASP 的 Venice 256c）以及通用 CPU 服务器（Venice SP7/SP8/Venice-X）进行了定制（图表 5）。管理层对其 CPU 产品组合的实力充满信心，并认为相对于 x86 和基于 Arm 的 CPU，其有利的竞争地位将有助于他们进一步获取市场份额。

Cerebras 与 AMD 宣布合作，共同开发超低延迟推理解决方案。随着推理工作负载变得越来越异构化，客户对延迟、吞吐量、令牌容量、成本和规模的需求差异巨大，AMD 与 Cerebras 的合作旨在将 AMD Instinct GPU 的高吞吐量与 Cerebras 的超快速令牌生成能力相结合（图表 6，图表 7）。考虑到英伟达（NVDA）正在与 Groq 采取类似（尽管可能集成度更高）的方法，这一公告或许并不令人意外。尽管技术细节不多，但 Cerebras 计划在其自有数据中心部署首个联合解决方案，并最初于 2026 年下半年通过 Cerebras Cloud 向客户提供。

AMD 推出了 ROCm.AI，这是一个由人工智能驱动的开发平台，旨在通过 AI 加速开发、实现特定工作负载的 GPU 性能优化和编程（这似乎被他们视为应对英伟达 CUDA 护城河的答案；我们拭目以待……）。该解决方案基于 ROCm 核心软件栈（包括编译器、库和框架），并与 AI 编码代理集成，这些代理可以利用专家技能帮助生成代码以优化 GPU 性能（图表 8）。

AMD 还宣布了一系列面向企业、个人和物理 AI 领域的小型产品。AMD 推出了新产品，以应对企业 AI 部署中的若干挑战，包括电力与散热、成本以及部署便捷性，其 Instinct 350P GPU 被定位为一种宏观环境高效、易于部署的解决方案，适用于本地数据中心处理非前沿工作负载。其他新产品包括能够运行 24B 至 200B 参数规模模型（Ryzen AI400、Ryzen AI Max）的个人 AI 计算解决方案，以及一个新的面向开发者的平台（Gorgon Halo）。最后，AMD 推出了 KRIA AI Robotics，一个交钥匙机器人开发平台。

总体而言，我们认为此次活动相当积极，并继续看好公司的基本面实力，其 CPU 和 GPU 发展轨迹均有望带来基本面增长。我们对 AMD 的评级为跑赢大盘。

公司代码表：公司情况更新

O - 跑赢大盘，M - 与大市持平，U - 跑输大盘，NR - 未评级，CS - 暂停评级 来源：彭博社、Bernstein 估计与分析。


观察提示：公司情况更新

AMD：市场预期依然很高，但受益于 AI 需求驱动的 CPU 和 GPU 双重故事，可提供可观的增长。

详情：公司情况更新

图表 1：AMD 的基准测试显示其性能相对于 Vera Rubin 表现强劲（尽管我们通常对此类数据持保留态度）……

AMD Helios 提供最强大的机架级 AI 基础设施




图表 1

来源：AMD

图表 2：……以及与 MI355 相比，尤其是在低延迟用例方面


Instinct MI455X 在推理吞吐量方面实现代际提升



图表 2

来源：AMD


图表 3：AMD 计划为其机架级 GPU 设定年度发布节奏



图表 3

来源：AMD

图表 4：AMD 将其 2030 年 CPU TAM 从不久前预测的 1200 亿美元上调至 2200 亿美元



图表 4

来源：AMD

图表 5：AMD 最新一代 Venice CPU 将提供多种变体，以满足 GPU 服务器、代理型和通用工作负载的需求
EPYC "Venice" 最佳服务器 CPU 产品组合

GPU 服务器 "主机节点"

代理型 CPU 服务器 "沙盒"

通用 CPU 服务器

"Venice" HF RDIMM / MRDIMM

"Venice" 256c

"Venice" SP7

"Venice" SP8

"Venice-X"

"Verano" LPDDR

高频 CPU 到 GPU 带宽

高核心数 低功耗

均衡性能与功耗

技术计算与 HPC

来源：AMD

图表 6：AMD 与 Cerebras 的联合产品旨在结合高吞吐量与超低延迟……

超低延迟推理的最强解决方案

晶圆级超低延迟引擎

432 GB HBM4 容量

23.3 TB/s 内存带宽

44 GB 片上 SRAM
72 GPU 域
21,000 TB/s 内存带宽
900,000 AI 核心
来源：AMD

图表 7：……在宽延迟范围内提供更高的每瓦吞吐量（TPS/W）

AMD × cerebras 在领先 AI 模型上实现超快推理、更高 TPS/W
每瓦吞吐量（tokens/s/W）
高达 5 倍 TPS/kW
Helios + Cerebras
Cerebras
交互性（令牌/秒/用户） Kimi 2.6 1T 模型
来源：AMD

图表 8：ROCm.AI 在训练和推理工作负载中优化 GPU 性能

利用 ROCm.AI 加速推理
并行化与调度 专家并行、DP-attention、 计算通信重叠
推理
分页注意力、KV 缓存量化、 统一注意力（预填充 + 解码）
3.3 倍
平均性能提升
MHA 预填充、MLA 解码、Block-scale fused MoE
DeepSeek-R1 GLM-5 Kimi-K2.5 ROCm.AI 对比 ROCm 7
来源：AMD

附录 - 财务预测

图表 9：Bernstein AMD 损益表

来源：公司报告、Bernstein 估计与分析
EXHIBIT 10:Bernstein AMD资产负债表与现金流量表
来源：公司报告，Bernstein估算与分析