

KC桌面——外资精译

NOM：中国互联网与新媒体-LLM专家电话会要点

大语言模型专家电话会要点

关键点：公司情况更新

NOM中国互联网团队与一家中国领先大语言模型（LLM）公司的专家举行了小组电话会。据该专家称，中国LLM开发商下一阶段的竞争将由三个相互关联的趋势塑造：模型规模持续扩大、模型与工具链更深度的整合，以及系统级Token宏观环境学的更受重视。据专家称，DeepSeek（未上市）似乎处于这些趋势的交汇点，力求在缩小与海外前沿模型能力差距的同时，保持结构性更低的成本基础和大幅更低的Token价格。

模型规模持续扩大，但效率同样重要

中国LLM可能将朝着数万亿参数架构发展，由更大的计算集群、超级节点、高速互连和光网络支持。专家认为，约3万亿参数是中国LLM的下一个实际里程碑。

然而，纯参数扩展正接近收益递减。除了参数规模，模型竞争力将日益取决于架构和后训练效率、内存管理、可靠的工具使用以及长周期任务表现。

模型-工具链整合强化数据飞轮

据专家称，DeepSeek推迟正式发布V4的决定，部分反映了在智能体-工具链层面需要进一步调试和优化。其目标是构建一个可与Claude Code（由Anthropic [未上市] 开发）或Codex（由OpenAI [未上市] 开发）相媲美的集成产品，覆盖专业软件开发和更广泛的知识工作任务。

更深度的模型-工具链整合还可能创建专有数据飞轮。任务轨迹、工具调用、用户修正、执行失败和真实工作流可转化为模型和产品改进的反馈。因此，竞争优势正从独立模型转向集成的模型-智能体系统。

DeepSeek的结构性成本优化支撑其价格领导地位

DeepSeek将自己定位为性价比领导者。专家估计其混合推理成本低于每百万Token 0.8元人民币，假设缓存命中率为60%，且不包括模型训练计算、训练相关人事费用及其他研发成本，而混合售价约为每百万Token 1.3元人民币。这意味着推理贡献毛利率约为40%，尽管据报道V4代产品价格下降了约75%。

专家将DeepSeek的成本优势归因于更高效的注意力机制和内存管理，包括将KV缓存卸载到NVMe SSD，以及更高的基础设施利用率和在国内加速器上的大规模部署。DeepSeek正有效利用架构和基础设施优化来降低其成本曲线，并通过更低的Token价格将部分节省让利给客户。

AI参与循环缩短了模型领先周期

据专家称，单代模型的竞争优势领先期已从约六个月缩短至三到四个月。AI参与循环是这一加速的主要驱动力。自动评估、LLM作为裁判、多模型评分和教师模型反馈正变得比传统人工标注更重要。

因此，展望未来，LLM厂商的可持续差异化应来自计算规模、专用户交互以及从真实工作流中自动提取高质量训练信号的能力。

DeepSeek的海外增长由开发者驱动，与海外前沿模型互补

专家估计，截至2026年6月，DeepSeek的ARR达到约5.2亿美元，海外市场贡献约47-48%。海外用户集中在欧洲和美国，其次是日本、韩国和澳大利亚。采用仍由开发者驱动，个人开发者和小中型项目团队是核心客户群，而

大型企业渗透仍相对有限。

一个新兴模式是模型分层。开发者可能先使用Claude Code或Codex搭配优质海外模型进行初始规划、架构设计和复杂推理，然后切换到DeepSeek进行持续的代码生成和执行。因此，DeepSeek无需在整个工作流程中取代前沿模型；它可以先捕获Token密集的执行层，该层使用量更高且价格敏感度更大。

据专家称，这种互补定位仍可能对海外模型定价构成不确定性，因为用户越来越习惯于在优质和低成本模型之间路由任务。在可靠性和完成质量重于成本的场景中，优质定价应仍可维持，但嵌入智能体工作流程中的“足够好”、低成本模型可能捕获不成比例的Token量。

开源是分发杠杆

据专家称，尽管开源策略会影响直接商业化，但它能降低采用门槛、扩大海外覆盖范围、促进跨多云和硬件平台的部署，并让海外客户对数据、基础设施和定制化保留更大控制权。此外，在行业层面，有能力的开源替代方案使得闭源模型提供商更难维持高API溢价。

附录A-1：公司情况更新

本报告由NOM International (Hong Kong) Ltd. (NIHK) 在香港编制。NOM集团实体详情请参见免责声明。