

KC桌面——外资精译

GS：美洲科技硬件AI项目动态2026年7月

我们汇总了2026年7月在新云服务商、主权云及企业领域AI项目方面的最新公告与进展。此为精选项目公告，不代表AI基础设施整体市场机会。

2026年7月要点包括

NVDA等芯片制造商正为其新云客户提供底层GPU容量的最低收入保障（若新云服务商无法将容量租赁给其他客户），以换取新云服务商超过一定水平的收入分成。这些兜底计划应能通过支持新云服务商的持续增长，扩大终端客户可用的算力供给。NVDA将主权新云服务商Firmus和Sharon AI列为其收入分成与信用支持模式的两个早期合作伙伴。我们认为新云需求的持续强劲对领先AI服务器厂商DELL和SMCI构成利好。

\- 企业级AI应用场景（本地部署及云端）规模化扩展。例如，据报道星巴克正在开发专有的AI辅助内部工具，用于库存跟踪和维护管理，旨在替代来自微软、IBM和甲骨文的第三方软件。彭博报道称，星巴克企业技术团队有望削减约3000万美元预算，其中包括约1000万美元的软件支出。另外，英国资金科技公司Revolut在Nebius云上使用H1000 GPU预训练了PRAGMA（该公司面向银行客户的的行为模型）。Revolut的风控、信贷、营销和产品团队现利用该统一模型执行AI推理任务，成效显著。企业AI采用范围的扩大应利好面向企业的硬件OEM厂商（DELL、HPE）和IT分销商（SNX、INGM）。

新云服务商、AI实验室及数据中心运营商

以下按时间倒序列出重要动态。

Meta宣布与贝莱德达成战略合资，在埃尔帕索开发数据中心（2026年7月28日）：根据战略合资协议，Meta Platforms与贝莱德合作开发并拥有位于得克萨斯州埃尔帕索的一个1吉瓦AI数据中心园区，贝莱德管理产品持有该项目80%的股权，Meta保留20%的股权。该项目总研究140亿美元，预计于2028年开始分批投运。

■ 地点：得克萨斯州埃尔帕索

时间：容量自2028年起陆续上线，租期最长20年（初始期限4年，另有四个5年续租选项）

IREN签署28亿美元新客户合同（2026年7月20日）：IREN Limited已与领先AI开发商签订价值28亿美元的新客户合同，并将其2026年年度经常性收入目标提高至40亿美元以上。

客户：微软、英伟达、Perplexity、Figure AI、Together AI、Fluidstack、Fireworks AI、Fal AI、Hume AI

■ 地点：美国及加拿大

Sharon AI与未具名AI实验室签署13.2亿美元云计算服务协议（2026年7月17日）：在签署一份为期五年、价值13.2亿美元的云计算合同（客户为一家未披露名称的AI实验室）后，澳大利亚新云服务商Sharon AI正在新西兰的数据中心基础设施上部署其首个AI工厂，预计收入将于2027年上半年开始确认。

关键细节：AI工厂，总容量132MW（已签约116MW），预计到2027年年中部署超过62,000块英伟达GPU，澳大利亚72MW容量采用英伟达DSX AI工厂设计，最多可部署40,000块Grace Blackwell GPU，与Vast Data签订600PB存储协议

■ 规模：合同价值13.2亿美元，云协议9.5亿美元，容量协议12.5亿美元，总容量132MW

■ 地点：新西兰

■ 时间：GPU部署至2027年年中

■ 此前已公布的合作伙伴：思科、英伟达、Vast Data

Nebius推出通过基础设施合作伙伴关系实现AI云全球规模化扩展的商业模式（2026年7月15日）：Nebius推出轻资产商业模式，与数据中心开发商、基础设施读者及区域运营商合作，在全球部署其全栈AI云平台。该模式允许合作伙伴出资并拥有物理基础设施，而Nebius提供其系统架构、软件栈和全球销售体系以实现容量的商业化变现。

规模：Nebius所需增量资本极低，合作伙伴负责基础设施、硬件和数据中心的出资与所有权

时间：该模式于2026年7月15日公布，初步安排已达成

Arcee AI在英伟达Blackwell平台上训练前沿开源模型（2026年7月14日）：Arcee

AI（前沿开源权重模型开发商）已在由2,048块英伟达Blackwell Ultra GPU组成的集群上训练了其Trinity Large推理优化模型，利用英伟达NeMo和Quantum InfiniBand网络，打造出一款前沿级开源权重模型，其推理成本显著低于闭源替代方案。Trinity-Large-Thinking是Trinity Large的推理优化版本，专为长时间运行的智能体、强大的工具调用和多步骤工作流而设计。

关键细节：通过Arcee API进行推理的成本约为每100万输出token 0.90美元，在同等智能体质量下，比领先的闭源推理模型便宜约20倍。Trinity-Large-Preview在OpenRouter上线前两个月内处理了超过3.37万亿token，成为美国使用量最大的开源模型，并在OpenClaw集合中位列全球第四。

■ 主要合作伙伴：英伟达和Prime Intellect

Galaxy完成Helios数据中心园区一期工程，向CoreWeave交付133兆瓦关键IT负载（2026年7月6日）：随着位于西得克萨斯州的Helios数据中心园区一期工程按期完工，开发商Galaxy Digital已根据一份15年租约向云服务商Core Weave交付133兆瓦关键IT负载。260兆瓦的二期扩建项目已开始绿地开发，预计于2027年上半年交付。

■ 关键细节：已获批总电力容量1.63吉瓦（可扩展至3.6吉瓦），园区占地2,200英亩

■ 地点：西得克萨斯州

时间：一期租金自2026年第二季度起算，二期数据机房预计于2027年上半年交付

主权云：公司情况更新

以下按时间倒序列出重要动态。

Napster、DETSAD与联想携手打造沙特阿拉伯主权AI基础设施以支持本地部署（2026年7月30日）：Napster、DETECON AL SAUDIA（DETSAD）与联想合作在沙特阿拉伯王国交付主权AI基础设施，将沙特本土数据中心服务与Napster的企业AI平台相结合，提供完全在沙特境内、本地托管的智能体AI部署路径，以契合“2030愿景”。

关键细节：主权AI基础设施、本地托管云服务、Tier III/Tier IV数据中心能力、AI就绪基础设施、托管运营、网络安全、网络连接、数据驻留、合规对齐、SLA背书的运营、平台许可、工具定制、质量保证、上线部署、技术培训，以及联想的解决方案与服务组合。

■ 关键合作伙伴：Napster、DETECON AL SAUDIA (DETSAD)、联想

■ 地点：沙特阿拉伯（利雅得，计划扩展至海湾合作委员会成员国）

Pantheon Atlas 获得克罗地亚 1GW 数据中心电网接入许可（2026年7月24日）

在获得克罗地亚输电系统运营商 HOPS 的电网接入许可后，开发商 Pantheon Atlas 正推进其位于克罗地亚 Topusko 的 500 亿欧元、1 吉瓦超大规模 AI 数据中心园区项目。该园区按照 NVIDIA GW-Scale AI Factory 标准设计，计划于 2027 年初与 Kon č ar Group 和 Greenvolt 等合作伙伴共同开工建设。

■ 关键细节：NVIDIA GW-Scale AI Factory 标准、高于 Tier IV 的弹性标准、800MW 可用 IT 负载、280 公里输电线路和光纤线路、400kV 变电站

- 关键合作伙伴：Pantheon Atlas LLC、HOPS、Kon č ar Group、Greenvolt、Dalekovod Projekt、Parsec Lab、克罗地亚共和国宏观环境部、HEP Group
 - 规模：总研究 500 亿欧元（初始阶段 120 亿欧元），总容量 1GW，园区占地 310 英亩（可扩展至 450 英亩）
 - 地点：克罗地亚 Topusko
- 时间安排：2027 年初开工，2029 年第一季度投入运营

Firmus 将与 NVIDIA 合作建设拥有 17 万块 GPU 的 AI 工厂园区，服务全球 AI 原生企业（2026年7月1日）：Firmus 已与 NVIDIA 合作，在印度尼西亚巴淡岛开发一座 360 MW 的 AI 工厂园区，配备 17 万块 NVIDIA 加速器，涵盖 Grace-Blackwell、Vera-Rubin 和 Vera 系列。

■ 关键细节：NVIDIA 与 Firmus 合作采用收入分成和信用支持模式。Firmus 将销售由 NVIDIA 驱动的云服务，NVIDIA 既获得标准产品收入，也获得所支持容量云收入的分成。

- 关键合作伙伴：NVIDIA
- 规模：360 MW 电力容量
- 地点：印度尼西亚巴淡岛

企业板块：公司情况更新

以下标题按时间倒序排列。

Flow Traders 选择 CoreWeave

为量化交易基础模型训练提供算力（2026年7月28日）：Flow Traders 已选择 CoreWeave 作为其新成立的 AI 和深度学习部门的主要 AI 云平台提供商，将其高强度基础模型训练负载迁移至 CoreWeave Cloud，以获得专用计算容量和大规模多节点性能。

星巴克利用 AI 减少对微软、IBM 软件的依赖（2026年7月9日）：据报道，星巴克正在开发专有的 AI 辅助内部工具，以替代来自微软、IBM 和甲骨文的第三方软件，这是其削减 20 亿美元成本并提升咖啡师运营效率的更广泛举措的一部分。

- 关键细节：用于内部库存跟踪和维护管理平台的 AI 辅助编码；替代甲骨文 Symphony 销售点系统
- 规模：年度软件支出 4 亿美元；目标技术预算削减 3000 万美元，其中包括 1000 万美元的软件支出和 1300 万美元的专业服务费用
- 时间安排：部分工具可能在 2027 年底前推出

Revolut 与 NVIDIA 合作构建交易基础模型（2026年7月8日）：Revolut 开发了 PRAGMA，这是一个基于 Transformer 的行为模型系列，通过 Nebius AI Cloud 在 NVIDIA H100 GPU 上进行训练，旨在用统一的智能层取代孤立的机器学习流水线，从而提高欺诈检测准确性，并将模型开发周期加快 3-5 倍。PRAGMA 行为模型将每位客户的财务旅程解读为丰富的时间序列信号，类似于高级语言模型对文本序列的解读方式。

- 关键合作伙伴：NVIDIA 和 Nebius AI Cloud
- 规模：基于 111 个国家 2600 万用户记录进行预训练（2070 亿个令牌）