

KC桌面——外资精译

波士顿咨询：AI成本失控前，CFO必须学会管好“Token计价器”

AI治理的第一波浪潮聚焦于“谁能用”，第二波浪潮将转向“怎么算账”。随着AI从实验走向生产，CFO、CIO和CTO们接手了一个全新的成本管理对象：Token。Token是AI模型处理数据的基本单位，过去它们大多被埋在IT预算里，用FinOps的原则和流程来管理。但当AI使用量在企业内规模化——从最成熟的软件开发，扩展到销售、市场、运营等各个职能——AI的Token账单正在爆炸式增长。尤其是AI Agent的兴起，它们大量消耗Token，让计价器直接“踩油门”。FinOps已经跟不上节奏。

> KC评论：FinOps擅长管服务器和云资源，但Token的计价逻辑完全不同。一个请求的Token成本取决于提示词长度、上下文检索量、输出长度、模型选择、推理难度、工具调用、缓存命中率，甚至Agent跑了几轮循环。传统IT成本管理工具在这里基本失灵。

Token成本不是线性增长，而是被四个隐形引擎推高

Token成本并非自动指数级增长，且在不同平台和模型间差异巨大。关键指标不是单纯的成本，而是“单位成果的成本”。波士顿咨询提出了一个“AI投资回报率”框架： $\text{RoAI} = \text{经济回报} / (\text{人类智能成本} + \text{Token成本})$ 。在未经管理的Agent workflows中，每个有用成果消耗的Token会急剧且隐形地复合增长，这是四个力量相互作用的结果。

第一个力量是采用广度和深度。用户从简单聊天转向多步骤研究、代码生成、Agent部署和工作流编排，Token成本随之增长。第二个是任务强度：一个简短回答、一份文档审查和一个长时间运行的Agent会话，看起来都像一次请求，但经济性天差地别。第三个是上下文和循环。Agent会携带大量信息前进，包括指令、历史、检索文档和工具输出，并且在每个循环中重复这些信息，消耗大量Token。第四个是模型组合。默认使用最新前沿模型、最高推理设置或最大上下文窗口，是一个对账单影响巨大的设计选择。反过来也可能成立：一个较弱的模型需要多次重试才能得到答案，每个成功成果的成本可能高于一个能快速给出答案的强模型。

由于单位成本随Token消耗线性上升，正确的优化目标是“在所需质量、延迟、风险和人工审查负担下，每个成功成果的成本”。挑战在于让这个分母变得可见且可控。

三种Token成本，三种记账方式，不能再往IT预算里一塞了事

Token成本不应该放在IT预算里，也不应该被分配到损益表的任何单一科目。Token成本有三种类型，每种应该有不同的会计处理方式。构建可复用能力的Token是投资，类似于资本支出。当AI用于设计Agent、跨职能重新设计工作流，以及（对于运行自有AI推理的企业）提供规模化执行时，AI基础设施是资本支出。运行内部工作的Token是运营费用。CFO可以为每个职能和工作流设定合理的预算，并让管理者对产出负责。产品内部或客户交互中的Token是销售成本，必须作为毛利率的一部分来管理，其影响显著且完全透明。

Token成本透明度对于AI赋能的产品尤其重要。传统SaaS的经济性受益于规模效应：一旦软件获得许可，每个新客户的边际成本几乎为零。AI推理改变了成本曲线：每次客户交互都伴随着运行模型的成本。管理层需要能够看到规模化吸收推理对毛利率的影响，包括价格、使用量、模型架构、缓存和路由。

为了准确核算成本并评估RoAI，企业需要一个工作流层面的运营模型，让管理层能够做到三件事：看清正在发生什么、塑造成本、以及要么证明价值要么停止（或最小化）该活动。

> KC评论：很多企业现在的情况是——AI花了很多钱，但不知道花在了哪个工作流、产生了什么成果。没有归属的成本就是失控的成本，没有定义成果的支出就是未经证明的支出。

四个杠杆：从“消除不必要的模型使用”到“训练Token纪律”

企业需要学会管理AI及其相关成本，这很可能是CIO/CTO与职能及业务部门负责人的共同责任。他们应聚焦四个领域。

消除不必要的模型使用。许多早期的Agent之所以存在，是因为它们构建速度快，而不是因为模型是合适的工具。结构化查询、基于规则的路由、算术运算和确定性策略检查，这些是软件、API或可复用技能的任务，不是AI。将工作路由到传统软件本身就是一个有效的成本杠杆，而且通常还能提高可靠性。

按任务复杂度路由。将低复杂度的工作匹配给较轻量或开源模型，将前沿模型保留给真正困难的推理任务。在仪表盘中包含推理努力设置和上下文窗口选择，因为默认设置往往过度提供。让系统根据质量、置信度、延迟和成本自动路由，而不是把所有请求都发给最强模型。

复用上下文和组件。提示缓存和批处理可以在设计到工作流中时，大幅降低重复上下文和异步工作负载的成本。广泛使用的政策和流程，如标准指令、品牌规则、合规要求和常见工作流，应成为稳定、缓存友好的提示前缀。它们可以包含在策划的知识包、批准的模板和技能库中，方便访问。

训练Token纪律。良好的行为和纪律能降低Token成本。用户应学会请求最小的有用答案、约束输出长度、避免粘贴不必要的文档、区分探索和执行。界面应默认简洁输出、检索纪律和明确的停止规则。在按量计费的系统中，简洁成为有价值的成本控制杠杆。

治理“成果”而非“活动”：建立最高Token消耗工作流的定期审查

领导者应建立一个针对最高Token消耗工作流的定期审查流程。每次审查应评估业务分子（成果）与完整分母：Token成本加上启动、审查、纠正、批准和运行工作流所需的人力时间。然后决定是扩大规模、优化、重新定义范围还是停止该工作流。

软件工程展示了这种审查为何重要。一个Agent编码工作流可以以很小的Token成本产生大量输出，但代码行数是一个活动指标。分子应计算实际被交付并通过审查的代码。分母应包括规格说明、审查、纠正、测试和批准时间。同一个工作流可能是巨大的正回报，也可能是负回报，取决于它产生了多少有用、被接受的输出，以及消耗了多少人力。

同样的逻辑适用于工程之外。一个服务Agent关闭了更多工单但导致了更多升级，这是在产生活动而非回报。一个营销Agent生成了没人使用的资产也是如此。关键的治理问题不是AI是否忙碌，而是在计算了全部成本后，成果是否得到了改善。

波士顿咨询估计，企业在12个月内可以通过降低Token成本和让每个Token产生更大价值来显著提高AI支出效率。关键节省机会包括：停止或最小化可避免的支出、将工作路由到合适的工作马、缓存内容以避免重复的AI活动、应用正确的控制、以及培训员工提高AI素养。可以按三个阶段思考：快速见效（第1-3个月）、大石头（第3-6个月）和长尾（第6-12个月）。快速见效为大石头提供资金，其影响被更长的节省尾期所放大。企业可以控制RoAI的分母，其财务影响会随时间累积。Token成本是真实且快速增长的问题，正在引起CEO和董事会的关注。CFO、CIO和CTO需要准备好答案，当那些领导者开始提问时。