

KC桌面——外资精译

波士顿咨询：AI竞争已进入“Token时代”，增长差距正在拉大

波士顿咨询（BCG）最新报告指出，企业竞争已从“人才垄断”转向“Token消耗”。当AI模型在几乎所有领域达到博士级知识水平时，优势不再来自拥有智能，而来自更高效地将智能应用于商业问题。BCG将这种通过Token消耗来部署智能的竞争模式，定义为“Token-based competition”——Token是AI模型的语言和货币，正如1988年BCG首次提出的“时间竞争”一样，Token消耗速度正成为新的制胜基础。

报告分析了107家年收入超5亿美元的上市科技公司，发现Token消耗最高的前五分之一企业，其收入中位数同比增长达16.5%，而最低消耗组仅为5.1%。差距超过3倍。这并非巧合：AI驱动的流程会随着模型改进和每次交互学习而变得更智能、更快、更便宜，形成持续增长的飞轮效应。领先企业正在围绕AI重新设计工作流程，让人专注于指导和改进系统，而非替代系统。

> KC评论：Token消耗量正在成为衡量企业AI落地深度的硬指标。就像当年电商看GMV、SaaS看ARR，现在投资者和董事会应该开始关注“每Token产出价值”。那些只把AI当成本削减工具的公司，很可能在下一轮竞争中掉队。

管理Token要像管理资本：引入“智能投资回报率”

BCG建议企业采用ROInt（Return on Intelligence）作为核心衡量指标，即产出价值除以劳动力和Token的总成本。这能统一评估不同AI应用的价值：在客服自动化等替代场景中，ROInt衡量效率提升；在软件工程或研发等增强场景中，ROInt衡量产出增长、创新加速或新收入创造。

报告警告两种极端：只衡量劳动力节省会系统性偏向狭窄的AI应用，错失更大价值；而单纯追求Token消耗最大化（所谓“Tokenmaxxing”）则会导致员工游戏指标。正确的做法是像管理资本投资一样管理Token，将Token支出导向最高回报机会，尤其是那些能随时间有机增长回报的领域。



图表 1

将AI责任从IT部门移出，纳入战略规划核心

BCG发现，许多企业将AI视为IT成本中心，导致预算管理碎片化。CFO不知道Token消耗资金从何而来，CTO担心“Token超支”打乱预算，AI卓越中心（CoE）负责人则缺乏对未来使用量和成本的洞察。报告建议将AI责任从IT部门转移至战略规划、AI CoE或财务部门，使其融入工作流程的核心。

以英国消费品公司Reckitt为例，该公司在营销、产品开发和研发中战略性应用AI，加速了从洞察到收入的路径，同时降低成本。Reckitt报告称，内容开发速度提升高达60%，研究周期缩短且原型数量减少，营销和创新产出

质量更高。这印证了BCG的核心观点：当AI被战略性部署时，会触发持续增长的飞轮——组织学会如何更有效地将优势应用于整个业务。

> KC评论：把AI放在IT部门管，就像把电商放在技术部管——注定做不大。真正聪明的公司会让业务部门为Token消耗负责，就像他们为广告预算负责一样。谁离客户近，谁就该决定Token花在哪。

把Token当人才放大器，而非劳动力替代品

BCG颠覆了传统认知：裁员不仅降低成本，也可能削弱组织将AI输出转化为可信价值的能力。在大多数AI工作流程中，人类负责启动、指导和完成工作——决定哪些问题值得解决、设计提示词或 workflow、评估输出、运用判断力并承担责任。这就是ROInt指标同时包含人力和Token成本的原因。

Gartner预测，到2027年，一半因AI削减客服人员的公司将重新招聘。在321名客服领导者的调查中，只有20%真正因AI减少了人员。AI能力是“锯齿状”的：它能自动化某些任务，但许多角色仍依赖人类背景、关系和物理存在，这些更难替代。相反，Cloudflare CEO Matthew Prince在《华尔街日报》专栏中分享，公司减少了“衡量型”岗位（包括中层管理和运营），同时加速招聘工程和客户面对面的员工。

BCG此前研究发现，50%-55%的工作岗位将被AI重塑，而只有10%-15%可能被取代。这意味着Token时代的赢家，是那些拒绝在投资AI和投资人才之间做错误选择的公司。目前，只有不到10%的员工以“代理式”方式使用AI——即委托AI代理规划和执行多步骤工作，而非仅仅提问或完成离散任务。采用停滞往往源于人性原因：员工不知道AI能创造什么价值、习惯旧有工作方式、或担心威胁自身专业身份。领导者需要直接解决这些障碍，否则Token消耗量上升，却无法转化为价值。

JPM推出Coach AI平台时，分阶段推广，让顾问在日常工作中学习使用。资产与财富管理CEO Mary Callahan Erdoes表示，目标是“消除员工日常工作中的无趣工作，让他们专注于更高价值的任务”。顾问现在使用AI研究内容和查找客户信息的速度提升高达95%，从而有更多时间进行有意义的客户对话。