

KC桌面——外资精译

波士顿咨询：AI技术与行业应用观察

企业AI的宏观环境逻辑正在快速变化。波士顿咨询（BCG）最新报告指出，Anthropic和OpenAI等AI实验室已从固定费率订阅转向按量计费，下一步可能是动态定价——在需求高峰时段价格飙升。对终端用户而言，AI成本敞口正在扩大。BCG估算，若AI算力市场向更流动、更透明的方向演进，每年可释放高达1400亿美元的“暗价值”——这一价值源于资本、商品和服务供需中的低效。

终端用户正从固定订阅转向按量计费，动态定价或成下一阶段

报告显示，Anthropic于2026年4月将企业客户转为每人20美元基础费加按token计费的API费率，OpenAI在同年4月初将Codex从固定消息定价转为token计量，GitHub随后收紧Copilot限制，Windsurf则在3月以硬性周限额取代固定积分。这些变化直接关联到AI算力资源的紧张。

BCG认为，下一步可能是动态token定价——推理价格随底层AI算力的供需波动，类似批发电力价格在炎热午后上涨、夜间回落。在模型可替代的场景下（如聊天机器人、摘要工具、编码助手可在Claude、GPT或开源模型间切换），竞争将保持强劲，价格更贴近供应商的实时算力成本。但在深度生态集成场景（如定制芯片、微调模型、数据驻留安排），切换成本会削弱替代性，token价格将更多反映谈判关系价值而非边际成本。

AI实验室和数据中心面临价格发现不足与融资成本高企


报告指出，当前AI算力市场的结构性挑战集中在两个群体。对AI实验室和大型算力用户（如自动驾驶公司、生物科技企业）而言，价格发现极为有限——网站上列出的价格很少匹配实际交易价，多数通过双边谈判、折扣和预留容量协议达成，且不公开。同时，供需不确定性管理工具匮乏。数据中心空置率仅1%，约92%的新增容量在建成前已被预承诺，但部分GPU集群利用率低至5%（据Cast.AI数据）。长期合同虽能锁定供应，但无法灵活应对需求变化。

对数据中心运营商而言，融资成本高企。GPU硬件残值不确定（新一代产品约每两年推出一次），客户合同租金波动剧烈——H100每小时租金从2024年初约8美元的高点跌至2025年底的1.96美元，2026年4月回升至2.64美元。贷款方偏好可预测现金流和低绩效不确定性，但当前AI数据中心融资恰恰缺乏这两点。


> KC评论：这意味着，如果AI算力市场能建立类似原油的基准价格和期货合约，数据中心运营商将能对冲硬件残值和租金波动不确定性，从而降低借贷成本、释放更多资金用于扩建产能。

算力商品化面临技术异质性、基准缺失和激励错位三重阻力


报告识别出阻碍市场流动化的关键因素。技术层面，AI算力在时间（高峰/低谷价格波动）、质量（H100与H200性能差异，以及隐藏的CPU、网络、存储成本）和地理（不同区域价格差异显著）三个维度上存在异质性。基准层面，虽然已出现Ormn H100指数和Silicon Data H100租赁指数等尝试，但各指数采用不同方法收集数据和标准化定价，同一GPU在同一天可能在不同指数上呈现显著差异。激励层面，数据中心运营商长期依赖双边长期合同，缺乏标准化定价或支持公开基准的动力——但报告认为，若市场透明度能降低其融资成本并帮助吸引企业客户，部分运营商可能看到战略价值。



图表 1



图表 2



图表 3