

KC桌面——外资精译

数据稀缺环境下的动态、高分辨率财富测量

摘要

准确全面地衡量家庭生计状况，对于监测减贫进展以及将社会援助项目精准瞄准最需要帮助的人群至关重要。然而，传统数据收集的高昂成本历来使得全面测量成为一项艰巨任务。本文利用来自四个非洲国家的详细住户普查摘录数据，评估了基于卫星的替代性深度学习方法，以加速实现大规模、精细尺度且动态的资产财富测量。结果表明，Transformer架构解决了多个开放的测量问题，能够最准确地衡量各国及城市内部家庭资产财富的局部变化，以及家庭资产财富随时间的变化。通过人为限制数据可用性的实验表明，该模型在数据有限的情况下仍能实现高性能。所提出的方法展示了结合卫星图像、公开地理特征以及新型深度学习架构，在数据稀缺环境下进行超本地化和动态财富测量的前景。

Zhuo Zheng, ^a Timothy Wu, ^a Richard Lee, ^{b,c} David Newhouse, ^d Talip Kilic, ^d Marshall Burke, ^{c,e} Stefano Ermon, ^a 和 David B. Lobell ^{b,c}

^a 斯坦福大学计算机科学系，美国加利福尼亚州斯坦福，94305

^b 斯坦福大学地球系统科学系，美国加利福尼亚州斯坦福，94305

^c 斯坦福大学粮食安全与环境中心，美国加利福尼亚州斯坦福，94305

^d 世界银行集团发展经济学数据组，美国华盛顿哥伦比亚特区，20433

^e 斯坦福大学环境社会科学系，美国加利福尼亚州斯坦福，94305

文章信息

关键词：经济福祉 高分辨率 贫困制图 卫星图像 深度学习

JEL代码：C45, I32

准确、最新且高分辨率的经济福祉测量，对于监测和实现减贫的国际目标至关重要。这些目标包括联合国可持续发展目标1“无贫穷”（其原定2030年截止日期日益临近），以及无数其他国际和区域减贫目标。对家庭贫困和财富的精细估算，对于了解这些目标是否正在实现，以及在进展滞后的地区精准定位和评估反贫困干预措施至关重要[6]。

中低收入国家的官方贫困测量长期以来依赖住户调查，这是一种不可或缺但耗时耗力的生计衡量工具。鉴于可靠调查测量所需的技术能力，以及开展全国性或次全国性代表性生计调查所面临的巨大后勤困难，在世界大部分地区，此类调查往往无法频繁完成，导致许多时期和许多地区缺乏全面、及时的贫困及相关结果的衡量数据[6, 9]。与此同时，调查数据通常基于旨在代表较大空间尺度的样本，因此通常不足以在村庄或社区层面（反贫困干预措施往往需要瞄准的层面）生成可靠的估计。因此，迫切需要更具成本效益和可扩展性的地方层面生计测量替代方案，以补充和扩展现有的基于住户调查的工作。

近年来，丰富的公开遥感数据和机器学习的进步改变了生计测量的格局，逐渐从全国人口普查及相关住户调查，转向将这些信息与卫星及其他传感器信息相结合的努力。早期研究使用粗分辨率的公开卫星图像和/或手机数据，结合早期的机器学习和深度学习架构，展示了如何利用这些新信息源来支持大规模的财富和贫困测量[4, 17, 29]。后续研究引入了进一步的改进，利用公开或专有地理空间数据来改进基于卫星的财富测量[8, 12, 2]。这些进展证实，利用卫星图像和机器学习可以成为估算财富的一种准确、廉价且可扩展的解决方案[6, 21, 23]。

在此，我们利用从国家统计局获取的全国人口普查或普查摘录数据，以及来自多个不同分辨率的公共和私人传感器的多光谱卫星图像，构建了一个大规模、多分辨率、多时相的财富数据集。我们的数据集涵盖了四个非洲国家（马拉维、莫桑比克、布基纳法索和马达加斯加）超过1200万户家庭，并且独特地包含了马拉维两个城市内精确的地理定位测量数据，以及同一地点随时间推移的重复测量数据——这是以往研究所缺乏的两个特征。

我们利用这些数据，在先前工作的基础上做出了四项贡献。首先，我们直接测试了一种新型深度学习模型——具体来说是视觉Transformer——与文献中常见的基于卷积神经网络（CNN）的早期深度学习架构，以及使用地理特征和表格机器学习方法（XGBoost）进行预测的更简单模型进行了对比。具体来说，我们设计了一个条件模块，使我们的Transformer模型能够处理多模态输入，同时整合卫星图像和地理空间特征（见“方法”部分）。我们测试了使用Landsat（30米/像素）、PlanetScope（3米/像素）和/或SkySat（0.5米/像素）传感器卫星图像的模型。然后，我们将这些更复杂的方法和输入与仅依赖来自一系列来源的预定义地理空间特征的更简单方法进行了比较。

这些比较很重要，因为依赖公开数据的更简单方法在大规模实施时可能既更容易也更便宜，特别是对于希望广泛应用这些方法的公共组织而言。因此，了解不同模型架构和输入之间的性能权衡，对于理解如何推广有前景的新测量方法至关重要。

第二，我们方法的一个关键优势在于使用了来自全国人口普查或数据提取的精确高分辨率数据进行模型训练和评估。与早期主要依赖公开可用的住户调查数据（其特点是空间位置数据不精确且住户样本有限）的工作不同，我们的数据覆盖了特定地点中数量大得多的住户，并且在某些情况下具有精确的地理参考。与这种“黄金标准”数据进行对比，使我们能够理解模型预测误差是源于预测不准确还是真实测量中的噪声——这种理解在发展中国家早期的研究中往往难以实现[6, 29]。此外，这使我们能够考虑广泛的样本量，以评估先进机器学习方法产生准确估计所需的最低训练数据量。为了量化训练样本量对性能的重要性，我们广泛测试了额外训练数据在多种设置下对模型性能的影响程度。

第三，我们高分辨率的人口普查数据使得对卫星图像和其他地理空间数据如何用于预测非洲城市区域内生计差异有了新颖的理解——鉴于先前设置中训练数据的有限样本和空间噪声，这种能力同样难以评估。这在城市环境中可能尤为重要，因为即使在很小的空间范围内，生计也表现出显著的空间变异性。利用来自马拉维两个城市的全面且精确地理参考的人口普查数据，我们能够使用不同分辨率的卫星数据训练和测试模型，并发现这些模型在预测这些城市内街道和社区层面的财富差异方面出奇地准确。

第四，人口普查和数据提取使我们能够评估基于图像的模型能否准确预测财富随时间的变化。先前的努力再次受到地面数据的严重制约，这些数据未能在不同调查中重复采样相同地点[29]。因此，目前尚不清楚一个主要训练用于预测财富或消费空间变化的基于图像的模型是否能够预测时间变化，因为后者通常规模更小，且可能由图像中更难检测到的变化驱动。来自马拉维和莫桑比克同一地点相隔10年的重复人口普查数据，使我们能够评估模型是否确实能从图像中提取信息，以预测资产财富的时间变化。


结果

国家层面财富预测的表现 对于国家层面的财富预测，我们在每个国家单独训练每个模型，并对每个模型进行国家层面的五折交叉验证。CNN模型仅使用Landsat卫星图像作为输入。XGBoost使用地理空间特征（地理特征），可单独使用或与卫星图像统计特征结合使用。所有模型均训练用于预测资产财富指数（AWI）[29]。AWI的估计值是在马达加斯加、马拉维和莫桑比克的精细行政层级生成并与图像关联的。在布基纳法索，AWI估计值仅适用于334个区（表1）。这减少了布基纳法索训练数据的有效样本量，如图1d右图所示的调查测量资产财富的聚集模式。这一差异反映在结果中。如图1a所示，一个不依赖地理特征的朴素transformer模型在马拉维、莫桑比克和马达加斯加数据集上始终优于其他模型。在这些国家，当使用完整的人口普查数据提取进行训练时，使用transformer模型的预测分别达到了0.83、0.70和0.62的 R^2 值。在布基纳法索，由于有效样本量较小，使用卫星图像和地理空间特征的XGBoost在模型中取得了最佳平均性能（解释了62.9%的变异）。仅使用卫星图像的朴素transformer仍具有竞争力（解释了57.4%的变异）。我们还将训练样本数量限制为原始训练数据集的1%、5%、10%、25%和50%，以分析模型性能如何随训练样本量变化。基于这四个国家的结果，我们凭经验确定10%是模型性能的关键拐点，低于此值，估计的准确性会迅速恶化。

降低财富预测训练样本收集成本的另一个关键因素是每个样本聚合的住户数量。为了分析这一因素，我们每个行政区随机抽取10户住户来构建训练样本，为每个国家生成一个“10户”训练数据集。然后，我们在这个“10户”训练集上训练一个朴素transformer模型，同时仍在原始的完整住户测试集上评估其性能。结果（图1b）表明，使用10户数据训练的transformer模型表现出与使用所有住户数据训练的模型相当的性能。以马拉维为例，10户数据仅包含约23%的受访住户。使用所有住户训练的模型与使用10户样本训练的模型之间的性能差距仅为3个百分点（82%对79%）。相比之下，当减少训练样本数量时，使用完整训练样本训练的模型与使用25%样本训练的模型之间的性能差距高达12个百分点（82%对70%）。


这些结果为数据高效的财富测量提供了重要见解。当每张图像至少包含10户住户时，使用我们的transformer模型预测财富时，调查更多普查区比调查普查区内更多住户更为优先。地理空间特征被公认为是改善经济测量的有价值的辅助数据 [21]，广泛应用于财富预测。这里我们为transformer模型设计了一个条件模块（见“方法”），以实现地理空间特征和深度视觉特征的有效融合。结果如图1c所示，表明地理空间特征显著改善了

a




图表 1


b




图表 2




图表 3




图表 4




图表 5




图表 6




图表 7




图表 8



图表 9




图表 10




图表 11


d




图表 12



图表 13




图表 14




图表 15

图1：国家层面资产财富指数预测的表现。a. 四个国家在四种不同机器学习方法上的表现比较，这些方法基于普查数据提取的不同比例样本进行训练。负的 R^2 值未显示。Transformer 结果未整合地理特征，并使用所有样本家庭构建的资产财富进行训练。b. 使用所有家庭构建的资产财富与每个行政区10户家庭构建的资产财富训练的 Transformer 模型之间的表现比较。c. 整合与未整合地理空间特征的 Transformer 模型之间的表现比较。d. 调查测量的资产财富与表现最佳折数预测财富的散点图。

所有国家的模型表现，尤其是在布基纳法索，由于在公社层面将图像与调查数据关联导致有效样本量较小，表现较差。当训练样本量较小时，地理空间特征似乎特别有益，这表明模型在样本量较小时难以从原始图像中学习最优的视觉表征，此时地理空间特征成为财富预测的有价值补充。在图1所示的方法中，图1c中带有地理特征的 Transformer 模型在所有情况下的估计 R^2 均为最高，除了一种情况：在莫桑比克使用全部普查数据进行训练时，朴素 Transformer 模型的准确度略高。图2中的四张网格化财富地图，分辨率为 4.8 公里/像素，完全使用我们的 Transformer 模型和 Landsat 影像生成。无需准备地理空间特征，整个制图过程可在1小时内使用8块 NVIDIA RTX A4000 GPU 完成。这意味着我们的方法在加速国家尺度上的精细财富测量方面具有巨大潜力。



图表 16




图表 17

图2：国家层面预测资产财富指数地图。a. 2018年马拉维国家层面财富资产地图。b. 2017年莫桑比克国家层面财富资产地图。c. 2018年马达加斯加国家层面财富资产地图。d. 2019年布基纳法索国家层面财富资产地图。AWI 值由各国特定模型生成，因此不具跨国可比性。

国家层面财富变化预测的表现


我们进一步通过五折交叉验证评估每个国家的国家层面财富变化预测。遵循 [29], CNN 模型使用沿通道维度拼接的双时相 Landsat 图像作为输入。我们的 Transformer 模型通过权重共享的单图像编码

器分别处理每个双时相图像，并将编码后的特征沿通道维度拼接，然后输入最终回归网络。与之前的设置不同，XGBoost 仅以双时相卫星图像作为输入，因为马拉维2008年和莫桑比克2007年没有可用的地理空间特征。结果（图3a）显示，在全样本上训练的深度学习模型能够捕捉马拉维52%和莫桑比克42%的财富变化。在给定相同输入数据的情况下，深度模型优于 XGBoost，这意味着表征在财富测量中也很重要。我们的 Transformer 模型在估计莫桑比克的十年财富变化方面略优于常用的 CNN，并在马拉维取得了相当的表现。这种差异可能归因于训练样本量和模型复杂度的不同。莫桑比克的训练样本量大约是马拉维的 $\$10\times\$$ ，这可以解释为什么更灵活的 Transformer 模型在莫桑比克的表现优于 CNN 估计。与上述横截面结果类似，我们模拟了两种数据稀缺场景来预测变化：(i) 限制抽样普查区的数量；(ii) 将每个样本汇总的家庭数量减少到10户。结果（图3c）表明，减少抽样位置的数量比减少每个样本汇总的家庭数量对准确度的损害更大，这与国家层面财富预测的实验结果一致。




图表 18


abC



图表 19




图表 20




图表 21

d


e



图表 22




图表 23



图表 24


图3：国家层面资产财富指数十年变化预测的表现。a. 两个国家在三种机器学习方法上的表现比较，这些方法基于普查数据提取的不同比例样本进行训练。负的 R^2 值未显示。b. 马拉维2008年至2018年国家层面财富资产变化地图。c. 使用每个行政区所有家庭构建的资产财富与每个行政区10户家庭构建的资产财富训练的 Transformer 模型之间的表现比较。d. 莫桑比克2007年至2017年国家层面财富资产变化地图。e. 调查测量的资产财富与表现最佳折数预测财富的散点图。

我们进一步展示了我们的 Transformer 模型在马拉维（图3b）和莫桑比克（图3d）十年财富变化制图上的可扩展性。与单时相财富地图不同，双时相财富变化地图提供了对经济发展动态更深入的洞察，允许识别随时间经历显著增长或下降的区域。我们发现马拉维南部地区表现出更多的负向变化，表明该十年间财富下降，而北部和一些中部地区相对中性或略有增长。在莫桑比克，大多数地区显示出财富总体增长，南部地区相比北部地区财富增长更多。有几个孤立的区域，特别是靠近北部的一个蓝色区域，经历了财富下降。在这两个国家，财富分布的变化并不均匀，表明某些地区从经济增长中获益更多，而其他地区则落后。这种财富差距可以为影响这些变化的经济政策、发展计划或气候影响等外部因素提供洞察。




图表 25


a



图表 26



图表 27



图表 28

C
d
h

| 图4：城市层面资产财富指数预测的表现。a. 两个城市在四种不同机器学习方法上的表现比较，这些方法基于普查数据的不同比例样本进行训练。b. 使用 Skysat 影像与 PlanetScope 影像估计的 Transformer 模型之间的表现比较。c. 整合与未整合地理空间特征的 Transformer 模型之间的表现比较。d. 调查测量的资产财富与表现最佳折数预测财富的散点图。e. 基于卫星的马拉维国家财富资产地图。f. 利隆圭国家层面财富资产地图。g. 利隆圭城市层面财富资产地图。h. 布兰太尔国家层面财富资产地图。i. 布兰太尔城市层面财富资产地图。

城市层面财富预测的表现

基于Landsat的财富预测模型生成了空间分辨率为4.8公里的财富地图。对于某些应用，例如在城市区域内定向援助，更高分辨率的财富地图更具价值。为此，我们利用两个城市的家庭级普查数据，测试了使用高分辨率卫星影像（PlanetScope和SkySat）进行财富预测的效果。遵循与前两个小节相同的设置，我们评估了CNN、Transformer和XGBoost模型，如图4a所示。在两个城市中，CNN和Transformer模型的表现始终优于XGBoost（无论是否包含地理空间特征）。这凸显了高分辨率卫星影像的深度视觉表征对于城市级财富预测的重要性，这也是基于深度学习的模型与XGBoost之间的主要差距。在布兰太尔，我们的Transformer模型明显优于CNN，尤其是在使用完整数据集时，展示了随着数据增加而更强的可扩展性，同时在利隆圭也取得了与CNN相当的性能。在两个城市中，随着训练数据比例的增加，所有模型都表现出显著的性能提升；然而，在数据量达到约25%-50%后，性能提升开始趋于平稳，超过该阈值后收益递减。

我们比较了两种常用的专有高分辨率多光谱卫星影像，即PlanetScope（3米）和SkySat（0.5米），如图4b所示。结果表明，在两个城市的不同训练数据比例下，SkySat的表现始终优于PlanetScope。两种传感器都能捕获4波段（红、绿、蓝和近红外）卫星影像，但它们在空间分辨率和幅宽上有所不同。这凸显了城市空间细节对于使用我们的Transformer模型准确衡量财富的重要性。虽然PlanetScope的平均性能低于SkySat，但其更宽的幅宽和高重访频率能提供更全面的卫星影像，有助于以可观的精度进行大规模财富制图（图4g和4i）。因此，SkySat非常适

合对精度要求高的局部区域财富测量，而PlanetScope则更适合用于获取宏观洞察的大规模财富制图。

尽管城市级财富预测前景广阔，但训练城市级Transformer模型仍然需要足够多的样本，而这些样本的收集成本高昂。我们还评估了整合地理空间特征是否能减少城市级财富预测所需的训练样本。如图4c所示，我们发现与国家层面的预测不同，地理空间特征通常会降低模型性能。这是因为地理空间特征总是从低分辨率卫星影像（例如Landsat，30米）中推导得出，以实现全球覆盖。这些低分辨率的地理空间特征会给基于高分辨率卫星影像的财富预测引入空间误差。例如，粗略的土地覆盖图可能会忽略城市区域中微小但重要的空间细节。在这种情况下，即使训练样本量不同，我们的Transformer模型也能仅从卫星影像中学习到更准确的财富表征。

总体而言，我们在马拉维的两个城市——利隆圭和布兰太尔，展示了准确的大规模城市级财富制图。与4.8公里分辨率的国家级财富地图（图4f和4h）相比，我们0.3公里分辨率的城市级财富地图（图4g和4i）提供了这两个城市前所未有的精细财富空间分布，并且性能强劲，解释了利隆圭高达76%的财富变异，以及布兰太尔高达67%的财富变异（图4d）。

讨论

本文提出并评估了使用视觉Transformer架构来解决多个开放性问题，这些问题涉及结合调查和卫星数据以在精细空间尺度上生成财富估算。对于横截面财富预测，使用来自四个国家的地理参考普查摘录进行的仔细评估表明，Transformer模型的估算表现良好。当与Landsat影像配对时，在所有四个国家中，对于所有考虑的样本量，整合了地理特征的Transformer模型在资产指数预测上的 R^2 值均优于常用的CNN和XGBoost模型。在所有国家中，当使用少于10%的普查摘录进行训练时，精度迅速下降。在莫桑比克和马达加斯加，使用Transformer模型生成的估算所解释的财富变异比使用XGBoost和地理特征生成的估算高出约20至30个百分点。Transformer模型在所有四个国家中也优于CNN，在马达加斯加和莫桑比克，优势高达约5个百分点。在莫桑比克、马达加斯加和布基纳法索，当样本量较小时，将地理特征整合到Transformer架构中可将性能提升5至10个百分点。

Transformer模型在预测0.3公里尺度城市内部变异时也表现良好，在利隆圭实现了高达0.76的 R^2 ，在布兰太尔实现了0.67。然而，在此尺度下整合地理特征会降低性能，因为这些特征是从较低分辨率的Landsat影像构建的。最后，在预测莫桑比克和马拉维资产财富指数的十年变化时，Transformer模型也比CNN和XGBoost生成了更准确的估算。尽管缺乏可用的地理特征，模型预测在精细空间水平上仍实现了马拉维0.57和莫桑比克0.42的 R^2 值。这相较于[29]在类似设置中报告的0.15至0.17的 R^2 值是一个巨大的改进，并证明了在给定足够训练数据的情况下，将Transformer模型与影像相结合以估算精细层面财富变化的可行性。

结果指出了应用整合了地理空间特征的Transformer模型来生成高分辨率资产财富预测的益处。这反过来又凸显了开发工具、文档和培训材料的重要性，以使国家统计局、国际组织和其他数据提供者能够进行此类估算。此外，开发和评估与预测相关的不确定性估算方法对于促进实施至关重要。

5/7

这些结果还凸显了获取足够规模的训练数据以估算预测模型的重要性。总体而言，当用于训练模型的图像数量低于总体的10%时，预测性能会迅速下降。然而，在限制用于生成训练数据标签的样本规模时，结果则稳健得多。此外，在布基纳法索，尽管由于将卫星图像与调查数据在更高地理层级进行关联，导致训练数据的有效样本量减少，但预测准确率仍然保持较高水平。未来研究可探索在使用家庭调查中通常收集的小样本训练Transformer模型时，如何进一步提升性能。

最后，这些结果展示了利用Transformer模型更广泛地预测财富和家庭福祉变化的潜力。未来研究可以考察变化模型中的参数在时间和/或空间上的稳定性。这或可为在缺乏调查数据的情况下，利用地理空间数据生成福利变化的近似微观估计指明方向。

方法

我们详细介绍了大规模、多分辨率、多时相财富数据集、财富及其变化预测方法以及评估方法。

多分辨率与多时相财富数据集。我们使用了四个低收入国家（马拉维、莫桑比克、布基纳法索和马达加斯加）以及马拉维两个城市的数据作为非洲研究区域。选择这些国家是因为现有人口普查摘录中提供了位置标识符。这使我们能够将模型定位在迄今为止最全面的尺度上，将通用模型调整到特定国家甚至城市，并稳健地模拟数据稀缺对模型性能的影响，涵盖三种时空情景：国家级财富水平预测、十年期国家级财富变化预测以及城市级财富水平预测。

资产财富指数（AWI）。我们利用全国人口普查问卷中的数据构建资产财富指数。我们使用了莫桑比克和马达加斯加的完整人口普查数据，以及马拉维和布基纳法索的人口普查摘录，最终数据集包含四个国家超过1200万户家庭，每个国家的数据集中代表超过70万户家庭。相比之下，先前利用DHS数据的研究[29, 23]涵盖了23个非洲国家约50万户家庭，而LSMS数据则测量了五个国家约9000户家庭。表1详细描述了数据集规模。

根据人口普查问卷，我们将七项住房特征（住房类型、墙体材料、屋顶材料、地面材料、水源、厕所类型和能源来源）按1至5级进行排序。此外，我们使用二元分类（拥有/未拥有）评估六项资产（收音机、电视、固定电话、汽车、摩托车和自行车）的存在情况。这些数据随后被标准化，用于构建主成分分析（PCA）模型，并提取第一主成分作为资产财富指数[13, 25, 29]。资产财富指数标签随后从家庭层面汇总到

表1

全国人口普查数据详情。

行政区层面，然后根据每个像素所属的行政区进行标记。最后，我们对逐像素的资产财富指数图进行平均，得到每个图像的真值标量。由于每个国家构建的PCA不同，一个国家的0值并不对应另一个国家相同水平的财富。

卫星图像。对于国家级财富及其变化预测，我们收集了马拉维、莫桑比克、马达加斯加和布基纳法索的白天Landsat（30米/像素）卫星图像，其中马拉维和莫桑比克拥有双时相图像对。我们的Landsat图像数据集是使用以各国人口普查年份为中心的三年无云像素中位数构建的。对于有两个人口普查期的国家，早期普查使用了Landsat 5和Landsat 7的图像，而近期普查则使用了Landsat 8。每张Landsat图像固定大小为150×150像素，因此每张图像覆盖20.25平方公里（4.5×4.5公里）。这些图像有六个波段：红、绿、蓝、近红外、短波红外1和短波红外2。对于城市级财富预测，我们收集了PlanetScope（3米/像素）和SkySat（0.5米/像素）多光谱卫星图像，以覆盖利隆圭和布兰太尔的每个行政区。基于行政区的平均大小，我们根据经验将每个网格的大小定义为0.3×0.3平方公里，这使得每张PlanetScope图像为100×100像素，每张SkySat图像为600×600像素。尽管使用了2018年的家庭级人口普查数据，但我们利用了2023年4月获取的可用PlanetScope和SkySat图像。这些图像包含红、绿、蓝和近红外波段。

地理空间特征。此外，我们还用公开可用的已处理地理空间特征（我们称之为地理特征）来补充卫星图像。这些地理特征捕捉了人口、发展和环境统计数据。这些特征包括：人口结构[18]、人口密度[28]、年降雨量[1]、最低和最高温度[1]、夜间灯光[3, 11]、陆地净初级生产力[10]、水体净初级生产力[24]、手机信号塔数量[22]、不透水面变化年份[15]、土地覆盖类型[5]、GHSL[26]、建筑物数量[27]、建筑面积[27]、土壤pH值[16]和土壤有机碳[16]。图5提供了一个数据点的可视化表示；请注意，最终的资产财富标签被合并为一个标量值。

训练财富测量模型

比较包括一种基于树的模型，即极限梯度提升（XGBoost）[7]，以及两种先进的深度学习模型（卷积神经网络和基于编码器-线性架构的Transformer[29]）。基于来自[14]的经验和

图5：卫星图像与地理空间特征及资产财富指数标签示例。这是一个国家级训练样本的案例。

系统观察，我们选择SwinV2-T[19]作为Transformer模型的代表性主干网络。

XGBoost。本文使用了XGBoost回归模型。通过实验，我们确定仅将图像级通道矩作为XGBoost输入特征可获得最佳性能。仅使用卫星图像时，我们使用了三个矩（均值、标准差和偏度）；同时使用卫星图像和地理空间特征时，仅使用一个矩（仅均值）。对于财富变化预测，我们将两年所有通道的矩输入到一个单一的XGBoost模

型中，该模型被训练为直接预测AWI变化。

卷积神经网络（CNN）。遵循文献[29]，我们构建了一个基于ResNet-18的CNN模型，用于财富水平预测和变化预测。对于水平预测，我们首先使用ResNet-18提取深层特征，然后通过全局平均池化层计算嵌入向量。在最后一个深层特征上附加两个多层感知机（MLP）层以预测AWI。对于财富变化预测，主要区别在于特征提取。我们将双时相图像沿通道轴拼接，并将结果输入CNN以提取深层特征。

视觉Transformer及其多模态变体。对于Transformer架构，我们首先采用SwinV2-T作为骨干网络来提取深层层次化特征。与CNN类似，附加两个MLP层以预测AWI。为了将地理空间特征集成到该Transformer模型中，我们提供了一种条件机制，该机制采用标准交叉注意力层，以可学习的方式将地理空间特征融入深层特征。SwinV2-T生成四个深层层次化特征；因此，我们采用四个交叉注意力层进行条件化。通过四次条件化，最终的深层特征与地理空间特征良好集成。最后一个深层特征用于基于上述两个MLP层的财富回归。对于财富变化预测，我们采用孪生网络架构，该架构在双时相图像间共享SwinV2-T骨干网络，即我们独立使用SwinV2-T为每张图像提取深层特征。然后，我们将这两组深层特征沿通道轴拼接，并将所得张量输入两个MLP层以预测财富变化。

深度模型的实现细节。我们使用相同配置训练所有深度模型。所有模型均通过最小化均方误差损失进行端到端训练，优化器采用AdamW[20]。每个模型训练100个epoch。总批量大小为32，恒定学习率为 $1e-4$ ，权重衰减为 $1e-2$ 。训练数据增强采用D4二面体群变换以缓解过拟合。MLP层用于预测AWI。对于财富变化预测，主要区别在于特征提取。我们将双时相图像沿通道轴拼接，并将结果输入CNN以提取深层特征。

模型评估

数据划分与交叉验证。为确保对模型性能的稳健评估，我们采用五折交叉验证，为每个国家或城市训练五个不同的模型。每个模型在四折上训练，在剩余一折上测试。折的划分通过对行政区划进行均匀采样创建，以保持同一行政区内的所有图像在一起，使得所有五折具有大致相同数量的图像。采用 R^2 作为水平预测和变化预测的指标。

模拟数据稀缺性。为研究模型在数据稀缺情况下的性能，我们模拟了两种有限数据可用性场景。(i) 限制图像数量。我们减少采样到训练数据中的图像数量。在限制数据时，我们在四个训练折的每一折内均匀随机采样图像。我们使用完整训练集中1%、5%、10%、25%、50%和100%的样本进行了实验。(ii) 限制图像内家庭数量。我们引入了一个替代性的“10户家庭资产财富”标签。在创建10户家庭AWI标签时，从每个枚举区均匀采样家庭。此后，10户家庭AWI标签的创建过程与上述完整AWI标签的创建过程相同。这些标签仅使用每个枚举区10户家庭的数据，而我们的完整资产财富标签则使用每个枚举区数百至数千户家庭的数据。

致谢

我们感谢Lina Cardona、Carlos Da Maia、Francis Mulangu、Mario Negre、Soudiki Soubeiga和Michael Weber在获取数据方面的帮助；感谢Haishan Fu、Olivier Dupriez、Craig Hammer和Jed Friedman的支持；以及Brian Amaro、Nahum Maru和Rohan Sikand在初步分析中的协助。本项目部分由“知识促进变革计划”第四阶段资助的项目研究课题“了解低收入和中等收入国家内部经济福祉差异趋势”以及Keck基金会资助。

作者贡献

DN、TK、MB、SE和DL构思了项目并设计了分析方案；RL处理了数据；ZZ和TW主导了分析；ZZ、DL、DN和MB撰写了论文。

代码与数据可用性

进行分析和生成图表的代码可在https://github.com/Z-Zheng/dynamic_highres_poverty获取。我们目前尚未获得国家统计局的许可，无法共享家庭层面数据或图像级标签。

参考文献

- [1] Abatzoglou, J.T., Dobrowski, S.Z., Parks, S.A., Hegewisch, K.C., 2018. Terraclimate, a high-resolution global dataset of monthly climate and climatic water balance from 1958 – 2015. *Scientific Data* 5, 170191. doi:10.1038/sdata.2017.191.
- [3] Baugh, K., Elvidge, C.D., Ghosh, T., Ziskin, D., 2010. Development of a 2009 stable lights product using dm sp-ols data, in: *Proceedings of the Asia-Pacific Advanced Network* 30, p. 114.
- [4] Blumenstock, J., Cadamuro, G., On, R., 2015. Predicting poverty and wealth from mobile phone metadata. *Science* 350, 1073 – 1076.
- [6] Burke, M., Driscoll, A., Lobell, D.B., Ermon, S., 2021. Using satellite imagery to understand and promote sustainable development. *Science* 371, eabe8628.
- [7] Chen, T., Guestrin, C., 2016. XGBoost: A scalable tree boosting system, in: *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pp. 785 – 794.
- [9] Dang, H.A.H., Serajuddin, U., 2020. Tracking the sustainable development goals: Emerging measurement challenges and further reflections. *World Development* 127, 104570.
- [11] Elvidge, C.D., Baugh, K., Zhizhin, M., Hsu, F.C., Ghosh, T., 2017. Viirs night-time lights. *International Journal of Remote Sensing* 38, 5860 – 5879.
- [12] Engstrom, R., Hersh, J., Newhouse, D., 2022. Poverty from space: Using high resolution satellite imagery for estimating economic well-being. *The World Bank Economic Review* 36, 382 – 412.
- [13] Filmer, D., Pritchett, L.H., 2001. Estimating wealth effects without expenditure data—or tears: an application to educational enrollments in states of india. *Demography* 38, 115 – 132.
- [14] Goldblum, M., Souri, H., Ni, R., Shu, M., Prabhu, V.U., Somepalli, G., Chattopadhyay, P., Ibrahim, M., Bardes, A., Hoffman, J., Chellappa, R., Wilson, A.G., Goldstein, T., 2023. Battle of the backbones: A large-scale comparison of pretrained models across computer vision tasks, in: *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.
- [17] Jean, N., Burke, M., Xie, M., Davis, W.M., Lobell, D.B., Ermon, S., 2016. Combining satellite imagery and machine learning to predict poverty. *Science* 353, 790 – 794.
- [18] Linard, C., Gilbert, M., Snow, R.W., Noor, A.M., Tatem, A.J., 2012. 2010年非洲人口分布、聚落格局与可达性. *PLoS ONE* 7, e31743. doi:10.1371/journal.pone.0031743.
- [19] Liu, Z., Hu, H., Lin, Y., Yao, Z., Xie, Z., Wei, Y., Ning, J., Cao, Y., Zhang, Z., Dong, L., 等, 2022. Swin Transformer v2：扩展容量与分辨率, 载于：IEEE/CVF计算机视觉与模式识别会议论文集, 第12009 – 12019页。
- [21] Newhouse, D., 2024.
利用地理空间数据进行贫困与财富的小区域估计：我们迄今学到了什么？加爾各答统计协会公报 76, 7 – 32.
- [23] Pettersson, M.B., Kakooei, M., Ortheden, J., Johansson, F.D., Daoud, A., 2023.
卫星影像时间序列改善深度学习对非洲社区级贫困的估计, 载于：IJCAI, 第6165 – 6173页。
- [25] Sahn, D.E., Stifel, D., 2003. 在缺乏支出数据情况下探索福利的替代衡量指标. *收入与财富评论* 49, 463 – 489.
- [29] Yeh, C., Perez, A., Driscoll, A., Azzari, G., Tang, Z., Lobell, D., Ermon, S., Burke, M., 2020.
利用公开卫星影像与深度学习理解非洲经济福祉. *自然·通讯* 11, 2.