

KC桌面——外资精译

世界银行：你低估了集群实验中的“大小不均”代价


在政策评估和经济学实验中，研究者经常面临一个棘手问题：个体之间的行为会相互影响。当你在一个社区里给部分居民发催缴税单，没收到信的人会不会因为邻居收到信而改变行为？这种“溢出效应”正是世界银行最新研究论文的核心关注点。但更关键的是，这篇论文揭示了一个被大量实验设计者忽视的陷阱——集群之间的“大小不均”会严重削弱实验的统计效力，甚至让精心设计的实验变成“白费功夫”。

集群规模差异是实验效力的“隐形杀手”

当实验单位被分组到不同的集群中（如学校、村庄、街区），研究者常采用“部分人口实验”设计：不同集群被分配到不同的处理强度（如0%、25%、50%的个体被处理），然后与纯对照组比较。世界银行团队指出，这种设计面临两个维度的集群异质性：集群规模差异和集群间结果分布差异。

论文通过一个数值模拟直观展示了问题的严重性：假设有200个集群，其中10个大型集群各有100个单位，其余190个小型集群各有25个单位。如果研究者忽略集群异质性，按照标准公式计算，要检测0.29个标准差的效果，实验效力应为80%。但一旦纳入集群规模差异，实际效力骤降至69%；如果再考虑结果分布的差异，真实效力仅为48%。这意味着，按照传统方法设计的实验，有超过一半的概率无法检测到研究者想要发现的效果。

> KC评论：这就像你打算在10个大型社区和190个小型社区做政策试点，但大型社区的人口结构和行为模式和小型社区完全不同。如果你用“一刀切”的统计公式，结果就是花了钱、费了力，最后发现“效果不显著”——不是政策没用，是你的实验设计根本没能力发现效果。



图表 1

方差公式需四层分解，传统方法遗漏关键项

论文的核心技术贡献在于对OLS估计量方差进行了精确分解。在存在集群异质性的情况下，估计量的方差可以拆解为四个部分：


- 独立观测下的基础方差
- 集群内相关性调整（即经典的“设计效应”或“Moulton因子”）

- 集群规模异质性带来的额外方差
- 集群间结果分布异质性带来的额外方差

传统实验设计文献（如Duflo、Glennerster和Kremer 2007年的经典指南）通常只考虑前两项，而忽略了后两项。世界银行团队证明，当集群规模差异较大时，常用的“集群稳健标准误”估计量会系统性高估，导致推断偏保守。更麻烦的是，这种保守不是“安全”的——它会让研究者误以为实验效力足够，实际上却严重不足。

论文进一步推导了在集群异质性条件下的统计效力公式、最小可检测效应（MDE）公式，以及最优集群分配概率。这些公式允许研究者根据实际数据中的集群规模分布和结果分布，精确计算需要多少样本才能可靠地检测出预期效果。

> KC评论：对政策制定者和企业来说，这意味着在做任何“分组试点”之前，必须先搞清楚各组之间的“底子”是否一样。如果不同区域的规模、人口结构差异很大，传统样本量计算公式会给你一个“虚假的安全感”。世界银行这篇论文提供的公式，相当于给实验设计装上了“异质性校正器”。




图表 2

阿根廷房产税实验证实：溢出效应真实存在，但高饱和度是关键

论文不仅停留在理论推导，还基于其方法论设计并实施了一项大规模实地实验。研究团队在阿根廷某城市开展了一场针对房产税缴纳的通信宣传活动，向随机选中的住宅发送个性化催缴信，内容包括欠税提醒、到期日、历史欠债和支付方式等信息。

实验设计的关键创新在于：研究者有意将同一街区的住户视为一个集群，并在不同街区设置不同的处理饱和度（即收到信件的住户比例）。这样，他们可以同时估计“直接效应”（收到信的人是否更可能缴税）和“溢出效应”（没收到信但邻居收到信的人是否也受影响）。

结果令人瞩目：收到催缴信的住户缴税率显著提高，直接效应约为5.1个百分点。更重要的是，在高饱和度街区（即大部分邻居都收到信），未收到信的住户缴税率也提高了2.6个百分点——这一效应在统计上显著，且集中在过去合规记录较好的住户中。这意味着，当社区内“被提醒”的人足够多时，信息会通过社交网络产生正向溢出。



图表 3

论文还展示了六个已发表实验的集群规模分布图，包括Crépon等（2013）对求职者的研究、Haushofer和Shapiro（2016）的现金转移实验等。这些实验的集群规模差异极大，从几十到上千不等，进一步印证了集群异质性是普遍存在的现实问题。

世界银行团队最后给出了实用建议：在设计部分人口实验时，研究者应事先收集基线数据，了解集群规模的分布特征，并使用论文提供的异质性校正公式计算样本量和统计效力。如果无法获得基线数据，至少应使用考虑集群规模差异的简化公式，这比完全忽略异质性的传统方法要可靠得多。

对于政策制定者和企业管理者而言，这篇论文的启示是明确的：任何涉及“分组试点”的评估——无论是税收政策、教育干预还是营销活动——都必须正视组间差异。否则，你可能会得出“政策无效”的错误结论，而实际上只是你的实验设计没能捕捉到真实效果。