

## KC桌面——外资精译

# 世界银行：你低估了集群实验中的“大小不均”代价

在政策评估和经济学实验中，集群随机实验（cluster experiments）是最常用的工具之一。但世界银行最新研究揭示了一个被广泛忽视的问题：当集群规模不均、结果分布各异时，实验的统计效力可能远低于研究者的预期。这篇论文不仅提供了理论修正，还通过阿根廷房产税合规实验验证了溢出效应的真实存在。

## 集群规模不均，实验效力可能被高估近一倍

传统实验设计通常假设集群是同质的——每个班级、每个社区、每个企业规模相近，结果分布相似。但现实远非如此。世界银行团队分析了六个已发表论文中的部分人口实验（partial population experiments），发现集群规模差异极大：有的集群只有几十个单位，有的则高达数百甚至上千。

当集群规模不均时，估计量的方差实际上由四个部分组成：独立观测下的基础方差、集群内相关性调整（即Moulton因子）、集群规模异质性带来的额外方差、以及集群间结果分布差异带来的方差。传统文献通常只考虑前两项，而忽略了后两项。

研究者的数值模拟令人警醒：假设200个集群中，前10个集群各有100个单位，后190个集群各有25个单位。在80%统计效力下，传统公式计算的最小可检测效应（MDE）为0.29个标准差。但一旦纳入集群规模异质性，实际效力降至69%；再考虑结果分布异质性，真实效力仅为48%——远低于研究者以为的80%。

> KC评论：这意味着大量基于集群实验的政策评估可能“假阴性”率极高——政策其实有效，但实验设计没能力检测出来。对于正在设计RCT的团队，第一步不是算样本量，而是检查你的集群到底有多“不均”。

## 方差估计偏误：保守不等于安全

研究者进一步证明，在集群异质性存在的情况下，常用的集群稳健方差估计量（cluster-robust variance estimator）存在系统性向上偏误。也就是说，标准误被高估了。

这听起来似乎是“好事”——保守估计总比低估风险强。但问题在于，过度保守的标准误会直接压低统计显著性，让研究者更难拒绝原假设。在政策评估中，这意味着一个真正有效的干预可能因为“标准误太大”而被判定为无效。

论文推导了在集群异质性条件下的渐近分布理论，并给出了明确的方差分解公式。关键发现是：当集群间结果分布差异较大时，传统方差估计量的偏误程度会显著增加。这种偏误不是小样本问题，而是在大样本下依然存在。

研究者还提供了最优集群分配概率的闭式解（closed-form solution），帮助实验设计者在不同处理强度之间分配集群，以最小化估计量的加权方差。这一工具可以直接用于优化实验设计，而不是事后补救。

> KC评论：对于已经做完实验的研究者，这个结论有点“扎心”——你的标准误可能被高估了，但你不能简单除以2。更好的做法是回到设计阶段，用论文提供的公式重新做效力计算。对于审稿人，看到“集群稳健标准误”时，应该追问一句：你的集群是同质的吗？

## 阿根廷实验：邻居效应真实存在，但只在高强度集群中显著

理论需要实证检验。世界银行团队在阿根廷设计并实施了一项大规模实地实验，旨在捕捉房产税合规中的直接效应和溢出效应。

实验设计基于论文的方法论框架：将住宅街区（street blocks）作为集群，随机分配不同处理强度。处理组中的部分住户收到个性化提醒信函，内容包括欠税信息、到期日、支付方式等。关键设计亮点在于，研究者有意在部分街区设置高处理强度（即该街区多数住户收到信件），以捕捉对未收到信件的邻居的溢出效应。

实验结果清晰且有力：收到信件的住户，房产税缴纳率显著提高——直接效应约为5.1个百分点。更重要的是，在高处理强度的街区中，未收到信件的邻居缴纳率也提高了2.6个百分点，这一效应在统计上显著。而在低处理强度街区，溢出效应则不明显。

研究者进一步按历史合规记录分组发现，溢出效应主要集中在历史合规率较高的街区。这意味着，社会规范和信息传递在“好邻居”之间更容易发挥作用——当大多数人都在缴税时，未缴税者更容易受到同伴压力。

这一发现对政策制定者有直接启示：如果税务部门想通过信息干预提升合规率，应该集中资源在少数街区做“饱和式”投放，而不是均匀撒网。因为溢出效应只在处理强度足够高时才会显现。

论文还指出，以往关于税收合规溢出效应的研究多为事后分析（ex-post analysis），即实验设计时并未考虑溢出效应。而本研究从设计阶段就将溢出效应纳入框架，使得估计更加可靠。

## 实践建议：实验设计者应该做什么？


基于理论分析和实证结果，研究者给出了几条可操作的建议：

第一，在设计阶段就收集集群规模分布信息，并使用论文提供的修正公式进行效力计算，而不是依赖传统公式。


第二，如果基线数据可用，应评估集群间结果分布的异质性程度。如果异质性较大，应考虑增加集群数量而非集群内样本量。

第三，在分配处理强度时，使用论文提供的最优分配概率公式，而不是简单均分。这可以显著提升实验效力。


第四，在分析阶段，报告集群规模分布和结果分布异质性的诊断信息，帮助读者评估估计量的可靠性。



图表 1



图表 2



图表 3

对于正在或计划开展集群实验的研究者和政策评估团队，这篇论文提供了一个重要的提醒：不要假设你的集群是同质的。忽略异质性，你可能会得到一个看起来漂亮、但实际上毫无检测能力的实验设计。而修正方法，论文已经给出了。